

drugo_pitanje

36557629 Damjan Crnković

2026-01-23

```
oscars <- read.csv2("oscars_dataset.csv")
oscars$Award <- factor(oscars$Award,
                      levels = c("Nominee", "Winner"))

oscars$Main.Genre <- factor(oscars$Main.Genre)
oscars$Subgenre <- factor(oscars$Subgenre)
oscars$Content.Rating <- factor(oscars$Content.Rating)

# Numeričke varijable
oscars$Year.of.Release <- as.integer(oscars$Year.of.Release)
oscars$Movie.Time <- as.integer(oscars$Movie.Time)

oscars$IMDB.Rating <- as.numeric(oscars$IMDB.Rating)
oscars$IMDB.Votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes))

oscars$Tomatometer.Rating <- as.numeric(oscars$Tomatometer.Rating)
oscars$Tomatometer.Count <- as.numeric(oscars$Tomatometer.Count)

oscars$Audience.Rating <- as.numeric(oscars$Audience.Rating)
oscars$Audience.Count <- as.numeric(oscars$Audience.Count)

# Datumi
oscars$Original.Release.Date <- as.Date(oscars$Original.Release.Date)
```

Analiza razlika u prosječnom trajanju filmova među žanrovima

Opis problema

Glavno pitanje iduće analize je utvrditi postoje li statistički značajne razlike u prosječnom trajanju filmova različitih žanrova. Kako bismo to ispitali, provjerit ćemo razdiobu trajanja filmova po glavnim žanrovima (Main.Genre) te primijeniti odgovarajuće statističke testove. Najprije pregledajmo koliko filmova pripada svakom žanru u našim podacima.

Priprema podataka

```
count <- table(oscars$Main.Genre)
count_df <- as.data.frame(count)
```

```
colnames(count_df) <- c("Glavni žanr", "Broj filmova")
kable(count_df, caption = "Broj filmova po glavnom žanru")
```

Table 1: Broj filmova po glavnom žanru

Glavni žanr	Broj filmova
Action	39
Adventure	45
Animation	3
Biography	101
Comedy	108
Crime	48
Drama	215
Family	1
Film-Noir	2
Horror	3
Music	1
Musical	2
Romance	1
Western	2

Zbog malog broja filmova nekih žanrova, svrstat ćemo te filmove u rang ‘Other’ kako bi analiza bila pouzdana i rezultati jasni za tumačenje.

```
oscars$Main.Genre2 <- as.character(oscars$Main.Genre)
small_genres <- c("Animation", "Family", "Film-Noir", "Horror",
                 "Music", "Musical", "Romance", "Western")
oscars$Main.Genre2[oscars$Main.Genre2 %in% small_genres] <- "Other"
oscars$Main.Genre2 <- factor(oscars$Main.Genre2)
paste0("Broj filmova sa žanrom 'Other': ", sum(oscars$Main.Genre2=="Other"))
```

```
## [1] "Broj filmova sa žanrom 'Other': 15"
```

Do kraja ove analize kao žanr koristit ćemo kolonu Main.Genre2.

Pretpostavke ANOVA-e

Najbolje ćemo utvrditi postoje li razlike u prosječnom trajanju filmova među žanrovima primjenom jedno-faktorske ANOVA-e ili njezine neparemetarske alternative, Kruskal-Wallis testa. Prikladni test odabiremo ovisno o tome jesu li zadovoljene iduće pretpostavke:

- 1 - Normalnost razioke podataka o trajanju filmova
- 2 - Homogenost varijanci podataka o trajanju filmova
- (3 - Nezavisnost opažanja)

Provjerimo sada normalnost podataka po žanrovima pomoću Lillieforsova testa na razini značajnosti $\alpha=0.05$. Hipoteze su:

H0: Podaci unutar žanra slijede normalnu distribuciju

H1: Podaci unutar žanra ne slijede normalnu distribuciju.

```

razliciti_genres <- levels(oscars$Main.Genre2)
normality_results <- data.frame(Genre = character(),
                                P_value = numeric(),
                                stringsAsFactors = FALSE)
for (genre in razliciti_genres) {
  genre_data <- oscars$Movie.Time[oscars$Main.Genre2 == genre]
  genre_test <- lillie.test(genre_data)

  normality_results <- rbind(normality_results,
                              data.frame(Genre = genre,
                                          P_value = genre_test$p.value))
}

kable(normality_results,
      col.names = c("Žanr", "P-vrijednost"),
      caption = "Lillieforsov test normalnosti trajanja filmova po žanru")

```

Table 2: Lillieforsov test normalnosti trajanja filmova po žanru

Žanr	P-vrijednost
Action	0.0149510
Adventure	0.0255196
Biography	0.0000451
Comedy	0.6720958
Crime	0.0435017
Drama	0.0001238
Other	0.1093098

Budući da većina distribucija trajanja filmova po žanrovima nije normalna (p -vrijednost < 0.05), nećemo primjeniti Barlettov test niti jednofaktorsku ANOVA-u, već koristimo (manje statistički značajan) Kruskal-Wallis test.

Kruskal-Wallis test

Provedimo sada test na razini značajnosti $\alpha=0.05$ sa sljedećim hipotezama:

H0: Medijani svih uzoraka su jednaki

H1: Barem dva medijana nisu jednaka.

Uvjet za primjenjivost testa je zadovoljen, odnosno veličina svakog uzorka je barem 5.

```
kruskal.test(Movie.Time ~ Main.Genre2, data = oscars)
```

```

##
##  Kruskal-Wallis rank sum test
##
## data:  Movie.Time by Main.Genre2
## Kruskal-Wallis chi-squared = 62.001, df = 6, p-value = 1.764e-11


```

Rezultati Kruskal-Wallis testa pokazuju vrlo malu p -vrijednost, što znači da odbacujemo nul-hipotezu u korist alternativne hipoteze. Barem jedna distribucija trajanja se značajno razlikuje od ostalih, odnosno postoji razlika u medijanima populacija.

Vizualna i deskriptivna analiza

Ostaje nam da vizualno očitamo koje žanrove karakterizira dulje ili kraće trajanje filmova, što možemo prikazati pomoću box-plota po žanrovima.

```
boxplot(Movie.Time ~ Main.Genre2,  
  data = oscars,  
  main = "Trajanje filmova po glavnom žanru",  
  xlab = "",  
  ylab = "Trajanje (minute)",  
  las = 2)
```



Pogledajmo i srednje vrijednosti:

```
mean_table <- oscars %>%  
  group_by(Main.Genre2) %>%  
  summarise(Mean_Duration = mean(Movie.Time, na.rm = TRUE),  
    Count = n()) %>%  
  arrange(desc(Mean_Duration))  
colnames(mean_table) <- c("Glavni žanr", "Srednje trajanje filma", "Broj filmova")  
kable(mean_table, caption = "Prosječno trajanje filmova po glavnom žanru")
```

Table 3: Prosječno trajanje filmova po glavnom žanru

Glavni žanr	Srednje trajanje filma	Broj filmova
Adventure	139.6444	45
Action	132.2564	39
Biography	132.2178	101
Drama	125.5256	215
Crime	122.2083	48
Comedy	111.8426	108
Other	105.7333	15

Ističu se filmovi žanra “Adventure” kao najduži u prosjeku.