

Oscarovci

Tim #1

2025-11-06

Contents

1	Opis skupa podataka	3
2	Priprema podataka za analizu	3
3	Analiza žanrova kod pobjednika	5
3.1	Opis problema	5
3.2	Single-label analiza	5
3.3	Multi-label analiza	7
3.4	Statističko testiranje	10
3.5	Zaključak	14
4	Analiza razlika u prosječnom trajanju filmova među žanrovima	15
4.1	Opis problema	15
4.2	Priprema podataka	15
4.3	Pretpostavke ANOVA-e	16
4.4	Kruskal-Wallis test	16
4.5	Vizualna i deskriptivna analiza	17
5	Istraživanje povezanosti između starosti filma i njegove ocjene	19
5.1	Opis problema	19
5.2	Vizualizacija podataka	19
5.3	Linearna regresija	20
5.4	Analiza reziduala	21
5.5	Q-Q graf	22
5.6	Testiranje Lillieforsovom inačicom	23
5.7	Pearsonov koeficijent korelacije	23

6	Možemo li naslutiti kako je film ocijenjen pomoću drugih značajki?	25
6.1	Opis problema	25
6.2	Deskriptivna statistika	25
6.3	Model višestruke linearne regresije	27
6.4	Test normalnosti reziduala	31
6.5	Bootstrap analiza	32
6.6	Zaključak	34
7	Analiza predviđanja pobjednika	35

1 Opis skupa podataka

Skup podataka koji analiziramo u projektu sadrži 571 odgovor/redak.

```
oscars = read_csv2("oscars_dataset.csv",
                  locale = locale(decimal_mark = ",", grouping_mark = "."),
                  show_col_types = FALSE)
var_types <- sapply(oscars, class)
names(oscars) <- make.names(names(oscars))
cat(paste(names(var_types), ": ", var_types, sep = "", collapse = "\n"))

## Unnamed: 0: numeric
## Film: character
## Oscar Year: character
## Film Studio/Producer(s): character
## Award: character
## Year of Release: numeric
## Movie Time: numeric
## Movie Genre: character
## Main Genre: character
## Subgenre: character
## IMDB Rating: numeric
## IMDB Votes: character
## Content Rating: character
## Directors: character
## Original Release Date: Date
## Production Company: character
## Tomatometer Rating: numeric
## Tomatometer Count: numeric
## Audience Rating: numeric
## Audience Count: numeric
```

2 Priprema podataka za analizu

```
oscars$Award <- factor(oscars$Award,
                      levels = c("Nominee", "Winner"))

oscars$Main.Genre <- factor(oscars$Main.Genre)
oscars$Subgenre <- factor(oscars$Subgenre)
oscars$Content.Rating <- factor(oscars$Content.Rating)
oscars$Movie.Genre <- factor(oscars$Movie.Genre)

oscars$Year.of.Release <- as.numeric(oscars$Year.of.Release)
oscars$Movie.Time <- as.numeric(oscars$Movie.Time)

oscars$IMDB.Rating <- as.numeric(oscars$IMDB.Rating)
oscars$IMDB.Votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes))

oscars$Tomatometer.Rating <- as.numeric(oscars$Tomatometer.Rating)
oscars$Tomatometer.Count <- as.numeric(oscars$Tomatometer.Count)
```

```
oscars$Audience.Rating <- as.numeric(oscars$Audience.Rating)
oscars$Audience.Count <- as.numeric(oscars$Audience.Count)

oscars$Original.Release.Date <- as.Date(oscars$Original.Release.Date)

oscars <- oscars[complete.cases(oscars[, c("IMDB.Rating",
                                           "Year.of.Release",
                                           "Movie.Time",
                                           "Main.Genre",
                                           "Content.Rating")]), ]
```

3 Analiza žanrova kod pobjednika

3.1 Opis problema

Cilj ove analize je ispitati postoji li povezanost između žanra filma i vjerojatnosti osvajanja Oscara. Analizu provodimo na dva načina zbog višestrukosti žanrova.

U single-label pristupu svakom filmu pridružujemo jedan glavni žanr. U multi-label pristupu film može pripadati više žanrova koji se zasebno broje. Time uspoređujemo kako različite metode označavanja utječu na zaključke.

3.2 Single-label analiza

3.2.1 Grupiranje žanrova i priprema podataka za analizu:

Prvo nego što krenemo raditi bilo kakve statističke testove, moramo se upoznati s podacima. U datasetu se nalazi više stupaca koje sadrže kako su labelirani filmovi po žanrovima.

```
winners <- oscars %>% filter(Award == "Winner")
nominees <- oscars %>% filter(Award %in% c("Nominee", "Winner"))

winner_counts <- winners %>%
  count(Main.Genre, name = "Winners")

nominee_counts <- nominees %>%
  count(Main.Genre, name = "Nominations")

genre_table <- nominee_counts %>%
  left_join(winner_counts, by = "Main.Genre") %>%
  mutate(
    Winners = replace_na(Winners, 0),
    NotWinner = Nominations - Winners
  ) %>%
  rename(Genre = Main.Genre)
```

Vizualizacija pobjeda i nominacija po žanru:


```
genre_plot_data <- genre_table %>%
  arrange(desc(Winners)) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )

ggplot(genre_plot_data,
  aes(x = Count,
    y = reorder(Genre, Count),
    fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  geom_text(aes(label = Count),
    position = position_stack(vjust = 0.5),
```

```

    size = 3) +
scale_fill_manual(values = c(
  "Winners" = "#1f78b4",
  "NotWinner" = "#a6cee3"
)) +
theme_minimal(base_size = 15) +
labs(
  title = "Oscari po žanru: Pobjede i nominacije",
  x = "Broj filmova",
  y = "Žanr",
  fill = ""
) +
coord_flip() +
theme(
  axis.text.x = element_text(angle = 90, hjust = 1)
)

```




Zbog velike disproporcije između broja pobjeda i nominacija, koristimo i logaritamsku skalu kako bismo mogli bolje vizualizirati podatke.

3.2.2 Logaritamska skala za broj pobjeda vs nominacija po žanru:

```

ggplot(genre_plot_data, aes(x = reorder(Genre, Count), y = Count + 1, fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  scale_y_log10() +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Oscari po žanru (log skala)",
    x = "Žanr", y = "Broj filmova (log10)", fill = "") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

```



3.2.3 Kontigencijska tablica nominiranih i pobjednika po žanrovima:

```
kontigencijska <- as.data.frame(genre_table[, c("Winners", "NotWinner")])
row.names(kontigencijska) <- genre_table$Genre
```

3.3 Multi-label analiza

3.3.1 Priprema podataka

Priprema podataka za multi-label analizu žanrova:

```
oscars_long <- oscars %>%
  separate_rows(Movie.Genre, sep = ",") %>%
  mutate(Movie.Genre = trimws(Movie.Genre))
```

Mutiramo podatke kako bismo razdvojili višestruke žanrove u zasebne retke.

```
oscars_long <- oscars %>%
  separate_rows(Movie.Genre, sep = ",") %>%
  mutate(Movie.Genre = trimws(Movie.Genre))
```

Izračun broja pobjeda i ne-pobjeda po žanru:

```
genre_counts <- oscars_long %>%
  mutate(
    Outcome = ifelse(Award == "Winner", "Winner", "NotWinner")
  ) %>%
  count(Movie.Genre, Outcome) %>%
```

```

pivot_wider(
  names_from = Outcome,
  values_from = n,
  values_fill = 0
) %>%
mutate(
  Total = Winner + NotWinner,
  GenreGroup = ifelse(Total < 5, "Other", Movie.Genre),
  SuccessRate = Winner / Total
)

```

Grupiranje rijetkih žanrova u kategoriju “Ostali” i izračun ukupnih vrijednosti po grupama žanrova:

```

genre_table_ml <- genre_counts %>%
  group_by(GenreGroup) %>%
  summarise(
    Winners = sum(Winner),
    NotWinner = sum(NotWinner),
    Total = sum(Total),
    SuccessRate = sum(Winner)/sum(Total),
    .groups = "drop"
  )

```

3.3.2 Vizualizacija rezultata multi-label analize žanrova:

```

genre_melt <- genre_table_ml %>%
  select(GenreGroup, Winners, NotWinner) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  ) %>%
  arrange(desc(Count))

ggplot(genre_melt,
  aes(x = Count,
    y = reorder(GenreGroup, Count),
    fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  geom_text(aes(label = Count),
    position = position_stack(vjust = 0.5),
    size = 3) +
  scale_fill_manual(values = c(
    "Winners" = "#1f78b4",
    "NotWinner" = "#a6cee3"
  )) +
  theme_minimal(base_size = 14) +
  labs(
    title = "Multi-label analiza žanrova (broj pojavljivanja)",
    x = "Broj pojavljivanja",
    y = "Žanr",


```



```

    fill = ""
  ) +
  coord_flip() +
  theme(
    axis.text.x = element_text(angle = 90, hjust = 1)
  )


```



```

ggplot(genre_melt, aes(x = reorder(GenreGroup, Count), y = Count + 1, fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  scale_y_log10() +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(
    title = "Multi-label analiza žanrova (log skala)",
    x = "Žanr",
    y = "Broj pojavljivanja (log10)",
    fill = ""
  ) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

```



3.4 Statističko testiranje

3.4.1 Hipoteze:

- Nulta hipoteza (H0): Ne postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.
- Alternativna hipoteza (H1): Postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.

3.4.2 Grupiranje žanrova i priprema podataka za analizu:

Kako bi ispitali nezavisnost dviju kategorijske varijable, odnosno kako bi ispitali jesu li žanrovi i pobjede zavisni, koristit ćemo hi-kvadrat test.

Hi-kvadrat statistika se provodi formulom:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

gdje je:

- O_{ij} = promatrana frekvencija u ćeliji (i, j)
- E_{ij} = očekivana frekvencija ako su varijable neovisne

i

- Mala vrijednost $\chi^2 \rightarrow$ promatrane frekvencije blizu očekivanih (neovisnost)

- Velika vrijednost $\chi^2 \rightarrow$ značajna odstupanja (ovisnost)

Stupnjevi slobode računamo:

$$df = (r - 1)(c - 1)$$

Standardizirani reziduali za procjenu odstupanja pojedine ćelije, odnosno u ovome slučaju žanra:

$$\text{StdRes}_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

- Pozitivni rezidual $\rightarrow$ više promatranih nego očekivanih
- Negativni rezidual $\rightarrow$ manje promatranih nego očekivanih
- Vrijednosti veće od ± 2 obično se smatraju **statistički značajnim!**

Važno je reći da hi-kvadrat test ima važan uvjet: očekivane frekvencije u svakoj ćeliji kontingencijske tablice trebaju biti veće od 5. Za žanrove s jako malim brojem filmova (npr. 1–2 pojave), očekivane frekvencije za te vrlo male. Kako bi statistički test bio valjan, grupirat ćemo manje zastupljene žanrove u kategoriju “Ostali” kako bismo osigurali da sve ćelije imaju dovoljne očekivane frekvencije.

3.4.3 Prvo ćemo analizirati prvi pristup: Single-label analiza

```
common_genres <- c("Action", "Adventure", "Biography", "Comedy", "Crime", "Drama")
oscars$GenreGroup <- ifelse(oscars$Main.Genre %in% common_genres,
                             oscars$Main.Genre,
                             "Other")

winner_counts <- as.data.frame(table(subset(oscars, Award=="Winner")$GenreGroup))
colnames(winner_counts) <- c("GenreGroup", "Winners")

nominee_counts <- as.data.frame(table(subset(oscars, Award %in% c("Winner", "Nominee"))$GenreGroup))
colnames(nominee_counts) <- c("GenreGroup", "Nominations")

df <- merge(nominee_counts, winner_counts, by="GenreGroup", all.x=TRUE)
df$Winners[is.na(df$Winners)] <- 0

df$NotWinner <- df$Nominations - df$Winners

kontigencijska_single <- as.data.frame(df[, c("Winners", "NotWinner")])
row.names(kontigencijska_single) <- df$GenreGroup

kontigencijska_single
```

```
##      Winners NotWinner
## 1          3         29
## 2          8         28
## 4         18         69
## 5         12         73
## 6          8         32
## 7         36        136
## Other          0          7
```

3.4.4 Hi-kvadrat test:

Sada radimo Hi-kvadrat test kako bismo vidjeli postoje li značajne razlike u učestalosti pobjeda među različitim žanrovima. Za razinu značajnosti, uzet ćemo $\alpha = 0,05$.

```
chisq_single <- chisq.test(kontigencijska_single)
```

```
## Warning in chisq.test(kontigencijska_single): Chi-squared approximation may be
## incorrect
```

```
chisq_single
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_single
## X-squared = 5.7752, df = 6, p-value = 0.4488
```

S obzirom na to da je $p\text{-value} > \alpha$, odnosno $0.1805 > 0.05$, prihvaćamo H_0 .

Standardizirani reziduali koji pokazuju kako žanrovi odstupaju:

```
chisq_single$stdres
```

```
##           Winners NotWinner
## 1    -1.3805374  1.3805374
## 2     0.5959243 -0.5959243
## 4     0.5790940 -0.5790940
## 5    -1.1571405  1.1571405
## 6     0.2524602 -0.2524602
## 7     1.0297288 -1.0297288
## Other -1.2710417  1.2710417
```

3.4.5 Zatim analiziramo Multi-label analizu:

```
kontigencijska_multi <- genre_table_ml[, c("Winners", "NotWinner")]
row.names(kontigencijska_multi) <- genre_table_ml$GenreGroup
```

```
## Warning: Setting row names on a tibble is deprecated.
```

```
kontigencijska_multi
```

```
## # A tibble: 20 x 2
##   Winners NotWinner
## *   <int>     <int>
## 1      3         29
## 2     10         45
## 3     20         73
## 4     15         86
```

```
## 5      12      48
## 6      79     328
## 7       5      18
## 8       1      20
## 9       2       8
## 10     12      41
## 11      1      19
## 12      7      14
## 13      1      21
## 14      0       6
## 15     22     107
## 16      0       9
## 17      3       7
## 18      7      28
## 19     11      20
## 20      2       9
```

3.4.6 Hi-kvadrat test

```
chisq_multi <- chisq.test(kontigencijska_multi)
```

```
## Warning in chisq.test(kontigencijska_multi): Chi-squared approximation may be
## incorrect
```

```
chisq_multi
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_multi
## X-squared = 25.666, df = 19, p-value = 0.1398
```

```
chisq_multi$stdres
```

```
##           Winners  NotWinner
## Action    -1.35279417  1.35279417
## Adventure -0.06963455  0.06963455
## Biography  0.76816603 -0.76816603
## Comedy    -0.99823258  0.99823258
## Crime      0.29936654 -0.29936654
## Drama      0.56362895 -0.56362895
## Family     0.39908880 -0.39908880
## Fantasy    -1.63956676  1.63956676
## Film-Noir  0.11950325 -0.11950325
## History    0.78714607 -0.78714607
## Music      -1.57170245  1.57170245
## Musical    1.76090654 -1.76090654
## Mystery    -1.70527353  1.70527353
## Other      -1.17155964  1.17155964
## Romance    -0.46021691  0.46021691
```

```
## Sci-Fi      -1.43674840  1.43674840
## Sport       0.93682010 -0.93682010
## Thriller    0.22606483 -0.22606483
## War         2.46138625 -2.46138625
## Western     -0.03053355  0.03053355
```

Ovdje također vidimo da je $p - value > \alpha$, odnosno $0.1036 > 0.05$ te prihvaćamo H_0 .

3.5 Zaključak

Na temelju dobivenih rezultata Hi-kvadrat testa kod oba pristupa, prihvaćamo H_0 i možemo zaključiti da ne postoje značajne razlike u učestalosti pobjeda među različitim žanrovima filmova nominiranih za Oscara. Standardizirani reziduali ukazuju na to koji žanrovi značajno odstupaju od očekivanih vrijednosti, što može biti korisno za daljnje istraživanje i razumijevanje trendova u dodjeli nagrada, kao i pitanje zašto su neki žanrovi češće nominirani od ostalih.

4 Analiza razlika u prosječnom trajanju filmova među žanrovima

4.1 Opis problema

Glavno pitanje iduće analize je utvrditi postoje li statistički značajne razlike u prosječnom trajanju filmova različitih žanrova. Kako bismo to ispitali, provjerit ćemo razdiobu trajanja filmova po glavnim žanrovima (Main.Genre) te primijeniti odgovarajuće statističke testove. Najprije pregledajmo koliko filmova pripada svakom žanru u našim podacima.

4.2 Priprema podataka

```
count <- table(oscars$Main.Genre)
count_df <- as.data.frame(count)
colnames(count_df) <- c("Glavni žanr", "Broj filmova")
kable(count_df, caption = "Broj filmova po glavnom žanru")
```

Table 1: Broj filmova po glavnom žanru

Glavni žanr	Broj filmova
Action	32
Adventure	36
Animation	3
Biography	87
Comedy	85
Crime	40
Drama	172
Family	0
Film-Noir	1
Horror	2
Music	0
Musical	0
Romance	0
Western	1

Zbog malog broja filmova nekih žanrova, svrstat ćemo te filmove u rang ‘Other’ kako bi analiza bila pouzdana i rezultati jasni za tumačenje.

```
oscars$Main.Genre2 <- as.character(oscars$Main.Genre)
small_genres <- c("Animation", "Family", "Film-Noir", "Horror",
                 "Music", "Musical", "Romance", "Western")
oscars$Main.Genre2[oscars$Main.Genre2 %in% small_genres] <- "Other"
oscars$Main.Genre2 <- factor(oscars$Main.Genre2)
paste0("Broj filmova sa žanrom 'Other': ", sum(oscars$Main.Genre2=="Other"))
```

```
## [1] "Broj filmova sa žanrom 'Other': 7"
```

Do kraja ove analize kao žanr koristit ćemo kolonu Main.Genre2.

4.3 Pretpostavke ANOVA-e

Najbolje ćemo utvrditi postoje li razlike u prosječnom trajanju filmova među žanrovima primjenom jedno-faktorske ANOVA-e ili njezine neparemetarske alternative, Kruskal-Wallis testa. Prikladni test odabiremo ovisno o tome jesu li zadovoljene iduće pretpostavke:

- 1 - Normalnost razioke podataka o trajanju filmova
- 2 - Homogenost varijanci podataka o trajanju filmova
- (3 - Nezavisnost opažanja)

Provjerimo sada normalnost podataka po žanrovima pomoću Lillieforsova testa na razini značajnosti $\alpha=0.05$. Hipoteze su:

H0: Podaci unutar žanra slijede normalnu distribuciju

H1: Podaci unutar žanra ne slijede normalnu distribuciju.

```
razliciti_genres <- levels(oscars$Main.Genre2)
normality_results <- data.frame(Genre = character(),
                                P_value = numeric(),
                                stringsAsFactors = FALSE)

for (genre in razliciti_genres) {
  genre_data <- oscars$Movie.Time[oscars$Main.Genre2 == genre]
  genre_test <- lillie.test(genre_data)

  normality_results <- rbind(normality_results,
                             data.frame(Genre = genre,
                                           P_value = genre_test$p.value))
}

kable(normality_results,
      col.names = c("Žanr", "P-vrijednost"),
      caption = "Lillieforsov test normalnosti trajanja filmova po žanru")
```

Table 2: Lillieforsov test normalnosti trajanja filmova po žanru

Žanr	P-vrijednost
Action	0.0554327
Adventure	0.0357200
Biography	0.0000002
Comedy	0.4915238
Crime	0.0802807
Drama	0.0029991
Other	0.2797697

Budući da većina distribucija trajanja filmova po žanrovima nije normalna (p -vrijednost < 0.05), nećemo primjeniti Barlettov test niti jednofaktorsku ANOVA-u, već koristimo (manje statistički značajan) Kruskal-Wallis test.

4.4 Kruskal-Wallis test

Provedimo sada test na razini značajnosti $\alpha=0.05$ sa sljedećim hipotezama:

H0: Medijani svih uzoraka su jednaki

H1: Barem dva medijana nisu jednaka.

Uvjet za primjenjivost testa je zadovoljen, odnosno veličina svakog uzorka je barem 5.


```
kruskal.test(Movie.Time ~ Main.Genre2, data = oscars)
```


```
##
## Kruskal-Wallis rank sum test
##
## data:  Movie.Time by Main.Genre2
## Kruskal-Wallis chi-squared = 60.298, df = 6, p-value = 3.915e-11
```

Rezultati Kruskal-Wallis testa pokazuju vrlo malu p-vrijednost, što znači da odbacujemo nul-hipotezu u korist alternativne hipoteze. Barem jedna distribucija trajanja se značajno razlikuje od ostalih, odnosno postoji razlika u medijanima populacija.

4.5 Vizualna i deskriptivna analiza

Ostaje nam da vizualno očitamo koje žanrove karakterizira dulje ili kraće trajanje filmova, što možemo prikazati pomoću box-plota po žanrovima.

```
boxplot(Movie.Time ~ Main.Genre2,
        data = oscars,
        main = "Trajanje filmova po glavnom žanru",
        xlab = "",
        ylab = "Trajanje (minute)",
        las = 2)
```



Pogledajmo i srednje vrijednosti:

```
mean_table <- oscars %>%
  group_by(Main.Genre2) %>%
  summarise(Mean_Duration = mean(Movie.Time, na.rm = TRUE),
            Count = n()) %>%
```

```

arrange(desc(Mean_Duration))
colnames(mean_table) <- c("Glavni žanr", "Srednje trajanje filma", "Broj filmova")
kable(mean_table, caption = "Prosječno trajanje filmova po glavnom žanru")

```

Table 3: Prosječno trajanje filmova po glavnom žanru

Glavni žanr	Srednje trajanje filma	Broj filmova
Adventure	142.3889	36
Action	137.6875	32
Biography	134.5057	87
Drama	126.0407	172
Crime	122.3500	40
Comedy	113.3176	85
Other	100.4286	7

Ističu se filmovi žanra “Adventure” kao najduži u prosjeku.

5 Istraživanje povezanosti između starosti filma i njegove ocjene


5.1 Opis problema

Jedno od pitanja koje razmatramo jest kako su filmovi ocijenjeni s obzirom na svoju starost, odnosno kako godina izlaska filma utječe na njegovu ocjenu. Cilj je dobiti uvid u trend promjene ocjena kroz godine i provjeriti jesu li godina izlaska i ocjena međusobno značajno korelirani.

5.2 Vizualizacija podataka

Analizirajmo sada povezanost između godine izlaska filma i njegove ocjene. Budući da promatramo utjecaj jedne numeričke varijable (godina izlaska) na drugu numeričku varijablu (ocjena), osnovni uvid u njihov odnos dobiva se grafičkim prikazom pomoću scatter plot. Takav prikaz omogućuje uočavanje općeg trenda i eventualne nelinearnosti.


```
plot(oscars$Year.of.Release, oscars$IMDB.Rating,  
      main = "Odnos godine izlaska filma i IMDb ocjene",  
      xlab = "Godina izlaska filma",  
      ylab = "IMDb ocjena")
```



Scatter plot ne pokazuje jasno povećanje ocjena s godinama izlaska zbog raspršenosti podataka i prisutnosti outliersa. Kako bismo bolje sagledali trend, možemo grupirati filmove po desetljećima i prikazati ocjene pomoću box plot, što omogućuje uočavanje promjena u medijanu i rasponu ocjena kroz vrijeme.

```
oscars$desetljece <- floor(oscars$Year.of.Release / 10) * 10  
boxplot(IMDB.Rating ~ desetljece, data = oscars,  
        main = "Distribucija IMDb ocjena po desetljećima",  
        xlab = "Desetljeće izlaska filma",  
        ylab = "IMDb ocjena")
```

Distribucija IMDb ocjena po desetljećima




Iz scatter plotu i box plotu može se naslutiti da postoji određena povezanost između godine izlaska filma i njegove ocjene, no ona se ne čini velikom.

5.3 Linearna regresija

Kako bismo procijenili jačinu promatranog odnosa, izrađujemo jednostavnu linearnu regresiju s ocjenom filma kao zavisnom varijablom i godinom izlaska kao nezavisnom varijablom.

```
fit.year <- lm(IMDB.Rating ~ Year.of.Release, data = oscars)
plot(oscars$Year.of.Release, oscars$IMDB.Rating,
     main = "Linearna regresija IMDb ocjene ~ godina izlaska",
     xlab = "Godina izlaska filma",
     ylab = "IMDb ocjena")
lines(oscars$Year.of.Release, fit.year$fitted.values, col = "blue")
```

Linearna regresija IMDb ocjene ~ godina izlaska




Dobiveni regresijski model pokazuje mali pozitivan nagib, što znači da noviji filmovi u prosjeku imaju nešto više ocjene, no efekt je slab. Kako bismo potvrdili valjanost ovakvog zaključka, potrebno je provjeriti temeljne pretpostavke linearne regresije, prvenstveno normalnost distribucije reziduala (i homogenost njihove varijance).

5.4 Analiza reziduala

Za vizualnu provjeru pretpostavke normalnosti reziduala koristimo histogram, koji omogućuje uvid u raspodjelu pogrešaka. Potpunu potvrdu normalnosti provjerit ćemo kasnije odgovarajućim statističkim testovima.

```
selected.model <- fit.year
hist(selected.model$residuals, breaks = 15,
      main = "Histogram reziduala linearnog regresijskog modela",
      xlab = "Reziduali modela",
      ylab = "Frekvencija")
```


Histogram reziduala linearnog regresijskog modela



5.5 Q-Q graf

Normalnost reziduala egzaktnije možemo provjeriti Q-Q plotom kako bismo utvrdili da pogreške modela približno slijede normalnu distribuciju, što je pretpostavka za valjanost statističkih testova koeficijenata i intervala pouzdanosti.

```
qqnorm(rstandard(selected.model),  
      main = "Q-Q dijagram standardiziranih reziduala",  
      xlab = "Teorijski kvantili normalne razdiobe",  
      ylab = "Standardizirani reziduali")  
qqline(rstandard(selected.model))
```



Q-Q graf pokazuje da reziduali uglavnom prate dijagonalnu liniju, s blagim odstupanjima na krajevima, što sugerira da pretpostavka normalnosti nije značajno narušena.

5.6 Testiranje Lillieforsovom inačicom

Provjerimo sada normalnost reziduala Lillieforsovom inačicom Kolmogorov-Smirnovljeva testa na razini značajnosti od 5% uz sljedeće hipoteze:

H0: Reziduali su normalno distribuirani

H1: Reziduali nisu normalno distribuirani.

```
lillie.test(rstandard(fit.year))
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  rstandard(fit.year)
## D = 0.029715, p-value = 0.4182
```

Testna statistika pokazuje vrlo visoku p-vrijednost. Budući da je ona veća od 0.05, test nije statistički značajan te nemamo dovoljno dokaza za odbacivanje nul-hipoteze. Reziduali se mogu smatrati normalno distribuiranim.

5.7 Pearsonov koeficijent korelacije

Kao završni korak analize, računamo Pearsonov koeficijent korelacije i provodimo test kako bismo statistički evaluirali odnos između godine nastanka filma i njegove IMDb ocjene. Test provodimo na razini značajnosti od 5% uz hipoteze:

H0: Ne postoji linearna povezanost između godine izlaska filma i IMDb ocjene.

H1: Postoji linearna povezanost između godine izlaska filma i IMDb ocjene.

```
cor.test(oscars$Year.of.Release,oscars$IMDB.Rating)
```

```
##  
## Pearson's product-moment correlation  
##  
## data:  oscars$Year.of.Release and oscars$IMDB.Rating  
## t = 5.3757, df = 457, p-value = 1.219e-07  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
##  0.1558226 0.3280753  
## sample estimates:  
##      cor  
## 0.2438714
```

Koeficijent korelacije r iznosi 0,33 što ukazuje na umjerenu pozitivnu korelaciju dviju varijabli. P-vrijednost je vrlo mala, manja od 0,05. S obzirom na to, odbacujemo hipotezu H_0 te je pozitivna povezanost statistički značajna. 95-postotni interval pouzdanosti je cijelim dijelom pozitivan što je još jedan indikator da pozitivna povezanost postoji.

Na temelju početnih deskriptivnih statistika opravdano bi bilo zaključiti i da stvarna korelacija između varijabli ne postoji te da je uočeni pozitivan trend posljedica šuma. Međutim, provedena statistička analiza i testovi pokazuju da je povezanost statistički značajna, a zbog velikog uzorka takav je zaključak opravdan.

6 Možemo li naslutiti kako je film ocijenjen pomoću drugih značajki?

6.1 Opis problema

U ovoj analizi istražujemo možemo li pomoću dostupnih značajki filmova (godina izlaska, trajanje, žanr i content rating) pouzdano predvidjeti IMDb ocjenu. Cilj je izgraditi model višestruke linearne regresije koji će omogućiti razumijevanje koje karakteristike utječu na ocjenu i koliko taj utjecaj snažan.

6.2 Deskriptivna statistika

```
data.frame(  
  Varijabla = c("IMDB.Rating", "Year.of.Release", "Movie.Time"),  
  Mean = c(  
    mean(oscars$IMDB.Rating, na.rm = TRUE),  
    mean(oscars$Year.of.Release, na.rm = TRUE),  
    mean(oscars$Movie.Time, na.rm = TRUE)  
  ),  
  Median = c(  
    median(oscars$IMDB.Rating, na.rm = TRUE),  
    median(oscars$Year.of.Release, na.rm = TRUE),  
    median(oscars$Movie.Time, na.rm = TRUE)  
  ),  
  SD = c(  
    sd(oscars$IMDB.Rating, na.rm = TRUE),  
    sd(oscars$Year.of.Release, na.rm = TRUE),  
    sd(oscars$Movie.Time, na.rm = TRUE)  
  ),  
  IQR = c(  
    IQR(oscars$IMDB.Rating, na.rm = TRUE),  
    IQR(oscars$Year.of.Release, na.rm = TRUE),  
    IQR(oscars$Movie.Time, na.rm = TRUE)  
  )  
)
```

##	Varijabla	Mean	Median	SD	IQR
## 1	IMDB.Rating	76.38344	77	5.047052	7
## 2	Year.of.Release	1977.73638	1979	28.569807	55
## 3	Movie.Time	126.67102	123	25.443804	29

6.2.1 Korelacijska matrica

Računamo korelacijsku matricu za ispitivanje linearnih odnosa između naših numeričkih varijabli.

```
cor_matrix <- cor(oscars[, c("IMDB.Rating", "Movie.Time", "Year.of.Release")],  
  use = "complete.obs")  
print(round(cor_matrix, 3))
```

```
##          IMDB.Rating Movie.Time Year.of.Release
```

## IMDB.Rating	1.000	0.233	0.244
## Movie.Time	0.233	1.000	0.177
## Year.of.Release	0.244	0.177	1.000


Korelacijska matrica pokazuje odnose između numeričkih prediktora. Pozitivna korelacija između godine izlaska i IMDb ocjene ukazuje na to da noviji filmovi teže imati više ocjene.

6.2.2 Scatter plot: IMDb ocjena vs trajanje filma

Grafički prikaz odnosa između trajanja filma i IMDb ocjene pomoću dijagrama raspršenja.

```
plot(oscars$Movie.Time, oscars$IMDB.Rating,
     main = "Odnos trajanja filma i IMDb ocjene",
     xlab = "Trajanje filma (minute)",
     ylab = "IMDb ocjena",
     pch = 19, col = rgb(0, 0, 1, 0.4))

abline(lm(IMDB.Rating ~ Movie.Time, data = oscars),
       col = "red", lwd = 2)
```



Iz scatter plota možemo vidjeti blagu pozitivnu vezu između trajanja filma i ocjene. Crvena linija predstavlja linearnu regresiju.

6.3 Model višestruke linearne regresije

6.3.1 Priprema dummy varijabli

Budući da kategorijske varijable ne mogu direktno ući u linearni regresijski model, potrebno ih je transformirati u dummy varijable.

```
oscars_model <- fastDummies::dummy_cols(oscars,
                                         select_columns = c("Main.Genre", "Content.Rating"),
                                         remove_first_dummy = TRUE,
                                         remove_selected_columns = FALSE)

names(oscars_model) <- make.names(names(oscars_model))

genre_cols <- grep("^Main.Genre_", names(oscars_model), value = TRUE)
rating_cols <- grep("^Content.Rating_", names(oscars_model), value = TRUE)
```

Dummy varijable omogućuju uključivanje kategorijskih varijabli u model tako da svaka kategorija dobiva svoju indikatorsku varijablu. Važno je izostaviti jednu dummy varijablu iz svake kategorijske varijable kako bi se izbjegla multikolinearnost.

6.3.2 Procjena modela

```
base_predictors <- c("Year.of.Release", "Movie.Time")
all_predictors <- c(base_predictors, genre_cols, rating_cols)

cat("Broj prediktora u modelu:", length(all_predictors), "\n")
```

```
## Broj prediktora u modelu: 19
```

```
cat("Prvih 5 dummy varijabli:\n")
```

```
## Prvih 5 dummy varijabli:
```

```
print(head(all_predictors, 10))
```

```
## [1] "Year.of.Release"      "Movie.Time"           "Main.Genre_Adventure"
## [4] "Main.Genre_Animation" "Main.Genre_Biography" "Main.Genre_Comedy"
## [7] "Main.Genre_Crime"     "Main.Genre_Drama"     "Main.Genre_Family"
## [10] "Main.Genre_Film.Noir"
```

```
model_formula <- reformulate(termlabels = all_predictors,
                             response = "IMDB.Rating")

fit_multi <- lm(model_formula, data = oscars_model)

summary(fit_multi)
```

```
##
## Call:
## lm(formula = model_formula, data = oscars_model)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -16.6407  -2.8016   0.1135   3.3341  14.8056
##
## Coefficients: (4 not defined because of singularities)
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    111.901600    27.655102     4.046 6.14e-05 ***
## Year.of.Release   -0.021725     0.014156    -1.535 0.125587
## Movie.Time        0.042805     0.009248     4.629 4.84e-06 ***
## Main.Genre_Adventure -1.205653     1.133681    -1.063 0.288141
## Main.Genre_Animation  7.955434     2.901561     2.742 0.006358 **
## Main.Genre_Biography -1.273996     0.949222    -1.342 0.180235
## Main.Genre_Comedy    -0.892347     0.989588    -0.902 0.367687
## Main.Genre_Crime      1.313266     1.117311     1.175 0.240474
## Main.Genre_Drama     -0.995620     0.897331    -1.110 0.267802
## Main.Genre_Family      NA          NA         NA     NA
## Main.Genre_Film.Noir -0.332851     4.683974    -0.071 0.943381
## Main.Genre_Horror      0.573027     3.362794     0.170 0.864772
## Main.Genre_Music       NA          NA         NA     NA
## Main.Genre_Musical     NA          NA         NA     NA
## Main.Genre_Romance     NA          NA         NA     NA
## Main.Genre_Western   -18.444058     4.691874    -3.931 9.81e-05 ***
## Content.Rating_NR      0.361885     0.833878     0.434 0.664515
## Content.Rating_PG      2.882645     0.879901     3.276 0.001135 **
## Content.Rating_PG.13   4.372843     1.114756     3.923 0.000101 ***
## Content.Rating_R       4.529896     1.009920     4.485 9.28e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.578 on 443 degrees of freedom
## Multiple R-squared:  0.204, Adjusted R-squared:  0.1771
## F-statistic:  7.57 on 15 and 443 DF, p-value: 4.302e-15
```

Model višestruke linearne regresije procjenjuje IMDb ocjenu kao funkciju godine izlaska, trajanja filma, žanra i content ratinga. Dummy varijable predstavljaju razlike u ocjenama između pojedinih žanrova i content ratinga u odnosu na referentnu kategoriju.

Iz sažetka modela možemo iščitati da su neki koeficijenti statistički značajni ($p < 0.05$), što znači da imaju značajan utjecaj na IMDb ocjenu. Adjusted R^2 pokazuje koliki postotak varijance u ocjenama model objašnjava, prilagođeno za broj parametara.

6.3.3 Testovi regresijskih koeficijenata i adjusted R^2

```
adj_r2 <- summary(fit.multi)$adj.r.squared
f_stat <- summary(fit.multi)$fstatistic
f_pval <- pf(f_stat[1], f_stat[2], f_stat[3], lower.tail = FALSE)

cat("Adjusted R²:", round(adj_r2, 4), "\n")
```

```
## Adjusted R2: 0.1771
```

```
cat("F-statistika:", round(f_stat[1], 2), "\n")
```

```
## F-statistika: 7.57
```

```
cat(sprintf("p-vrijednost: %.4e\n\n", f_pval))
```

```
## p-vrijednost: 4.3025e-15
```

```
coef_summary <- summary(fit.multi)$coefficients
significant_coefs <- sum(coef_summary[, 4] < 0.05, na.rm = TRUE)
total_coefs <- nrow(coef_summary)

cat("Broj značajnih koeficijenata (p < 0.05):", significant_coefs, "od", total_coefs, "\n")
```

```
## Broj značajnih koeficijenata (p < 0.05): 7 od 16
```

F-test pokazuje da je model statistički značajan i pruža bolju predikciju od nul-modela.

6.3.4 Predikcija srednje vrijednosti

Koristimo procijenjeni model za predikciju IMDb ocjene za “prosječan” film.

```
new_data <- data.frame(
  Year.of.Release = median(oscars$Year.of.Release, na.rm = TRUE),
  Movie.Time = median(oscars$Movie.Time, na.rm = TRUE)
)

for (col in c(genre_cols, rating_cols)) {
  new_data[[col]] <- 0
}

pred_mean <- predict(fit.multi, newdata = new_data,
  interval = "confidence", level = 0.95)

cat("Predikcija IMDb ocjene za prosječan film:\n")
```

```
## Predikcija IMDb ocjene za prosječan film:
```

```
cat("Godina izlaska:", new_data$Year.of.Release, "\n")
```

```
## Godina izlaska: 1979
```

```
cat("Trajanje:", new_data$Movie.Time, "minuta\n")
```

```
## Trajanje: 123 minuta
```

```
cat("Referentni žanr i rating\n\n")
```

```
## Referentni žanr i rating
```

```
cat("Predviđena ocjena:", round(pred_mean[1], 3), "\n")
```

```
## Predviđena ocjena: 74.173
```

```
cat("95% interval pouzdanosti: [",  
    round(pred_mean[2], 3), ",", round(pred_mean[3], 3), "]\n")
```


```
## 95% interval pouzdanosti: [ 71.984 , 76.361 ]
```

Interval pouzdanosti od 95% znači da smo 95% uvjereni da će se prava srednja vrijednost IMDb ocjene za filmove s ovim karakteristikama nalaziti unutar navedenog intervala.

6.3.5 Analiza reziduala

Prije donošenja konačnih zaključaka o modelu, potrebno je provjeriti pretpostavke linearne regresije analizom reziduala.

```
par(mfrow = c(2, 2))  
  
plot(fit.multi$fitted.values, fit.multi$residuals,  
     main = "Fitted vs Residuals",  
     xlab = "Fitted vrijednosti (predviđene ocjene)",  
     ylab = "Reziduali",  
     pch = 19, col = rgb(0, 0, 1, 0.5))  
abline(h = 0, col = "red", lwd = 2, lty = 2)  
  
hist(rstandard(fit.multi), breaks = 25,  
     main = "Histogram standardiziranih reziduala",  
     xlab = "Standardizirani reziduali",  
     ylab = "Frekvencija",  
     col = "lightblue")  
  
qqnorm(rstandard(fit.multi),  
       main = "Q-Q dijagram standardiziranih reziduala",  
       xlab = "Teorijski kvantili",  
       ylab = "Standardizirani reziduali")  
qqline(rstandard(fit.multi), col = "red", lwd = 2)  
  
plot(fit.multi$fitted.values, sqrt(abs(rstandard(fit.multi))),  
     main = "Scale-Location",  
     xlab = "Fitted vrijednosti",  
     ylab = "√|Standardizirani reziduali|",  
     pch = 19, col = rgb(0, 0, 1, 0.5))
```



```
par(mfrow = c(1, 1))
```

Q-Q plot pokazuje da reziduali uglavnom prate dijagonalnu liniju, s blagim odstupanjima na krajevima, što sugerira da pretpostavka normalnosti nije značajno narušena.

6.4 Test normalnosti reziduala

Provjerimo sada normalnost reziduala Lillieforsovom inačicom Kolmogorov-Smirnovljevog testa na razini značajnosti od 5% uz sljedeće hipoteze:

H_0 : Reziduali su normalno distribuirani H_1 : Reziduali nisu normalno distribuirani.

```
nortest::lillie.test(rstandard(fit.multi))
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  rstandard(fit.multi)
## D = 0.035697, p-value = 0.1686
```

Testna statistika pokazuje p-vrijednost. Ako je p-vrijednost veća od 0.05, test nije statistički značajan te nemamo dovoljno dokaza za odbacivanje nul-hipoteze. Reziduali se mogu smatrati normalno distribuiranima.

6.5 Bootstrap analiza

Bootstrap se koristi radi **robusnosti procjena**. Omogućuje procjenu intervala pouzdanosti bez striktnih pretpostavki o distribuciji podataka, što je posebno korisno kada pretpostavke normalnosti mogu biti narušene.

```
set.seed(42)

formula_string <- paste("IMDB.Rating ~", paste(all_predictors, collapse = " + "))

bootstrap_lm <- function(data, indices) {
  d <- data[indices, ]
  fit <- lm(as.formula(formula_string), data = d)
  return(coef(fit))
}

boot_results <- boot::boot(data = oscars_model,
                          statistic = bootstrap_lm,
                          R = 1000)
```

6.5.1 Bootstrap intervali pouzdanosti

Bootstrap intervali pouzdanosti za sve koeficijente modela:

```
set.seed(42)

formula_string <- paste("IMDB.Rating ~", paste(all_predictors, collapse = " + "))

n_expected_coefs <- length(all_predictors) + 1

bootstrap_lm <- function(data, indices) {
  d <- data[indices, ]
  tryCatch({
    fit <- lm(as.formula(formula_string), data = d)
    coefs <- coef(fit)
    if (length(coefs) == n_expected_coefs) {
      return(coefs)
    } else {
      return(rep(NA, n_expected_coefs))
    }
  }, error = function(e) {
    return(rep(NA, n_expected_coefs))
  })
}

# Bootstrap s 1000 iteracija
boot_results <- boot::boot(data = oscars_model,
                          statistic = bootstrap_lm,
                          R = 1000)
```


Bootstrap standardne pogreške (Boot_SE) omogućuju usporedbu s klasičnim OLS standardnim pogreškama. Sličnost ovih vrijednosti potvrđuje robusnost procjena.

6.5.2 Vizualizacija Bootstrap distribucija


```
par(mfrow = c(2, 2))

# Bootstrap za Year.of.Release
if (ncol(boot_results$t) >= 2) {
  hist(boot_results$t[, 2], breaks = 30,
       main = "Bootstrap: Year.of.Release",
       xlab = "Koeficijent",
       col = "lightblue",
       border = "white")
  abline(v = coef(fit.multi)[2], col = "red", lwd = 2)
  abline(v = quantile(boot_results$t[, 2], c(0.025, 0.975), na.rm = TRUE),
        col = "darkred", lwd = 2, lty = 2)
}

# Bootstrap za Movie.Time
if (ncol(boot_results$t) >= 3) {
  hist(boot_results$t[, 3], breaks = 30,
       main = "Bootstrap: Movie.Time",
       xlab = "Koeficijent",
       col = "lightgreen",
       border = "white")
  abline(v = coef(fit.multi)[3], col = "red", lwd = 2)
  abline(v = quantile(boot_results$t[, 3], c(0.025, 0.975), na.rm = TRUE),
        col = "darkred", lwd = 2, lty = 2)
}

# Bootstrap za Intercept
hist(boot_results$t[, 1], breaks = 30,
     main = "Bootstrap: Intercept",
     xlab = "Koeficijent",
     col = "lightyellow",
     border = "white")
abline(v = coef(fit.multi)[1], col = "red", lwd = 2)
abline(v = quantile(boot_results$t[, 1], c(0.025, 0.975), na.rm = TRUE),
      col = "darkred", lwd = 2, lty = 2)

par(mfrow = c(1, 1))
```



Crvena linija označava procjenu koeficijenta iz originalnog modela, dok isprekidane linije označavaju 95% bootstrap interval pouzdanosti.

6.6 Zaključak

Model višestruke linearne regresije koristi godinu izlaska filma, trajanje filma, žanr i content rating za predikciju IMDb ocjene nominiranih filmova za Oscara.

Adjusted R^2 iznosi 0.1771, što znači da model objašnjava 17.71% varijance u IMDb ocjenama. F-test pokazuje da je model statistički značajan ($p < 0.001$), što znači da korištene značajke imaju prediktivnu moć.

7 od 16 koeficijenata su statistički značajni na razini značajnosti od 5%, što ukazuje na to da većina varijabli uključenih u model ima značajan doprinos predikciji ocjene.

Bootstrap analiza korištena je radi robusnosti procjena. Bootstrap intervali pouzdanosti potvrđuju stabilnost procjena koeficijenata i omogućuju zaključivanje bez striktnih pretpostavki o normalnosti podataka.

Iako model objašnjava značajan dio varijabilnosti, preostala neobjašnjena varijanca ukazuje na to da postoje i drugi faktori (kvaliteta režije, gluma, priča) koji utječu na ocjene, a nisu uključeni u ovaj model.

7 Analiza predviđanja pobjednika

U ovoj analizi istražujemo postoje li statistički značajne razlike između filmova koji su osvojili Oscara (“Winner”) i onih koji su bili samo nominirani (“Nominee”). Analizu provodimo na temelju dostupnih značajki: IMDb ocjene, žanra, godine izlaska i trajanja filma.


```
oscars <- read.csv("oscars_dataset.csv", sep = ";", na.strings = c("", "NA", "Unknown"), encoding = "UTF-8")
```

7.0.0.1 Priprema podataka Prije analize, uređujemo dataset: pretvaramo numeričke varijable u ispravan format, kreiramo binarnu varijablu za pobjedu te grupiramo rjeđe žanrove kako bismo osigurali stabilnost modela.

```
# Pretvorbe tipova, uređivanje dataseta
oscars <- oscars %>%
  mutate(
    IMDB.Rating = as.numeric(IMDB.Rating),
    Year.of.Release = as.numeric(Year.of.Release),
    Movie.Time = as.numeric(Movie.Time),
    # Kreiranje binarne varijable (1 = Winner, 0 = Nominee)
    IsWinner = ifelse(Award == "Winner", 1, 0),
    # Grupiranje žanrova radi stabilnosti modela
    Main.Genre = ifelse(Main.Genre %in% c("Drama", "Comedy", "Biography", "Adventure", "Action", "Crime", "Drama", "Comedy", "Biography", "Adventure", "Action", "Crime"),
                        Main.Genre, "Other"),
    Main.Genre = factor(Main.Genre),
    Award = factor(Award, levels = c("Nominee", "Winner"))
  ) %>%
  filter(complete.cases(IMDB.Rating, Main.Genre, Year.of.Release, Movie.Time, IsWinner))
```


Da bismo dobili uvid u razlike u ocjenama, vizualizirat ćemo distribucije ocjena za pobjednike i nominirane.

```
ggplot(oscars, aes(x = Award, y = IMDB.Rating, fill = Award)) +
  geom_boxplot() +
  labs(
    x = "Ishod",
    y = "IMDb ocjena",
    title = "Distribucija IMDb ocjena s obzirom na pobjedu"
  )
```



7.0.0.2 Box plot: Distribucija IMDb ocjena s obzirom na pobjedu

```
ggplot(oscars, aes(x = IMDB.Rating, fill = Award)) +
  geom_histogram(position = "identity", alpha = 0.6, bins = 20) +
  labs(
    x = "IMDb ocjena",
    y = "Frekvencija",
    title = "Histogram ocjena: Pobjednici vs Nominirani"
  )
```




7.0.0.3 Histogram: Pobjednici vs Nominirani

Također nas zanima imaju li određeni žanrovi veći udio pobjednika.

```
genre_prop <- oscars %>%
  group_by(Main.Genre) %>%
  summarise(
    Total = n(),
    Winners = sum(IsWinner),
    PropWinner = Winners / Total
  )

ggplot(genre_prop, aes(x = Main.Genre, y = PropWinner)) +
  geom_col(fill = "steelblue") +
  labs(
    x = "Žanr",
    y = "Udio pobjednika",
    title = "Udio pobjednika po žanru"
  )
```



7.0.0.4 Stupčasti dijagram udjela pobjednika po žanru

Kako bismo statistički provjerili postoji li razlika u IMDb ocjenama između pobjednika i ostalih, provedemo t-test.

```
t.test(IMDB.Rating ~ Award, data = oscars)
```

7.0.0.5 t-test (IMDb ocjena: Pobjednici vs Ostali)

```
##
```

```
## Welch Two Sample t-test
##
## data: IMDB.Rating by Award
## t = -3.573, df = 120.07, p-value = 0.0005091
## alternative hypothesis: true difference in means between group Nominee and group Winner is not equal
## 95 percent confidence interval:
## -0.3895394 -0.1117541
## sample estimates:
## mean in group Nominee mean in group Winner
## 7.529140 7.779787
```

Rezultati t-testa pokazuju statistički značajnu razliku u srednjim vrijednostima ocjena ($p = 0.0005091 < 0.05$). To znači da pobjednici u prosjeku imaju više ocjene od nominiranih.

Sada ćemo izgraditi prediktivni model koristeći logističku regresiju kako bismo procijenili vjerojatnost pobjede na temelju više značajki istovremeno.

```
model <- glm(
  IsWinner ~ IMDB.Rating + Main.Genre + Year.of.Release + Movie.Time,
  data = oscars,
  family = binomial(link = "logit")
)

summary(model)
```

7.0.0.6 Logistička regresija

```
##
## Call:
## glm(formula = IsWinner ~ IMDB.Rating + Main.Genre + Year.of.Release +
##      Movie.Time, family = binomial(link = "logit"), data = oscars)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    1.413908   8.774323   0.161  0.87198
## IMDB.Rating     0.734343   0.250839   2.928  0.00342 **
## Main.GenreAdventure  1.040600   0.746957   1.393  0.16358
## Main.GenreBiography  1.162477   0.680924   1.707  0.08778 .
## Main.GenreComedy     1.085377   0.708697   1.532  0.12564
## Main.GenreCrime      1.096404   0.739827   1.482  0.13835
## Main.GenreDrama      1.336590   0.654786   2.041  0.04122 *
## Main.GenreOther     -13.233791 595.590513  -0.022  0.98227
## Year.of.Release    -0.006177   0.004538  -1.361  0.17345
## Movie.Time         0.018617   0.004590   4.056 4.99e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 464.92  on 561  degrees of freedom
```

```
## AIC: 484.92
##
## Number of Fisher Scoring iterations: 15
```

Za evaluaciju kvalitete modela, izračunat ćemo točnost (Accuracy), nacrtati ROC krivulju, izračunati površinu ispod krivulje (AUC) te McFaddenov pseudo- R^2 .

```
predicted_probs <- predict(model, type = "response")
predicted_class <- ifelse(predicted_probs > 0.5, 1, 0)
accuracy <- mean(predicted_class == oscar$IsWinner)
print(paste("Accuracy:", round(accuracy, 4)))
```

7.0.0.7 Evaluacija modela: Accuracy

```
## [1] "Accuracy: 0.8424"
```


```
par(family = "sans")
roc_obj <- roc(oscar$IsWinner, predicted_probs)
```

7.0.0.8 Evaluacija modela: ROC krivulja i AUC

```
## Setting levels: control = 0, case = 1
```

```
## Setting direction: controls < cases
```

```
plot(roc_obj, main = "ROC Krivulja", col = "blue")
```



```
auc_value <- auc(roc_obj)
print(paste("AUC:", round(auc_value, 4)))
```

```
## [1] "AUC: 0.6991"
```

AUC mjeri sposobnost modela da razlikuje klase. Vrijednost 0.5 predstavlja nasumično pogađanje, a 1.0 predstavlja savršen model. Dobiveni AUC od 0.6991 ukazuje na umjerenu sposobnost modela da razlikuje pobjednike od nominiranih.

```
null_model <- glm(IsWinner ~ 1, data = oscars, family = binomial)
pseudo_r2 <- 1 - (logLik(model) / logLik(null_model))
print(paste("McFadden's Pseudo-R^2:", round(pseudo_r2, 4)))
```

7.0.0.9 Evaluacija modela: McFaddenov Pseudo R^2

```
## [1] "McFadden's Pseudo-R^2: 0.0898"
```

Ukazuje na to koliko model bolje objašnjava podatke u usporedbi s nul-modelom. Niska vrijednost (0.0898) sugerira da, iako su varijable statistički značajne, one objašnjavaju samo mali dio varijabilnosti u tome tko će osvojiti Oscara.