

Oscarovci

Tim #1

2025-11-06

Contents

1	Opis skupa podataka	2
2	Analiza žanrova kod pobjednika (Matija)	4
2.1	Opis problema	4
2.2	Single-label analiza	4
2.3	Multi-label analiza	8
2.4	Statističko testiranje	11
2.5	Zaključak	15
3	Analiza ocjena kroz godine (Roko)	16
4	Možemo li naslutiti ocjenu na IMDb pomoću nekih parametara? (Roko)	19
5	Istraživačko pitanje: Ocjene filmova i njihova starost (Damjan)	22
6	Analiza predviđanja pobjednika (Ivan)	31
6.1	Opis problema	31
6.2	Analiza podataka	31
6.3	Logistička regresija	36
6.4	Test omjera vjerodostojnosti (LR test)	38
6.5	Odds Ratios - Tumačenje koeficijenata	39
6.6	Predikcija i Confusion Matrix	41
6.7	Zaključak	44

1 Opis skupa podataka

Skup podataka koji analiziramo u projektu sadrži 571 odgovor/redak.

```
#Prikaz varijabli u skupu podataka i njihovog podatkovnog tipa
```

```
data = read_csv2("oscars_dataset.csv")
```

```
## i Using '','' as decimal and '.'' as grouping mark. Use `read_delim()` for more control.
```

```
## Rows: 571 Columns: 20
```

```
## -- Column specification -----
```

```
## Delimiter: ";"
```

```
## chr (11): Film, Oscar Year, Film Studio/Producer(s), Award, Movie Genre, Ma...
```

```
## dbl (3): Unnamed: 0, Year of Release, Movie Time
```

```
## num (5): IMDB Rating, Tomatometer Rating, Tomatometer Count, Audience Rati...
```

```
## date (1): Original Release Date
```

```
##
```

```
## i Use `spec()` to retrieve the full column specification for this data.
```

```
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
glimpse(data)
```

```
## Rows: 571
```

```
## Columns: 20
```

```
## $ `Unnamed: 0` <dbl> 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13~
```

```
## $ Film <chr> "Wings", "7th Heaven", "The Racket", "The Br~
```

```
## $ `Oscar Year` <chr> "1927/28", "1927/28", "1927/28", "1928/29", ~
```

```
## $ `Film Studio/Producer(s)` <chr> "Famous Players-Lasky", "Fox", "The Caddo Co~
```

```
## $ Award <chr> "Winner", "Nominee", "Nominee", "Winner", "N~
```

```
## $ `Year of Release` <dbl> 1927, 1927, 1928, 1929, 1929, 1929, 1928, 19~
```

```
## $ `Movie Time` <dbl> 144, 110, 84, 100, 91, 130, 95, 113, 152, 87~
```

```
## $ `Movie Genre` <chr> "Drama,Romance,War", "Drama,Romance", "Crime~
```

```
## $ `Main Genre` <chr> "Drama", "Drama", "Crime", "Drama", "Action"~
```

```
## $ Subgenre <chr> "Romance", "Romance", "Drama", "Musical", "C~
```

```
## $ `IMDB Rating` <dbl> 75, 77, 67, 57, 58, 57, 56, 74, 81, 71, 62, ~
```

```
## $ `IMDB Votes` <chr> "12,221", "3,439", "1,257", "6,890", "765", ~
```

```
## $ `Content Rating` <chr> "PG-13", NA, NA, "NR", NA, NA, "NR", NA, NA, ~
```

```
## $ Directors <chr> "William Wellman", NA, NA, "Harry Beaumont", ~
```

```
## $ `Original Release Date` <date> 1927-08-12, NA, NA, 1929-02-01, NA, NA, 192~
```

```
## $ `Production Company` <chr> "Unknown", NA, NA, "MGM Home Entertainment", ~
```

```
## $ `Tomatometer Rating` <dbl> 930, NA, NA, 330, NA, NA, 560, NA, NA, 750, ~
```

```
## $ `Tomatometer Count` <dbl> 460, NA, NA, 240, NA, NA, 90, NA, NA, 80, NA~
```

```
## $ `Audience Rating` <dbl> 780, NA, NA, 210, NA, NA, 380, NA, NA, 690, ~
```

```
## $ `Audience Count` <dbl> 35300, NA, NA, 18130, NA, NA, 3560, NA, NA, ~
```

```
var_types <- sapply(data, class)
```

```
cat(paste(names(var_types), ": ", var_types, sep = " ", collapse = "\n"))
```

```
## Unnamed: 0: numeric
```

```
## Film: character
```

Oscar Year: character
Film Studio/Producer(s): character
Award: character
Year of Release: numeric
Movie Time: numeric
Movie Genre: character
Main Genre: character
Subgenre: character
IMDB Rating: numeric
IMDB Votes: character
Content Rating: character
Directors: character
Original Release Date: Date
Production Company: character
Tomatometer Rating: numeric
Tomatometer Count: numeric
Audience Rating: numeric
Audience Count: numeric

2 Analiza žanrova kod pobjednika (Matija)

2.1 Opis problema

Cilj ove analize je ispitati postoji li povezanost između filmskih žanrova i vjerojatnosti osvajanja Oscara. S obzirom na to da je teško svesti film na samo jedan žanr, analizu provodimo na dva načina:

1. *Single-label pristup* – svakom filmu pridružujemo samo jedan glavni žanr (Main Genre).
2. *Multi-label pristup* – film može pripadati više žanrova (Movie Genre), a svaki žanr ćemo zasebno brojati.

Na taj način možemo usporediti kako različiti modeli označavanja žanrova utječu na rezultate.

2.2 Single-label analiza

2.2.1 Grupiranje žanrova i priprema podataka za analizu:

Prvo nego što krenemo raditi bilo kakve statističke testove, moramo se upoznati s podacima. U datasetu se nalazi više stupaca koje sadrže kako su labelirani filmovi po z

```
data <- data %>%
  mutate(`Main Genre` = as.character(`Main Genre`))

winners <- data %>% filter(Award == "Winner")
nominees <- data %>% filter(Award %in% c("Nominee", "Winner"))

winner_counts <- winners %>%
  count(`Main Genre`, name = "Winners")

nominee_counts <- nominees %>%
  count(`Main Genre`, name = "Nominations")

genre_table <- nominee_counts %>%
  left_join(winner_counts, by = "Main Genre") %>%
  mutate(
    Winners = replace_na(Winners, 0),
    NotWinner = Nominations - Winners
  ) %>%
  rename(Genre = `Main Genre`)
```

Vizualizacija pobjeda i nominacija po žanru:


```
genre_plot_data <- genre_table %>%
  arrange(desc(Winners)) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )

ggplot(genre_plot_data,
```

```

    aes(x = Count,
        y = reorder(Genre, Count),
        fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  geom_text(aes(label = Count),
            position = position_stack(vjust = 0.5),
            size = 3) +
  scale_fill_manual(values = c(
    "Winners" = "#1f78b4",
    "NotWinner" = "#a6cee3"
  )) +
  theme_minimal(base_size = 15) +
  labs(
    title = "Oscari po žanru: Pobjede i nominacije",
    x = "Broj filmova",
    y = "Žanr",
    fill = ""
  )
)

```



Zbog velike disproporcije između broja pobjeda i nominacija, koristimo i postotne prikaze te logaritamsku skalu kako bismo mogli bolje vizualizirati podatke.


2.2.2 Postotni prikaz pobjeda vs nominacija po žanru:

```

ggplot(genre_plot_data, aes(x = reorder(Genre, -Count), y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "fill", color = "black") +
  scale_y_continuous(labels = scales::percent_format()) +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6c3e3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Postotak pobjeda vs nominacija po žanru",


```

```
x = "Žanr", y = "Postotak", fill = "") +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



2.2.3 Logaritamska skala za broj pobjeda vs nominacija po žanru:

```
ggplot(genre_plot_data, aes(x = reorder(Genre, Count), y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  scale_y_log10() +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Oscari po žanru (log skala)",
       x = "Žanr", y = "Broj filmova (log10)", fill = "") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




2.2.4 Stopa uspješnosti po žanru:

Možemo također izračunati stopu uspješnosti (postotak pobjeda u odnosu na broj nominacija) za svaki žanr kako bismo dodatno ilustrirali razlike među žanrovima.

```
genre_table <- genre_table %>%
  mutate(WinRate = (Winners / Nominations) * 100)

ggplot(genre_table, aes(x = reorder(Genre, WinRate), y = WinRate)) +
  geom_col(fill = "#1f78b4", width = 0.7) +
  geom_text(
    aes(label = sprintf("%.1f%%", WinRate)),
    hjust = -0.1,
    size = 4
  ) +
  coord_flip() +
  scale_y_continuous(limits = c(0, max(genre_table$WinRate) * 1.15)) +
  labs(
    title = "Stopa pobjeda po žanru",
    x = "Žanr",
    y = "Postotak pobjede"
  ) +
  theme_minimal(base_size = 14) +
  theme(
    plot.title = element_text(face = "bold", size = 16),
    axis.text.y = element_text(size = 12),
    axis.text.x = element_text(size = 11)
  )
```



2.2.5 Kontingencijska tablica nominiranih i pobjednika po žanrovima:

```
kontingencijska <- genre_table[, c("Winners", "NotWinner")]
row.names(kontingencijska) <- genre_table$Genre
kontingencijska
```

```
## # A tibble: 14 x 2
##   Winners NotWinner
## *   <int>     <int>
## 1      3        36
## 2      9        36
## 3      0         3
## 4     18        83
## 5     13        95
## 6      9        39
## 7     42       173
## 8      0         1
## 9      0         2
## 10     0         3
## 11     0         1
## 12     0         2
## 13     0         1
## 14     0         2
```

2.3 Multi-label analiza

2.3.1 Priprema podataka

Priprema podataka za multi-label analizu žanrova:


```
data <- data %>%
  mutate(`Movie Genre` = as.character(`Movie Genre`))
```

Mutiramo podatke kako bismo razdvojili višestruke žanrove u zasebne retke.

```
data_long <- data %>%
  separate_rows(`Movie Genre`, sep = ",") %>%
  mutate(`Movie Genre` = trimws(`Movie Genre`))
```

Izračun broja pobjeda i ne-pobjeda po žanru:

```
genre_counts <- data_long %>%
  mutate(
    Outcome = ifelse(Award == "Winner", "Winner", "NotWinner")
  ) %>%
  count(`Movie Genre`, Outcome) %>%
  pivot_wider(
    names_from = Outcome,
    values_from = n,
    values_fill = 0
  ) %>%
  mutate(
    Total = Winner + NotWinner,
    GenreGroup = ifelse(Total < 5, "Other", `Movie Genre`),
    SuccessRate = Winner / Total
  )
```

Grupiranje rijetkih žanrova u kategoriju “Ostali” i izračun ukupnih vrijednosti po grupama žanrova:

```
genre_table_ml <- genre_counts %>%
  group_by(GenreGroup) %>%
  summarise(
    Winners = sum(Winner),
    NotWinner = sum(NotWinner),
    Total = sum(Total),
    SuccessRate = sum(Winner)/sum(Total),
    .groups = "drop"
  )
```


2.3.2 Vizualizacija rezultata multi-label analize žanrova:

```
genre_melt <- genre_table_ml %>%
  select(GenreGroup, Winners, NotWinner) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )


# Bar plot (broj pojavljivanja)
ggplot(genre_melt, aes(x = Count, y = reorder(GenreGroup, Count), fill = Outcome)) +
```

```
geom_bar(stat = "identity", color = "black") +
geom_text(aes(label = Count), position = position_stack(vjust = 0.5), size = 3) +
scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
theme_minimal(base_size = 14) +
labs(title = "Multi-label analiza žanrova (grupirani rijetki žanrovi)",
x = "Broj pojavljivanja",
y = "Žanr",
fill = "")
```

Multi-label analiza žanrova (grupirani rijetki žanrovi)



```
# Bar plot (postotak pobjeda)
ggplot(genre_table_ml, aes(x = SuccessRate, y = reorder(GenreGroup, SuccessRate))) +
geom_col(fill = "#1f78b4") +
geom_text(aes(label = scales::percent(SuccessRate, accuracy = 0.1)), hjust = -0.1, size = 4) +
scale_x_continuous(labels = scales::percent_format(), limits = c(0, NA)) +
theme_minimal(base_size = 14) +
labs(title = "Postotak uspješnosti po žanru (multi-label)",
x = "Udio pobjeda",
y = "Žanr")
```



2.4 Statističko testiranje

2.4.1 Hipoteze:

- Nulta hipoteza (H_0): Ne postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.
- Alternativna hipoteza (H_1): Postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.

2.4.2 Grupiranje žanrova i priprema podataka za analizu:

Kako bi ispitali nezavisnost dviju kategorijske varijable, odnosno kako bi ispitali jesu li žanrovi i pobjede zavisi, koristit ćemo hi-kvadrat test. Neka je kontingencijska tablica dimenzija $r \times c$ sa:

- O_{ij} = promatrana frekvencija u ćeliji (i, j)
- E_{ij} = očekivana frekvencija ako su varijable neovisne

Očekivane frekvencije računamo

$$E_{ij} = \frac{(\text{ukupno u redu } i) \cdot (\text{ukupno u stupcu } j)}{\text{ukupan broj promatranja}}$$

Hi-kvadrat statistika se provodi formulom:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- Mala vrijednost $\chi^2 \rightarrow$ promatrane frekvencije blizu očekivanih (neovisnost)

- Velika vrijednost $\chi^2 \rightarrow$ značajna odstupanja (ovisnost)

Stupnjevi slobode računamo:

$$df = (r - 1)(c - 1)$$

Standardizirani reziduali za procjenu odstupanja pojedine ćelije, odnosno u ovome slučaju žanra:

$$\text{StdRes}_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

- Pozitivni rezidual $\rightarrow$ više promatranih nego očekivanih
- Negativni rezidual $\rightarrow$ manje promatranih nego očekivanih
- Vrijednosti veće od ± 2 obično se smatraju **statistički značajnim!**

Važno je reći da hi-kvadrat test ima važan uvjet: očekivane frekvencije u svakoj ćeliji kontingencijske tablice trebaju biti veće od 5. Za žanrove s jako malim brojem filmova (npr. 1–2 pojave), očekivane frekvencije za te vrlo male. Kako bi statistički test bio valjan, grupirat ćemo manje zastupljene žanrove u kategoriju “Ostali” kako bismo osigurali da sve ćelije imaju dovoljne očekivane frekvencije.

2.4.3 Prvo ćemo analizirati prvi pristup: Single-label analiza

```
common_genres <- c("Action", "Adventure", "Biography", "Comedy", "Crime", "Drama")
data$GenreGroup <- ifelse(data$`Main Genre` %in% common_genres,
                           data$`Main Genre`,
                           "Other")

# broj pobjeda po grupama
winner_counts <- as.data.frame(table(subset(data, Award=="Winner")$GenreGroup))
colnames(winner_counts) <- c("GenreGroup", "Winners")

# broj nominacija po grupama
nominee_counts <- as.data.frame(table(subset(data, Award %in% c("Winner", "Nominee"))$GenreGroup))
colnames(nominee_counts) <- c("GenreGroup", "Nominations")

df <- merge(nominee_counts, winner_counts, by="GenreGroup", all.x=TRUE)
df$Winners[is.na(df$Winners)] <- 0

# Dodaj kolonu za ne-pobjede
df$NotWinner <- df$Nominations - df$Winners

kontigencijska_single <- as.data.frame(df[, c("Winners", "NotWinner")])
row.names(kontigencijska_single) <- df$GenreGroup

#Prikaz kontigencijske tablice
kontigencijska_single
```

```
##           Winners NotWinner
## Action           3         36
## Adventure        9         36
```

## Biography	18	83
## Comedy	13	95
## Crime	9	39
## Drama	42	173
## Other	0	15

2.4.4 Hi-kvadrat test:

Sada radimo Hi-kvadrat test kako bismo vidjeli postoje li značajne razlike u učestalosti pobjeda među različitim žanrovima. Za razinu značajnosti, uzet ćemo $\alpha = 0,05$.

```
# Chi-squared test
chisq_single <- chisq.test(kontigencijska_single)
chisq_single
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_single
## X-squared = 8.8789, df = 6, p-value = 0.1805
```

S obzirom na to da je $p - value > \alpha$, odnosno $0.1805 > 0.05$, prihvaćamo H_0 .

Standardizirani reziduali koji pokazuju kako žanrovi odstupaju:

```
chisq_single$stdres
```

```
##           Winners NotWinner
## Action    -1.5300621  1.5300621
## Adventure  0.6667449 -0.6667449
## Biography  0.4060704 -0.4060704
## Comedy    -1.3771971  1.3771971
## Crime      0.4465715 -0.4465715
## Drama      1.5385882 -1.5385882
## Other     -1.7423324  1.7423324
```

2.4.5 Zatim analiziramo Multi-label analizu:

```
kontigencijska_multi <- genre_table_ml[, c("Winners", "NotWinner")]
row.names(kontigencijska_multi) <- genre_table_ml$GenreGroup
kontigencijska_multi
```

```
## # A tibble: 20 x 2
##   Winners NotWinner
## *   <int>     <int>
## 1      3         36
## 2     11         56
## 3     20         89
## 4     16        109
## 5     13         59
```

```
## 6      88      414
## 7       6       21
## 8       1       23
## 9       2       11
## 10      13       54
## 11       1       25
## 12       8       22
## 13       2       26
## 14       0        7
## 15      25      149
## 16       0       10
## 17       3        7
## 18       8       32
## 19      13       29
## 20       3       12
```

2.4.6 Hi-kvadrat test

```
chisq_multi <- chisq.test(kontigencijska_multi)
chisq_multi
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_multi
## X-squared = 27.047, df = 19, p-value = 0.1036
```

```
chisq_multi$stdres
```

```
##           Winners  NotWinner
## Action    -1.50765823  1.50765823
## Adventure -0.02714508  0.02714508
## Biography  0.52937302 -0.52937302
## Comedy    -1.17770142  1.17770142
## Crime      0.35563977 -0.35563977
## Drama      0.74281443 -0.74281443
## Family     0.80259845 -0.80259845
## Fantasy    -1.64522050  1.64522050
## Film-Noir -0.11246503  0.11246503
## History    0.64652494 -0.64652494
## Music      -1.75801693  1.75801693
## Musical    1.50914353 -1.50914353
## Mystery    -1.35147028  1.35147028
## Other      -1.18063854  1.18063854
## Romance    -0.82235271  0.82235271
## Sci-Fi     -1.41262596  1.41262596
## Sport      1.14985359 -1.14985359
## Thriller   0.59774895 -0.59774895
## War        2.55219613 -2.55219613
## Western    0.36279002 -0.36279002
```

Ovdje također vidimo da je $p - value > \alpha$, odnosno $0.1036 > 0.05$ te prihvaćamo H_0 .

2.5 Zaključak

Na temelju dobivenih rezultata Hi-kvadrat testa kod oba pristupa, prihvaćamo H_0 i možemo zaključiti da ne postoje značajne razlike u učestalosti pobjeda među različitim žanrovima filmova nominiranih za Oscara. Standardizirani reziduali ukazuju na to koji žanrovi značajno odstupaju od očekivanih vrijednosti, što može biti korisno za daljnje istraživanje i razumijevanje trendova u dodjeli nagrada, kao i pitanje zašto su neki žanrovi češće nominirani od ostalih.

3 Analiza ocjena kroz godine (Roko)

```
library(ggplot2)

oscars <- read.csv("oscars_dataset.csv", sep = ";")
oscars$win <- ifelse(oscars$Award == "Winner", 1, 0)
oscars$votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes))
summary(oscars$votes)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##       18   9660   58996  208480  259429  2452594

model <- glm(
  win ~ votes,
  data = oscars,
  family = binomial
)

summary(model)

##
## Call:
## glm(formula = win ~ votes, family = binomial, data = oscars)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.915e+00  1.396e-01 -13.721  < 2e-16 ***
## votes       1.155e-06  2.760e-07   4.186  2.84e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 493.96  on 569  degrees of freedom
## AIC: 497.96
##
## Number of Fisher Scoring iterations: 4

# za inkrementalan glas publike log odds za dobivanje nagrade
# ce biti veci za 1.155e-06

# za inkrementalnig 100 tis glasova
oscars$votes100k <- oscars$votes / 100000

model100k <- glm(win ~ votes100k, family = binomial, data = oscars)
summary(model100k)


##
## Call:
## glm(formula = win ~ votes100k, family = binomial, data = oscars)
```



```
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.9151      0.1396 -13.721  < 2e-16 ***
## votes100k     0.1155      0.0276   4.186 2.84e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 493.96  on 569  degrees of freedom
## AIC: 497.96
##
## Number of Fisher Scoring iterations: 4

# z je 4.186, dovoljno velika za odbacivanje hipoteze
# vjerojatnost da će film osvojiti Oscar raste s većim brojem glasova

# vizualizacija
newframe <- data.frame(
  votes100k = seq(
    min(oscars$votes100k),
    max(oscars$votes100k),
    length.out = 100
  )
)
newframe$prob <- predict(model100k, newframe, type = "response") # vjerojatnosti
ggplot(newframe, aes(x = votes100k, y = prob)) +
  geom_line() +
  labs(x = "IMDb votes (log scale)", y = "Predicted probability of winning",
       title = "Audience votes and Oscar-winning probability")
)
```



4 Možemo li naslutiti ocjenu na IMDb pomoću nekih parametara? (Roko)

```
library(ggplot2)
library(dplyr)

oscars <- read.csv("oscars_dataset.csv", sep=";")
oscars$rating <- as.numeric(oscars$IMDB.Rating) #IMDb rating
oscars$votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes)) #broj glasova na IMDb
oscars$runtime <- as.numeric(oscars$Movie.Time) # trajanje filma
oscars$year <- as.numeric(oscars$Year.of.Release) # godina izlaska filma
oscars$genre <- oscars$Main.Genre # žanr filma

oscars <- oscars %>%
  select(rating, votes, runtime, year, genre) %>%
  na.omit()


summary(oscars)
```

```
##      rating      votes      runtime      year
## Min.   :5.60   Min.    :   18   Min.    : 66.0   Min.    :1927
## 1st Qu.:7.30   1st Qu.:  9660   1st Qu.:107.0   1st Qu.:1944
## Median :7.60   Median : 58996   Median :121.0   Median :1972
## Mean   :7.57   Mean    :208480   Mean    :124.9   Mean    :1973
## 3rd Qu.:7.90   3rd Qu.:259429   3rd Qu.:136.5   3rd Qu.:2001
## Max.   :9.30   Max.    :2452594   Max.    :238.0   Max.    :2021
##      genre
## Length:571
## Class :character
## Mode  :character
##
##
##
```

#analiza parametara

#1. Možemo li sa brojem glasova na IMDb-u predvidjeti ocjenu?
H0: ne možemo, H1: možemo

```
ggplot(oscars, aes(x = votes, y = rating)) +
  geom_point(alpha = 0.4) +
  scale_x_log10() +
  labs(x = "Broj glasova na IMDb-u (log)", y = "Ocjena filma na IMDb-u")
```



Spearmanov test korelacije

```
cor.test(
  oscars$rating,
  oscars$votes,
  method = "spearman"
)
```


```
##
## Spearman's rank correlation rho
##
## data: oscars$rating and oscars$votes
## S = 10060771, p-value < 2.2e-16
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##      rho
## 0.6757533
```

p value je izrazito mali, odbacujemo hipotezu H0 (glasovi i ocjena nisu korelirane)

#2. Možemo li s obzirom na žanr predvidjeti kako je ocijenjen film?

H0: ne, H1: da

```
ggplot(oscars, aes(x = genre, y = rating)) +
  geom_boxplot() +
  coord_flip()
```



```
# linearni model kada uzmemo logaritam broja glasova
m1 <- lm(rating ~ log10(votes), data = oscars)
summary(m1)
```

```
##
## Call:
## lm(formula = rating ~ log10(votes), data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.4959 -0.2649  0.0303  0.2821  1.3492
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.49427    0.09135   60.14  <2e-16 ***
## log10(votes)  0.44334    0.01917   23.12  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4022 on 569 degrees of freedom
## Multiple R-squared:  0.4844, Adjusted R-squared:  0.4835
## F-statistic: 534.6 on 1 and 569 DF, p-value: < 2.2e-16
```

```
m2 <- lm(
  rating ~ log10(votes) + runtime + year + genre,
  data = oscars
)

summary(m2)
```

```
##
```

```
## Call:
## lm(formula = rating ~ log10(votes) + runtime + year + genre,
##     data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.74777 -0.18846  0.01839  0.21712  1.61036
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  22.4099872   1.5024169   14.916 < 2e-16 ***
## log10(votes)   0.6513740   0.0281238   23.161 < 2e-16 ***
## runtime        0.0011657   0.0006378    1.828  0.06815 .
## year         -0.0091827   0.0008064  -11.387 < 2e-16 ***
## genreAdventure  0.0076345   0.0782912    0.098  0.92235
## genreAnimation  0.2070180   0.2148561    0.964  0.33571
## genreBiography  0.0988861   0.0672692    1.470  0.14213
## genreComedy     0.0439202   0.0676069    0.650  0.51619
## genreCrime      0.1715388   0.0769889    2.228  0.02627 *
## genreDrama      0.1345456   0.0623389    2.158  0.03133 *
## genreFamily     -0.1829209   0.3596893   -0.509  0.61127
## genreFilm-Noir -0.2449906   0.2586819   -0.947  0.34401
## genreHorror      0.0380331   0.2127347    0.179  0.85817
## genreMusic      -0.8471014   0.3617841   -2.341  0.01956 *
## genreMusical    -0.4869664   0.2596788   -1.875  0.06128 .
## genreRomance    -0.3484781   0.3609246   -0.966  0.33471
## genreWestern    -0.7292415   0.2583592   -2.823  0.00493 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3546 on 554 degrees of freedom
## Multiple R-squared:  0.6099, Adjusted R-squared:  0.5986
## F-statistic: 54.14 on 16 and 554 DF, p-value: < 2.2e-16
```

5 Istraživačko pitanje: Ocjene filmova i njihova starost (Damjan)

```
oscars <- read.csv2("oscars_dataset.csv")
# glimpse(oscars)
```

5.0.0.1 U ovom dijelu analiziramo kako se ocjene filmova mijenjaju s obzirom na godinu izlaska. Promatramo zasbenu ocjene publike (IMDb) i ocjene kritičara (Rotten Tomatoes).

5.0.0.2 U ovoj analizi istražujemo kako su filmovi nominirani za Oscara za najbolji film oci-
jenjeni s obzirom na godinu izlaska.

```
oscars <- oscars %>%
  mutate(
```

```

IMDB.Rating = as.numeric(IMDB.Rating),
IMDB.Votes = as.numeric(gsub(",", "", IMDB.Votes)),
Tomatometer.Rating = as.numeric(Tomatometer.Rating),
Audience.Rating = as.numeric(Audience.Rating),
Award = factor(Award, levels = c("Nominee", "Winner"))
)

```


5.0.0.3 Pretvorbe tipova, uređivanje dataseta Da bismo dobili uvid u to postoji li promjena u prosječnim ocjenama filmova kroz vrijeme, usporedit ćemo IMDb ocjene starijih i novijih filmova.

```

oscars <- oscars %>%
  mutate(
    Period = ifelse(Year.of.Release < 1990, "Stariji", "Noviji")
  )

ggplot(oscars, aes(x = Period, y = IMDB.Rating)) +
  geom_boxplot() +
  labs(
    x = "Razdoblje",
    y = "IMDb ocjena",
    title = "IMDb ocjene starijih i novijih filmova"
  )

```



5.0.0.4 Side-to-side usporedba ocjena starijih i novijih filmova

Budući da želimo statistički provjeriti postoji li značajna razlika u IMDb ocjenama između starijih i novijih filmova, primijenit ćemo neparametarski Wilcoxonov rank-sum test.

```
wilcox.test(
  IMDB.Rating ~ Period,
  data = oscars
)
```

5.0.0.5 Wilcoxonov rank-sum test

```
##
## Wilcoxon rank sum test with continuity correction
##
## data: IMDB.Rating by Period
## W = 47342, p-value = 6.488e-08
## alternative hypothesis: true location shift is not equal to 0
```

Rezultati Wilcoxonovog testa pokazuju da je p-vrijednost vrlo mala ($p < 0,001$), što znači da postoji statistički značajna razlika u IMDb ocjenama između starijih i novijih filmova, pri čemu noviji filmovi imaju prosječno više ocjene.


Pogledajmo sada kako se IMDb ocjene mijenjaju kroz godine izlaska filmova.

```
ggplot(oscars, aes(x = Year.of.Release, y = IMDB.Rating)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "IMDb ocjena",
    title = "Odnos godine izlaska i IMDb ocjene"
  )
```

5.0.0.6 Graf: IMDb ocjena filmova kroz godine

```
## `geom_smooth()` using formula = 'y ~ x'
```


Odnos godine izlaska i IMDb ocjene



S grafa je vidljivo da regresijski pravac ima blagi pozitivan nagib, što upućuje na to da IMDb ocjene filmova kroz vrijeme pokazuju tendenciju blagog porasta. Međutim, raspršenost podataka oko regresijske linije je velika, pa je vidljivo da je taj trend slab i da godina izlaska objašnjava samo mali dio varijabilnosti IMDb ocjena.

Kako bi provjerili je li ovaj porast ocjena s vremenom statistički značajan, izračunat ćemo Pearsonov koeficijent korelacije između godine izlaska i IMDb ocjena.

```
cor.test(
  oscars$Year.of.Release,
  oscars$IMDB.Rating,
  use = "complete.obs"
)
```

5.0.0.7 Određivanje Pearsonovog koeficijenta korelacije (jačine i smjera linearne povezanosti)

```
##
## Pearson's product-moment correlation
##
## data:  oscars$Year.of.Release and oscars$IMDB.Rating
## t = 8.3363, df = 569, p-value = 5.783e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.2547525 0.4011050
## sample estimates:
##      cor
## 0.3299097
```

Pearsonov koeficijent korelacije između godine izlaska i IMDb ocjena iznosi 0,33, što indicira umjerenu pozitivnu linearnu povezanost. Budući da je p-vrijednost gotovo zanemariva, veza je statistički značajna. Međutim, iako trend pokazuje da noviji filmovi imaju blago više ocjene, godina izlaska objašnjava samo mali dio

varijabilnosti ocjena.

Da bismo bolje razumjeli kako godina izlaska utječe na IMDb ocjene i mogli predviđati ocjene filmova, koristit ćemo linearnu regresiju s ocjenom kao zavisnom varijablom i godinom izlaska kao neovisnom.

```
model <- lm(
  IMDB.Rating ~ Year.of.Release,
  data = oscars
)

summary(model)
```

5.0.0.8 Linearna regresija - IMDb

```
##
## Call:
## lm(formula = IMDB.Rating ~ Year.of.Release, data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.68474 -0.35157  0.00511  0.36096  1.63815
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -4.8580725   1.4910503   -3.258  0.00119 **
## Year.of.Release  0.0062981  0.0007555    8.336 5.78e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5288 on 569 degrees of freedom
## Multiple R-squared:  0.1088, Adjusted R-squared:  0.1073
## F-statistic: 69.49 on 1 and 569 DF, p-value: 5.783e-16
```


Linearni model pokazuje blagu pozitivnu povezanost između godine izlaska i IMDb ocjena. Svaka dodatna godina povećava očekivanu ocjenu za približno 0,006 rating bodova. Model je statistički značajan ($p < 0,001$), no godina izlaska objašnjava samo oko 1% varijabilnosti ocjena, što znači da iako postoji trend rasta ocjena s vremenom, on je relativno slab.

Napravimo sada sličnu analizu gdje ćemo kao ocjenu uzeti ocjenu kritičara, odnosno Rotten Tomatoes rating.

```
ggplot(oscars, aes(x = Year.of.Release, y = Tomatometer.Rating)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "Tomatometer ocjena",
    title = "Odnos godine izlaska i RT ocjene"
  )
```

5.0.0.9 Rotten Tomatoes i starost filma

```
## `geom_smooth()` using formula = 'y ~ x'
```



Regresijski pravac u ovom slučaju ima još manji nagib, no još uvijek ima pozitivan koeficijent smjera. Raspršenost podataka ponovno je velika (ponovno slab trend), stoga izračunajmo i za ovaj set podataka Pearsonov koeficijent korelacije.

```
cor.test(
  oscars$Year.of.Release,
  oscars$Tomatometer.Rating,
  use = "complete.obs"
)
```

```
##
## Pearson's product-moment correlation
##
## data:  oscars$Year.of.Release and oscars$Tomatometer.Rating
## t = 1.0749, df = 457, p-value = 0.283
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.04149945  0.14109647
## sample estimates:
##      cor
## 0.05021814
```

Pearsonov koeficijent korelacije između godine izlaska i ocjena kritičara (Tomatometer) iznosi 0,05, što ukazuje na vrlo slab trend. P-vrijednost je 0,283, što znači da veza nije statistički značajna. Drugim riječima, **ocjene kritičara ne pokazuju pouzdan trend rasta ili pada s vremenom.**

```
model <- lm(Tomatometer.Rating ~ Year.of.Release, data = oscars)
summary(model)
```

5.0.0.10 Linearna regresija - Rotten Tomatoes


```
##
## Call:
## lm(formula = Tomatometer.Rating ~ Year.of.Release, data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -58.427  -3.897   3.079   7.546  13.262
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   47.55938   37.29628   1.275   0.203
## Year.of.Release  0.02027    0.01886   1.075   0.283
##
## Residual standard error: 11.53 on 457 degrees of freedom
## (112 observations deleted due to missingness)
## Multiple R-squared:  0.002522,    Adjusted R-squared:  0.0003392
## F-statistic: 1.155 on 1 and 457 DF,  p-value: 0.283
```

Linearni model pokazuje da postoji gotovo zanemariva pozitivna veza između godine izlaska i ocjena kritičara (nagib = 0,02), koja nije statistički značajna ($p = 0,283$) i objašnjava manje od 1% varijabilnosti ocjena.

```
ggplot(oscars, aes(x = Year.of.Release, y = IMDB.Votes)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "broj IMDb glasova",
    title = "Odnos godine izlaska i broja IMDb glasova"
  )
```

5.0.0.11 Broj IMDb glasova i starost filma

```
## `geom_smooth()` using formula = 'y ~ x'
```




```
ggplot(oscars, aes(x = Year.of.Release, y = log(IMDB.Votes))) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "Log(broj IMDb glasova)",
    title = "Odnos godine izlaska i broja IMDb glasova"
  )
```

5.0.0.12 Isti postupak, uz `log(IMDB.Votes)`

```
## `geom_smooth()` using formula = 'y ~ x'
```

Odnos godine izlaska i broja IMDb glasova



```
cor.test(  
  oscars$Year.of.Release,  
  log(oscars$IMDB.Votes),  
  use = "complete.obs"  
)
```

5.0.0.13 Korelacija glasova i godine izlaska filma

```
##  
## Pearson's product-moment correlation  
##  
## data: oscars$Year.of.Release and log(oscars$IMDB.Votes)  
## t = 27.999, df = 569, p-value < 2.2e-16  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
## 0.7243963 0.7936847  
## sample estimates:  
## cor  
## 0.7612044
```

6 Analiza predviđanja pobjednika (Ivan)

6.1 Opis problema

U ovoj analizi istražiti ćemo **Možemo li pomoću dostupnih značajki pouzdano razlikovati pobjednike od ostalih?** na temelju dostupnih značajki. Za razliku od prethodnih analiza koje su se fokusirale na razlike između grupa, ova analiza koristi **logističku regresiju** kako bi modelirala vjerojatnost pobjede filma.

Cilj je utvrditi:

1. Koje značajke predviđaju pobjedu na Oscarima?
2. Koliko dobro možemo klasificirati pobjednike pomoću tih značajki?
3. Postoji li kombinacija varijabli koja omogućava pouzdanu predikciju?

Za analizu koristimo sljedeće prediktore:

- **IMDB Rating** - ocjena na IMDB platformi
- **IMDB Votes** - broj glasova korisnika (log transformacija)
- **Runtime** - trajanje filma u minutama
- **Year** - godina izlaska filma
- **Genre** - žanr filma (grupirani rijetki žanrovi)

6.2 Analiza podataka

6.2.1 Priprema podataka za logističku regresiju

Prvo učitavamo podatke i kreiramo potrebne varijable.

```
data <- read.csv("oscars_dataset.csv", sep=";")

# Kreiranje binarne varijable ishoda
# IsWinner = 1 (pobjednik), IsWinner = 0 (nominiran bez pobjede)
data$IsWinner <- ifelse(data$Award == "Winner", 1, 0)

# Čišćenje i pretvaranje varijabli
data$Rating <- as.numeric(data$IMDB.Rating)
data$Votes <- as.numeric(gsub(",", "", data$IMDB.Votes))
data$Runtime <- as.numeric(data$Movie.Time)
data$Year <- as.numeric(data$Year.of.Release)

# Grupiranje rijetkih žanrova
common_genres <- c("Action", "Adventure", "Biography",
                  "Comedy", "Crime", "Drama")
data$GenreGroup <- ifelse(data$Main.Genre %in% common_genres,
                        data$Main.Genre, "Other")
data$GenreGroup <- factor(data$GenreGroup,
                        levels = c("Drama", "Action", "Adventure",
                                  "Biography", "Comedy", "Crime", "Other"))
```

6.2.2 Finalni dataset za modeliranje

```

model_data <- data %>%
  dplyr::select(IsWinner, Rating, Votes, Runtime, Year, GenreGroup) %>%
  na.omit()

cat("Broj filmova u analizi:", nrow(model_data), "\n")

## Broj filmova u analizi: 571

cat("Broj pobjednika:", sum(model_data$IsWinner), "\n")

## Broj pobjednika: 94

cat("Broj nominiranih (bez pobjede):", sum(model_data$IsWinner == 0), "\n")

## Broj nominiranih (bez pobjede): 477

```

Nakon čišćenja podataka imamo **571 filmova**, od kojih je **94 (16.5%)** pobjednika. Omjer pobjednika i nominiranih je približno **1:5**, što predstavlja klasičan problem **neuravnoteženih klasa**.

6.2.3 Eksplorativna analiza

6.2.3.1 Usporedba IMDB ocjena Testiramo razlikuju li se pobjednici i nominirani po IMDB ocjeni koristeći **t-test**

```

cat("Pobjednici - Mean:",
    mean(model_data$Rating[model_data$IsWinner == 1]), "\n")

## Pobjednici - Mean: 7.779787

cat("Nominirani - Mean:",
    mean(model_data$Rating[model_data$IsWinner == 0]), "\n")

## Nominirani - Mean: 7.52914


t_rating <- t.test(Rating ~ IsWinner, data = model_data)
print(t_rating)

##
## Welch Two Sample t-test
##
## data: Rating by IsWinner
## t = -3.573, df = 120.07, p-value = 0.0005091
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
## -0.3895394 -0.1117541
## sample estimates:
## mean in group 0 mean in group 1
## 7.529140 7.779787

```



```
ggplot(model_data, aes(x = factor(IsWinner, labels = c("Nominee", "Winner")),
                      y = Rating, fill = factor(IsWinner))) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("0" = "#a6cee3", "1" = "#1f78b4")) +
  theme_minimal(base_size = 14) +
  labs(title = "IMDB ocjena: Pobjednici vs Nominirani",
       x = "", y = "IMDB Rating") +
  theme(legend.position = "none")
```



6.2.3.2 Usporedba broja glasova Zbog jako skewed distribucije koristimo **Wilcoxonov test**

```
cat("Pobjednici - Median votes:",
    median(model_data$Votes[model_data$IsWinner == 1]), "\n")
```

```
## Pobjednici - Median votes: 177533.5
```

```
cat("Nominirani - Median votes:",
    median(model_data$Votes[model_data$IsWinner == 0]), "\n")
```


```
## Nominirani - Median votes: 41582
```

```
wilcox_votes <- wilcox.test(Votes ~ IsWinner, data = model_data)
print(wilcox_votes)
```

```
##
```

```
## Wilcoxon rank sum test with continuity correction
##
## data: Votes by IsWinner
## W = 14434, p-value = 4.71e-08
## alternative hypothesis: true location shift is not equal to 0
```

```
ggplot(model_data, aes(x = factor(IsWinner, labels = c("Nominee", "Winner")),
                        y = Votes, fill = factor(IsWinner))) +
  geom_boxplot(alpha = 0.7) +
  scale_y_log10(labels = comma) +
  scale_fill_manual(values = c("0" = "#a6cee3", "1" = "#1f78b4")) +
  theme_minimal(base_size = 14) +
  labs(title = "Broj glasova (log skala): Pobjednici vs Nominirani",
       x = "", y = "IMDB Votes (log10)") +
  theme(legend.position = "none")
```



```
cat("Pobjednici - Mean runtime:",
    mean(model_data$Runtime[model_data$IsWinner == 1]), "\n")
```

6.2.3.3 Usporedba duljine filma

```
## Pobjednici - Mean runtime: 138.266
```

```
cat("Nominirani - Mean runtime:",
    mean(model_data$Runtime[model_data$IsWinner == 0]), "\n")
```

```
## Nominirani - Mean runtime: 122.26
```

```
t_runtime <- t.test(Runtime ~ IsWinner, data = model_data)
print(t_runtime)
```

```
##
## Welch Two Sample t-test
##
## data: Runtime by IsWinner
## t = -4.6816, df = 116.26, p-value = 7.767e-06
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
## -22.777405 -9.234594
## sample estimates:
## mean in group 0 mean in group 1
## 122.260 138.266
```

6.2.3.4 Distribucija po žanrovima Koristimo Chi-squared test nezavisnosti

```
genre_winner_table <- table(model_data$GenreGroup, model_data$IsWinner)
addmargins(genre_winner_table)
```

```
##
##      0  1 Sum
## Drama 173 42 215
## Action 36  3  39
## Adventure 36  9  45
## Biography 83 18 101
## Comedy 95 13 108
## Crime 39  9  48
## Other 15  0  15
## Sum 477 94 571
```


```
chisq_genre <- chisq.test(genre_winner_table)
print(chisq_genre)
```

```
##
## Pearson's Chi-squared test
##
## data: genre_winner_table
## X-squared = 8.8789, df = 6, p-value = 0.1805
```

Vizualizacija distribucije po žanrovima:

```
genre_plot_data <- model_data %>%
  group_by(GenreGroup, IsWinner) %>%
  summarise(Count = n(), .groups = "drop") %>%
  mutate(Outcome = ifelse(IsWinner == 1, "Winner", "Nominee"))

ggplot(genre_plot_data, aes(x = GenreGroup, y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "dodge", color = "black") +
  scale_fill_manual(values = c("Winner" = "#1f78b4", "Nominee" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Distribucija pobjednika i nominiranih po žanrovima",
       x = "Žanr", y = "Broj filmova", fill = "") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



6.3 Logistička regresija

Koristimo logističku regresiju za modeliranje binarne zavisne varijable (IsWinner)

6.3.1 Model 1: Samo IMDB Rating

```
model1 <- glm(IsWinner ~ Rating,
              data = model_data,
              family = binomial(link = "logit"))

summary(model1)
```

##

```
## Call:
## glm(formula = IsWinner ~ Rating, family = binomial(link = "logit"),
##      data = model_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -8.3611      1.7364  -4.815 1.47e-06 ***
## Rating         0.8798      0.2240   3.928 8.55e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 494.05  on 569  degrees of freedom
## AIC: 498.05
##
## Number of Fisher Scoring iterations: 4
```

```
null_model <- glm(IsWinner ~ 1, data = model_data, family = binomial)
ll_null <- logLik(null_model)
ll_model1 <- logLik(model1)
mcfadden_r2_m1 <- 1 - (ll_model1 / ll_null)

cat("McFadden's Pseudo R²:", round(as.numeric(mcfadden_r2_m1), 4), "\n")
```

6.3.1.1 McFadden's Pseudo R²

```
## McFadden's Pseudo R²: 0.0327
```

6.3.2 Model 2: Svi prediktori

```
model2 <- glm(IsWinner ~ Rating + log10(Votes) + Runtime + Year + GenreGroup,
              data = model_data,
              family = binomial(link = "logit"))

summary(model2)
```

```
##
## Call:
## glm(formula = IsWinner ~ Rating + log10(Votes) + Runtime + Year +
##      GenreGroup, family = binomial(link = "logit"), data = model_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    115.210770   17.700672    6.509 7.57e-11 ***
## Rating         -1.770832    0.397811   -4.451 8.53e-06 ***
## log10(Votes)     3.264831    0.447109    7.302 2.83e-13 ***
## Runtime          0.016514    0.005086    3.247 0.00117 **
```

```
## Year                -0.061292    0.008938   -6.857 7.02e-12 ***
## GenreGroupAction    -1.784374    0.664404   -2.686 0.00724 **
## GenreGroupAdventure -0.673262    0.494484   -1.362 0.17334
## GenreGroupBiography -0.022287    0.358982   -0.062 0.95050
## GenreGroupComedy     -0.513873    0.385988   -1.331 0.18308
## GenreGroupCrime      -0.823464    0.481372   -1.711 0.08714 .
## GenreGroupOther      -15.483637  573.192070   -0.027 0.97845
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 392.00  on 560  degrees of freedom
## AIC: 414
##
## Number of Fisher Scoring iterations: 15
```

```
ll_model2 <- logLik(model2)
mcfadden_r2_m2 <- 1 - (ll_model2 / ll_null)

cat("McFadden's Pseudo R²:", round(as.numeric(mcfadden_r2_m2), 4), "\n")
```

6.3.2.1 McFadden's Pseudo R²

```
## McFadden's Pseudo R²: 0.2325
```

6.4 Test omjera vjerodostojnosti (LR test)

Koristimo LR test za usporedbu modela

6.4.1 LR test: Model 2 vs Null model

```
LR_full <- -2 * (as.numeric(ll_null) - as.numeric(ll_model2))
df_full <- length(coef(model2)) - 1
p_value_full <- pchisq(LR_full, df = df_full, lower.tail = FALSE)

cat("H0: Svi regresori su redundantni\n")
```

```
## H0: Svi regresori su redundantni
```

```
cat("H1: Barem jedan regresor nije redundantan\n\n")
```

```
## H1: Barem jedan regresor nije redundantan
```

```
cat("LR statistika:", round(LR_full, 2), "\n")
```

```
## LR statistika: 118.76
```

```
cat("Stupnjevi slobode:", df_full, "\n")
```

```
## Stupnjevi slobode: 10
```

```
cat("p-vrijednost:", format.pval(p_value_full, digits = 3), "\n")
```

```
## p-vrijednost: <2e-16
```

6.4.2 LR test: Model 2 vs Model 1

```
LR_comparison <- -2 * (as.numeric(ll_model1) - as.numeric(ll_model2))
df_comparison <- length(coef(model2)) - length(coef(model1))
p_value_comparison <- pchisq(LR_comparison, df = df_comparison, lower.tail = FALSE)

cat("LR statistika:", round(LR_comparison, 2), "\n")
```

```
## LR statistika: 102.05
```

```
cat("Stupnjevi slobode:", df_comparison, "\n")
```

```
## Stupnjevi slobode: 9
```

```
cat("p-vrijednost:", format.pval(p_value_comparison, digits = 3), "\n")
```

```
## p-vrijednost: <2e-16
```

6.5 Odds Ratios - Tumačenje koeficijenata

Interpretiramo koeficijente kroz Odds Ratios

```
odds_ratios <- exp(coef(model2))
conf_int <- exp(confint(model2, quiet = TRUE))
```

```
## Waiting for profiling to be done...
```

```
odds_table <- data.frame(
  Predictor = names(odds_ratios),
  OddsRatio = odds_ratios,
  CI_Lower = conf_int[, 1],
  CI_Upper = conf_int[, 2]
)
rownames(odds_table) <- NULL

print(odds_table, digits = 3)
```

##	Predictor	OddsRatio	CI_Lower	CI_Upper
## 1	(Intercept)	1.08e+50	3.07e+35	5.26e+65
## 2	Rating	1.70e-01	7.62e-02	3.65e-01
## 3	log10(Votes)	2.62e+01	1.13e+01	6.57e+01
## 4	Runtime	1.02e+00	1.01e+00	1.03e+00
## 5	Year	9.41e-01	9.24e-01	9.57e-01
## 6	GenreGroupAction	1.68e-01	3.70e-02	5.42e-01
## 7	GenreGroupAdventure	5.10e-01	1.83e-01	1.29e+00
## 8	GenreGroupBiography	9.78e-01	4.77e-01	1.96e+00
## 9	GenreGroupComedy	5.98e-01	2.73e-01	1.25e+00
## 10	GenreGroupCrime	4.39e-01	1.63e-01	1.09e+00
## 11	GenreGroupOther	1.89e-07	NA	2.54e+09


Interpretacija Odds Ratios:

- **OR > 1:** Povećanje regresora povećava šanse za pobjedu
- **OR < 1:** Povećanje regresora smanjuje šanse za pobjedu
- **OR = 1:** Regresor nema utjecaj

```
odds_plot_data <- odds_table[-1, ]

ggplot(odds_plot_data, aes(x = OddsRatio, y = reorder(Predictor, OddsRatio))) +
  geom_point(size = 4, color = "#1f78b4") +
  geom_errorbarh(aes(xmin = CI_Lower, xmax = CI_Upper), height = 0.2) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "red") +
  theme_minimal(base_size = 14) +
  labs(title = "Odds Ratios za Model 2",
       subtitle = "Crvena linija = neutralan efekt (OR = 1)",
       x = "Odds Ratio (log skala)",
       y = "Prediktor") +
  scale_x_log10()
```

`height` was translated to `width`.



6.6 Predikcija i Confusion Matrix

6.6.1 Izračun predikcija

```
predicted_probs <- predict(model2, type = "response")
```

```
# Threshold postavljen na proporciju pobjednika u uzorku
threshold <- sum(model_data$IsWinner) / nrow(model_data)
cat("Odabrani threshold:", round(threshold, 3), "\n")
```

```
## Odabrani threshold: 0.165
```

```
predicted_class <- ifelse(predicted_probs >= threshold, 1, 0)
```

```
conf_matrix <- table(Predicted = predicted_class, Actual = model_data$IsWinner)
print(conf_matrix)
```

```
##           Actual
## Predicted    0    1
##           0 353  21
##           1 124  73
```

6.6.2 Metrike performansi

```

TP <- conf_matrix[2, 2] # True Positive
TN <- conf_matrix[1, 1] # True Negative
FP <- conf_matrix[2, 1] # False Positive
FN <- conf_matrix[1, 2] # False Negative

accuracy <- (TP + TN) / sum(conf_matrix)
precision <- TP / (TP + FP)
recall <- TP / (TP + FN)
f1 <- 2 * (precision * recall) / (precision + recall)

cat("Accuracy: ", round(accuracy, 4),
    " - postotak točnih predikcija\n")

```

```
## Accuracy: 0.7461 - postotak točnih predikcija
```

```

cat("Precision: ", round(precision, 4),
    " - od predviđenih pobjednika, koliko je stvarno pobijedilo\n")

```

```
## Precision: 0.3706 - od predviđenih pobjednika, koliko je stvarno pobijedilo
```

```

cat("Recall: ", round(recall, 4),
    " - koliko stvarnih pobjednika uspijemo detektirati\n")

```

```
## Recall: 0.7766 - koliko stvarnih pobjednika uspijemo detektirati
```

```

cat("F1 Score: ", round(f1, 4),
    " - harmonijska sredina precision i recall\n")

```

```
## F1 Score: 0.5017 - harmonijska sredina precision i recall
```

6.6.3 Vizualizacija Confusion Matrix


```

conf_df <- as.data.frame(conf_matrix)
colnames(conf_df) <- c("Predicted", "Actual", "Freq")

ggplot(conf_df, aes(x = Actual, y = Predicted, fill = Freq)) +
  geom_tile(color = "white", linewidth = 1) +
  geom_text(aes(label = Freq), size = 10, color = "white") +
  scale_fill_gradient(low = "#a6cee3", high = "#1f78b4") +
  theme_minimal(base_size = 14) +
  labs(title = "Confusion Matrix (Model 2)",
       x = "Stvarni ishod (0=Nominee, 1=Winner)",
       y = "Predviđeni ishod") +
  theme(legend.position = "none")

```


Confusion Matrix (Model 2)



6.6.4 Distribucija predvidenih vjerojatnosti

```
pred_df <- data.frame(
  Probability = predicted_probs,
  Actual = factor(model_data$IsWinner,
    levels = c(0, 1),
    labels = c("Nominee", "Winner"))
)

ggplot(pred_df, aes(x = Probability, fill = Actual)) +
  geom_histogram(position = "identity", alpha = 0.6, bins = 30, color = "black") +
  geom_vline(xintercept = threshold, linetype = "dashed",
    color = "red", linewidth = 1) +
  scale_fill_manual(values = c("Nominee" = "#a6cee3", "Winner" = "#1f78b4")) +
  theme_minimal(base_size = 14) +
  labs(title = "Distribucija predvidenih vjerojatnosti",
    subtitle = paste0("Crvena linija = threshold (",
      round(threshold, 3), ")"),
    x = "Predviđena vjerojatnost pobjede",
    y = "Broj filmova",
    fill = "Stvarni ishod")
```



6.7 Zaključak

Na temelju rezultata logističke regresije i testova omjera vjerodostojnosti, možemo zaključiti sljedeće:

Odgovor na glavno pitanje: Možemo li pouzdano razlikovati pobjednike?

Djelomično DA, ali s ograničenjima.

Pozitivni nalazi:

1. Model ima statistički značajnu prediktivnu moć (McFadden $R^2 = 0.233$, LR test $p < 0.001$)
2. Broj glasova na IMDB-u je najjači prediktor pobjede
3. Model postiže 74.6% accuracy
4. 77.7% recall - detektiramo većinu stvarnih pobjednika

Ograničenja:

1. Precision je 37.1% - prisutno je puno lažnih pozitiva
2. Model objašnjava samo 23.3% varijance
3. 76.7% faktora ostaje neobjašnjeno (kvaliteta glume i režije, marketinška kampanja, politički i kulturni kontekst, subjektivni ukus Akademije)

Praktična primjena:

Model je koristan za screening - može identificirati filmove s niskim šansama, ali nije pouzdan za definitivnu predikciju pobjednika. Služi više kao dopunski alat uz druge analize.

Na temelju dostupnih podataka, možemo zaključiti da je pobjeda na Oscarima fenomen koji se ne može potpuno objasniti kvantitativnim mjerama - što potvrđuje kompleksnost i nepredvidivost umjetničkih nagrada.