

Oscarovci

Tim #1

2025-11-06

Contents

1	Opis skupa podataka	3
2	Analiza žanrova kod pobjednika (Matija)	4
2.1	Opis problema	4
2.2	Single-label analiza	4
2.3	Multi-label analiza	8
2.4	Statističko testiranje	11
2.5	Zaključak	15
3	Istraživačko pitanje: Možemo li naslutiti kako je film ocijenjen pomoću drugih značajki?	16
3.1	Opis problema	16
3.2	Priprema podataka za analizu	16
3.3	Deskriptivna statistika	17
3.4	Korelacijska matrica	17
3.5	Scatter plot: IMDb ocjena vs trajanje filma	18
3.6	Model višestruke linearne regresije	19
3.7	Priprema dummy varijabli	19
3.8	Procjena modela	19
3.9	Testovi regresijskih koeficijenata i adjusted R^2	20
3.10	Predikcija srednje vrijednosti	21
3.11	Analiza reziduala	22
3.12	Test normalnosti reziduala	23
3.13	Bootstrap analiza	24
3.14	Bootstrap intervali pouzdanosti	24
3.15	Vizualizacija Bootstrap distribucija	26
3.16	Zaključak	27

4	Istraživanje povezanosti između starosti filma i njegove ocjene	28
4.1	Opis problema	28
4.2	Priprema podataka za analizu	28
4.3	Vizualizacija podataka	28
4.4	Linearna regresija	30
4.5	Analiza reziduala	30
4.6	Q-Q graf	31
4.7	Testiranje Lillieforsovom inačicom	32
4.8	Pearsonov koeficijent korelacije	32
5	Analiza predviđanja pobjednika (Ivan)	34
5.1	Opis problema	34
5.2	Analiza podataka	34
5.3	Logistička regresija	39
5.4	Test omjera vjerodostojnosti (LR test)	41
5.5	Odds Ratios - Tumačenje koeficijenata	42
5.6	Predikcija i Confusion Matrix	44
5.7	Zaključak	47

1 Opis skupa podataka

Skup podataka koji analiziramo u projektu sadrži 571 odgovor/redak.

#Prikaz varijabli u skupu podataka i njihovog podatkovnog tipa

```
data = read_csv2("oscars_dataset.csv", locale = locale(decimal_mark = ",", grouping_mark = ".") ,show_col
var_types <- sapply(data, class)
cat(paste(names(var_types), ": ", var_types, sep = " ", collapse = "\n"))
```

```
## Unnamed: 0: numeric
## Film: character
## Oscar Year: character
## Film Studio/Producer(s): character
## Award: character
## Year of Release: numeric
## Movie Time: numeric
## Movie Genre: character
## Main Genre: character
## Subgenre: character
## IMDB Rating: numeric
## IMDB Votes: character
## Content Rating: character
## Directors: character
## Original Release Date: Date
## Production Company: character
## Tomatometer Rating: numeric
## Tomatometer Count: numeric
## Audience Rating: numeric
## Audience Count: numeric
```

2 Analiza žanrova kod pobjednika (Matija)

2.1 Opis problema

Cilj ove analize je ispitati postoji li povezanost između filmskih žanrova i vjerojatnosti osvajanja Oscara. S obzirom na to da je teško svesti film na samo jedan žanr, analizu provodimo na dva načina:

1. *Single-label pristup* – svakom filmu pridružujemo samo jedan glavni žanr (Main Genre).
2. *Multi-label pristup* – film može pripadati više žanrova (Movie Genre), a svaki žanr ćemo zasebno brojati.

Na taj način možemo usporediti kako različiti modeli označavanja žanrova utječu na rezultate.

2.2 Single-label analiza

2.2.1 Grupiranje žanrova i priprema podataka za analizu:

Prvo nego što krenemo raditi bilo kakve statističke testove, moramo se upoznati s podacima. U datasetu se nalazi više stupaca koje sadrže kako su labelirani filmovi po z

```
data <- data %>%
  mutate(`Main Genre` = as.character(`Main Genre`))

winners <- data %>% filter(Award == "Winner")
nominees <- data %>% filter(Award %in% c("Nominee", "Winner"))

winner_counts <- winners %>%
  count(`Main Genre`, name = "Winners")

nominee_counts <- nominees %>%
  count(`Main Genre`, name = "Nominations")

genre_table <- nominee_counts %>%
  left_join(winner_counts, by = "Main Genre") %>%
  mutate(
    Winners = replace_na(Winners, 0),
    NotWinner = Nominations - Winners
  ) %>%
  rename(Genre = `Main Genre`)
```

Vizualizacija pobjeda i nominacija po žanru:


```
genre_plot_data <- genre_table %>%
  arrange(desc(Winners)) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )

ggplot(genre_plot_data,
```

```

    aes(x = Count,
        y = reorder(Genre, Count),
        fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  geom_text(aes(label = Count),
            position = position_stack(vjust = 0.5),
            size = 3) +
  scale_fill_manual(values = c(
    "Winners" = "#1f78b4",
    "NotWinner" = "#a6cee3"
  )) +
  theme_minimal(base_size = 15) +
  labs(
    title = "Oscari po žanru: Pobjede i nominacije",
    x = "Broj filmova",
    y = "Žanr",
    fill = ""
  )
)

```



Zbog velike disproporcije između broja pobjeda i nominacija, koristimo i postotne prikaze te logaritamsku skalu kako bismo mogli bolje vizualizirati podatke.


2.2.2 Postotni prikaz pobjeda vs nominacija po žanru:

```

ggplot(genre_plot_data, aes(x = reorder(Genre, -Count), y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "fill", color = "black") +
  scale_y_continuous(labels = scales::percent_format()) +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6c3e3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Postotak pobjeda vs nominacija po žanru",


```

```
x = "Žanr", y = "Postotak", fill = "") +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



2.2.3 Logaritamska skala za broj pobjeda vs nominacija po žanru:

```
ggplot(genre_plot_data, aes(x = reorder(Genre, Count), y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  scale_y_log10() +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Oscari po žanru (log skala)",
       x = "Žanr", y = "Broj filmova (log10)", fill = "") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




2.2.4 Stopa uspješnosti po žanru:

Možemo također izračunati stopu uspješnosti (postotak pobjeda u odnosu na broj nominacija) za svaki žanr kako bismo dodatno ilustrirali razlike među žanrovima.

```
genre_table <- genre_table %>%
  mutate(WinRate = (Winners / Nominations) * 100)

ggplot(genre_table, aes(x = reorder(Genre, WinRate), y = WinRate)) +
  geom_col(fill = "#1f78b4", width = 0.7) +
  geom_text(
    aes(label = sprintf("%.1f%%", WinRate)),
    hjust = -0.1,
    size = 4
  ) +
  coord_flip() +
  scale_y_continuous(limits = c(0, max(genre_table$WinRate) * 1.15)) +
  labs(
    title = "Stopa pobjeda po žanru",
    x = "Žanr",
    y = "Postotak pobjede"
  ) +
  theme_minimal(base_size = 14) +
  theme(
    plot.title = element_text(face = "bold", size = 16),
    axis.text.y = element_text(size = 12),
    axis.text.x = element_text(size = 11)
  )
```



2.2.5 Kontingencijska tablica nominiranih i pobjednika po žanrovima:

```
kontingencijska <- genre_table[, c("Winners", "NotWinner")]
row.names(kontingencijska) <- genre_table$Genre
kontingencijska
```

```
## # A tibble: 14 x 2
##   Winners NotWinner
## *   <int>     <int>
## 1         3         36
## 2         9         36
## 3         0          3
## 4        18         83
## 5        13         95
## 6         9         39
## 7        42        173
## 8         0          1
## 9         0          2
## 10        0          3
## 11        0          1
## 12        0          2
## 13        0          1
## 14        0          2
```

2.3 Multi-label analiza

2.3.1 Priprema podataka

Priprema podataka za multi-label analizu žanrova:


```
data <- data %>%
  mutate(`Movie Genre` = as.character(`Movie Genre`))
```

Mutiramo podatke kako bismo razdvojili višestruke žanrove u zasebne retke.

```
data_long <- data %>%
  separate_rows(`Movie Genre`, sep = ",") %>%
  mutate(`Movie Genre` = trimws(`Movie Genre`))
```

Izračun broja pobjeda i ne-pobjeda po žanru:

```
genre_counts <- data_long %>%
  mutate(
    Outcome = ifelse(Award == "Winner", "Winner", "NotWinner")
  ) %>%
  count(`Movie Genre`, Outcome) %>%
  pivot_wider(
    names_from = Outcome,
    values_from = n,
    values_fill = 0
  ) %>%
  mutate(
    Total = Winner + NotWinner,
    GenreGroup = ifelse(Total < 5, "Other", `Movie Genre`),
    SuccessRate = Winner / Total
  )
```

Grupiranje rijetkih žanrova u kategoriju “Ostali” i izračun ukupnih vrijednosti po grupama žanrova:

```
genre_table_ml <- genre_counts %>%
  group_by(GenreGroup) %>%
  summarise(
    Winners = sum(Winner),
    NotWinner = sum(NotWinner),
    Total = sum(Total),
    SuccessRate = sum(Winner)/sum(Total),
    .groups = "drop"
  )
```


2.3.2 Vizualizacija rezultata multi-label analize žanrova:

```
genre_melt <- genre_table_ml %>%
  select(GenreGroup, Winners, NotWinner) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )


# Bar plot (broj pojavljivanja)
ggplot(genre_melt, aes(x = Count, y = reorder(GenreGroup, Count), fill = Outcome)) +
```

```
geom_bar(stat = "identity", color = "black") +
geom_text(aes(label = Count), position = position_stack(vjust = 0.5), size = 3) +
scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
theme_minimal(base_size = 14) +
labs(title = "Multi-label analiza žanrova (grupirani rijetki žanrovi)",
x = "Broj pojavljivanja",
y = "Žanr",
fill = "")
```

Multi-label analiza žanrova (grupirani rijetki žanrovi)



```
# Bar plot (postotak pobjeda)
ggplot(genre_table_ml, aes(x = SuccessRate, y = reorder(GenreGroup, SuccessRate))) +
geom_col(fill = "#1f78b4") +
geom_text(aes(label = scales::percent(SuccessRate, accuracy = 0.1)), hjust = -0.1, size = 4) +
scale_x_continuous(labels = scales::percent_format(), limits = c(0, NA)) +
theme_minimal(base_size = 14) +
labs(title = "Postotak uspješnosti po žanru (multi-label)",
x = "Udio pobjeda",
y = "Žanr")
```



2.4 Statističko testiranje

2.4.1 Hipoteze:

- Nulta hipoteza (H_0): Ne postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.
- Alternativna hipoteza (H_1): Postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.

2.4.2 Grupiranje žanrova i priprema podataka za analizu:

Kako bi ispitali nezavisnost dviju kategorijske varijable, odnosno kako bi ispitali jesu li žanrovi i pobjede zavisi, koristit ćemo hi-kvadrat test. Neka je kontingencijska tablica dimenzija $r \times c$ sa:

- O_{ij} = promatrana frekvencija u ćeliji (i, j)
- E_{ij} = očekivana frekvencija ako su varijable neovisne

Očekivane frekvencije računamo

$$E_{ij} = \frac{(\text{ukupno u redu } i) \cdot (\text{ukupno u stupcu } j)}{\text{ukupan broj promatranja}}$$

Hi-kvadrat statistika se provodi formulom:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- Mala vrijednost $\chi^2 \rightarrow$ promatrane frekvencije blizu očekivanih (neovisnost)

- Velika vrijednost $\chi^2 \rightarrow$ značajna odstupanja (ovisnost)

Stupnjevi slobode računamo:

$$df = (r - 1)(c - 1)$$

Standardizirani reziduali za procjenu odstupanja pojedine ćelije, odnosno u ovome slučaju žanra:

$$\text{StdRes}_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

- Pozitivni rezidual $\rightarrow$ više promatranih nego očekivanih
- Negativni rezidual $\rightarrow$ manje promatranih nego očekivanih
- Vrijednosti veće od ± 2 obično se smatraju **statistički značajnim!**

Važno je reći da hi-kvadrat test ima važan uvjet: očekivane frekvencije u svakoj ćeliji kontingencijske tablice trebaju biti veće od 5. Za žanrove s jako malim brojem filmova (npr. 1–2 pojave), očekivane frekvencije za te vrlo male. Kako bi statistički test bio valjan, grupirat ćemo manje zastupljene žanrove u kategoriju “Ostali” kako bismo osigurali da sve ćelije imaju dovoljne očekivane frekvencije.

2.4.3 Prvo ćemo analizirati prvi pristup: Single-label analiza

```
common_genres <- c("Action", "Adventure", "Biography", "Comedy", "Crime", "Drama")
data$GenreGroup <- ifelse(data$`Main Genre` %in% common_genres,
                          data$`Main Genre`,
                          "Other")

# broj pobjeda po grupama
winner_counts <- as.data.frame(table(subset(data, Award=="Winner")$GenreGroup))
colnames(winner_counts) <- c("GenreGroup", "Winners")

# broj nominacija po grupama
nominee_counts <- as.data.frame(table(subset(data, Award %in% c("Winner", "Nominee"))$GenreGroup))
colnames(nominee_counts) <- c("GenreGroup", "Nominations")

df <- merge(nominee_counts, winner_counts, by="GenreGroup", all.x=TRUE)
df$Winners[is.na(df$Winners)] <- 0

# Dodaj kolonu za ne-pobjede
df$NotWinner <- df$Nominations - df$Winners

kontigencijska_single <- as.data.frame(df[, c("Winners", "NotWinner")])
row.names(kontigencijska_single) <- df$GenreGroup

#Prikaz kontigencijske tablice
kontigencijska_single
```

```
##           Winners NotWinner
## Action           3         36
## Adventure        9         36
```

## Biography	18	83
## Comedy	13	95
## Crime	9	39
## Drama	42	173
## Other	0	15

2.4.4 Hi-kvadrat test:

Sada radimo Hi-kvadrat test kako bismo vidjeli postoje li značajne razlike u učestalosti pobjeda među različitim žanrovima. Za razinu značajnosti, uzet ćemo $\alpha = 0,05$.

```
# Chi-squared test
chisq_single <- chisq.test(kontigencijska_single)
chisq_single
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_single
## X-squared = 8.8789, df = 6, p-value = 0.1805
```

S obzirom na to da je $p - value > \alpha$, odnosno $0.1805 > 0.05$, prihvaćamo H_0 .

Standardizirani reziduali koji pokazuju kako žanrovi odstupaju:

```
chisq_single$stdres
```

```
##           Winners NotWinner
## Action    -1.5300621  1.5300621
## Adventure  0.6667449 -0.6667449
## Biography  0.4060704 -0.4060704
## Comedy    -1.3771971  1.3771971
## Crime      0.4465715 -0.4465715
## Drama      1.5385882 -1.5385882
## Other     -1.7423324  1.7423324
```

2.4.5 Zatim analiziramo Multi-label analizu:

```
kontigencijska_multi <- genre_table_ml[, c("Winners", "NotWinner")]
row.names(kontigencijska_multi) <- genre_table_ml$GenreGroup
kontigencijska_multi
```

```
## # A tibble: 20 x 2
##   Winners NotWinner
## *   <int>     <int>
## 1      3         36
## 2     11         56
## 3     20         89
## 4     16        109
## 5     13         59
```

```
## 6      88      414
## 7       6       21
## 8       1       23
## 9       2       11
## 10     13       54
## 11      1       25
## 12      8       22
## 13      2       26
## 14      0        7
## 15     25     149
## 16      0       10
## 17      3        7
## 18      8       32
## 19     13       29
## 20      3       12
```

2.4.6 Hi-kvadrat test

```
chisq_multi <- chisq.test(kontigencijska_multi)
chisq_multi
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_multi
## X-squared = 27.047, df = 19, p-value = 0.1036
```

```
chisq_multi$stdres
```

```
##           Winners  NotWinner
## Action    -1.50765823  1.50765823
## Adventure -0.02714508  0.02714508
## Biography  0.52937302 -0.52937302
## Comedy    -1.17770142  1.17770142
## Crime      0.35563977 -0.35563977
## Drama      0.74281443 -0.74281443
## Family     0.80259845 -0.80259845
## Fantasy    -1.64522050  1.64522050
## Film-Noir -0.11246503  0.11246503
## History    0.64652494 -0.64652494
## Music      -1.75801693  1.75801693
## Musical    1.50914353 -1.50914353
## Mystery    -1.35147028  1.35147028
## Other      -1.18063854  1.18063854
## Romance    -0.82235271  0.82235271
## Sci-Fi     -1.41262596  1.41262596
## Sport      1.14985359 -1.14985359
## Thriller   0.59774895 -0.59774895
## War        2.55219613 -2.55219613
## Western    0.36279002 -0.36279002
```

Ovdje također vidimo da je $p - value > \alpha$, odnosno $0.1036 > 0.05$ te prihvaćamo H_0 .

2.5 Zaključak

Na temelju dobivenih rezultata Hi-kvadrat testa kod oba pristupa, prihvaćamo H_0 i možemo zaključiti da ne postoje značajne razlike u učestalosti pobjeda među različitim žanrovima filmova nominiranih za Oscara. Standardizirani reziduali ukazuju na to koji žanrovi značajno odstupaju od očekivanih vrijednosti, što može biti korisno za daljnje istraživanje i razumijevanje trendova u dodjeli nagrada, kao i pitanje zašto su neki žanrovi češće nominirani od ostalih.

3 Istraživačko pitanje: Možemo li naslutiti kako je film ocijenjen pomoću drugih značajki?

U ovoj analizi istražujemo možemo li pomoću dostupnih značajki filmova (godina izlaska, trajanje, žanr i content rating) pouzdano predvidjeti IMDb ocjenu. Cilj je izgraditi model višestruke linearne regresije koji će omogućiti razumijevanje koje karakteristike utječu na ocjenu i koliko taj utjecaj snažan.

```
oscars <- read.csv("oscars_dataset.csv", sep = ";")
```

3.1 Opis problema

Jedno od pitanja koje razmatramo je možemo li naslutiti kako je film ocijenjen na temelju drugih dostupnih značajki. Cilj je izgraditi model koji će omogućiti predikciju IMDb ocjene koristeći godinu izlaska filma, trajanje, žanr i content ratinga filma kao prediktore.

3.2 Priprema podataka za analizu

Najprije moramo provjeriti nedostajuće podatke i osigurati da su tipovi varijabli ispravni.

```
data.frame(  
  Varijabla = c("IMDB.Rating", "Year.of.Release", "Movie.Time", "Main.Genre", "Content.Rating"),  
  Broj_vrijednosti = c(  
    sum(oscars$IMDB.Rating != ""),  
    sum(oscars$Year.of.Release != ""),  
    sum(oscars$Movie.Time != ""),  
    sum(oscars$Main.Genre != ""),  
    sum(oscars$Content.Rating != "")  
  )  
)
```

```
##      Varijabla Broj_vrijednosti  
## 1  IMDB.Rating             571  
## 2 Year.of.Release          571  
## 3   Movie.Time            571  
## 4   Main.Genre            571  
## 5 Content.Rating          459
```

Primjećujemo da postoje neki nedostaci. Kako bi podaci bili spremni za daljnju analizu, potrebno je osigurati da su tipovi podataka ispravni i ukloniti redove s nedostajućim vrijednostima.

```
oscars$IMDB.Rating <- as.numeric(as.character(oscars$IMDB.Rating))  
oscars$Year.of.Release <- as.numeric(as.character(oscars$Year.of.Release))  
oscars$Movie.Time <- as.numeric(as.character(oscars$Movie.Time))  
  
oscars_clean <- oscars[complete.cases(oscars[, c("IMDB.Rating", "Year.of.Release",  
                                                "Movie.Time", "Main.Genre",  
                                                "Content.Rating")]), ]
```


3.3 Deskriptivna statistika

Numeričke varijable

```
summary(oscars_clean[, c("IMDB.Rating", "Year.of.Release", "Movie.Time")])
```

```
##   IMDB.Rating   Year.of.Release   Movie.Time
##   Min.   :5.60   Min.   :1927   Min.   : 66.0
##   1st Qu.:7.30   1st Qu.:1944   1st Qu.:107.0
##   Median :7.60   Median :1972   Median :121.0
##   Mean   :7.57   Mean   :1973   Mean   :124.9
##   3rd Qu.:7.90   3rd Qu.:2001   3rd Qu.:136.5
##   Max.   :9.30   Max.   :2021   Max.   :238.0
```

Mjere centralne tendencije i rasipanja

```
data.frame(
  Varijabla = c("IMDB.Rating", "Year.of.Release", "Movie.Time"),
  Mean = c(
    mean(oscars_clean$IMDB.Rating, na.rm = TRUE),
    mean(oscars_clean$Year.of.Release, na.rm = TRUE),
    mean(oscars_clean$Movie.Time, na.rm = TRUE)
  ),
  Median = c(
    median(oscars_clean$IMDB.Rating, na.rm = TRUE),
    median(oscars_clean$Year.of.Release, na.rm = TRUE),
    median(oscars_clean$Movie.Time, na.rm = TRUE)
  ),
  SD = c(
    sd(oscars_clean$IMDB.Rating, na.rm = TRUE),
    sd(oscars_clean$Year.of.Release, na.rm = TRUE),
    sd(oscars_clean$Movie.Time, na.rm = TRUE)
  ),
  IQR = c(
    IQR(oscars_clean$IMDB.Rating, na.rm = TRUE),
    IQR(oscars_clean$Year.of.Release, na.rm = TRUE),
    IQR(oscars_clean$Movie.Time, na.rm = TRUE)
  )
)
```

```
##           Varijabla           Mean Median           SD  IQR
## 1      IMDB.Rating      7.570403    7.6 0.5596518 0.6
## 2 Year.of.Release 1973.357268 1972.0 29.3157379 57.0
## 3      Movie.Time 124.894921 121.0 26.3228170 29.5
```

3.4 Korelacijska matrica

Računamo korelacijsku matricu za ispitivanje linearnih odnosa između naših numeričkih varijabli.

```
cor_matrix <- cor(oscars_clean[, c("IMDB.Rating", "Movie.Time", "Year.of.Release")],
  use = "complete.obs")
print(round(cor_matrix, 3))
```

```
##          IMDB.Rating Movie.Time Year.of.Release
## IMDB.Rating          1.000      0.292          0.330
## Movie.Time           0.292      1.000          0.242
## Year.of.Release      0.330      0.242          1.000
```


Korelacijska matrica pokazuje odnose između numeričkih prediktora. Pozitivna korelacija između godine izlaska i IMDb ocjene ukazuje na to da noviji filmovi teže imati više ocjene.

3.5 Scatter plot: IMDb ocjena vs trajanje filma

Grafički prikaz odnosa između trajanja filma i IMDb ocjene pomoću dijagrama raspršenja.

```
plot(oscars_clean$Movie.Time, oscars_clean$IMDB.Rating,
     main = "Odnos trajanja filma i IMDb ocjene",
     xlab = "Trajanje filma (minute)",
     ylab = "IMDb ocjena",
     pch = 19, col = rgb(0, 0, 1, 0.4))

abline(lm(IMDB.Rating ~ Movie.Time, data = oscars_clean),
       col = "red", lwd = 2)
```



Iz scatter plotu možemo vidjeti blagu pozitivnu vezu između trajanja filma i ocjene. Crvena linija predstavlja linearnu regresiju.

3.6 Model višestruke linearne regresije

Sada ćemo izgraditi model koristeći višestruku linearnu regresiju.

3.7 Priprema dummy varijabli

Budući da kategorijske varijable ne mogu direktno ući u linearni regresijski model, potrebno ih je transformirati u dummy varijable.

```
oscars_model <- fastDummies::dummy_cols(oscars_clean,
                                         select_columns = c("Main.Genre", "Content.Rating"),
                                         remove_first_dummy = TRUE,
                                         remove_selected_columns = FALSE)

names(oscars_model) <- make.names(names(oscars_model))

# Pregled dostupnih dummy varijabli
genre_cols <- grep("^Main.Genre_", names(oscars_model), value = TRUE)
rating_cols <- grep("^Content.Rating_", names(oscars_model), value = TRUE)
```

Dummy varijable omogućuju uključivanje kategorijskih varijabli u model tako da svaka kategorija dobiva svoju indikatorsku varijablu. Važno je izostaviti jednu dummy varijablu iz svake kategorijske varijable kako bi se izbjegla multikolinearnost.

3.8 Procjena modela

```
base_predictors <- c("Year.of.Release", "Movie.Time")
all_predictors <- c(base_predictors, genre_cols, rating_cols)

cat("Broj prediktora u modelu:", length(all_predictors), "\n")

## Broj prediktora u modelu: 20

cat("Prvih 5 dummy varijabli:\n")

## Prvih 5 dummy varijabli:

print(head(all_predictors, 10))

## [1] "Year.of.Release"      "Movie.Time"           "Main.Genre_Adventure"
## [4] "Main.Genre_Animation" "Main.Genre_Biography" "Main.Genre_Comedy"
## [7] "Main.Genre_Crime"     "Main.Genre_Drama"     "Main.Genre_Family"
## [10] "Main.Genre_Film.Noir"

model_formula <- reformulate(termlabels = all_predictors,
                             response = "IMDB.Rating")

fit_multi <- lm(model_formula, data = oscars_model)

summary(fit_multi)
```

```
##
## Call:
## lm(formula = model_formula, data = oscars_model)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.64027 -0.30374  0.01772  0.33585  1.49495
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      3.1592144   2.3170669    1.363 0.173297
## Year.of.Release    0.0018122   0.0011910    1.522 0.128685
## Movie.Time         0.0052093   0.0008615    6.047 2.73e-09 ***
## Main.Genre_Adventure -0.0380734   0.1091455   -0.349 0.727349
## Main.Genre_Animation  0.7457589   0.3056128    2.440 0.014993 *
## Main.Genre_Biography -0.0764575   0.0927162   -0.825 0.409934
## Main.Genre_Comedy     0.0080785   0.0944425    0.086 0.931864
## Main.Genre_Crime      0.2992392   0.1078003    2.776 0.005693 **
## Main.Genre_Drama      0.0024800   0.0863247    0.029 0.977091
## Main.Genre_Family     0.4499028   0.4999644    0.900 0.368583
## Main.Genre_Film.Noir  0.1689826   0.3578175    0.472 0.636929
## Main.Genre_Horror     0.1869882   0.2953578    0.633 0.526938
## Main.Genre_Music     -1.4016225   0.5005105   -2.800 0.005284 **
## Main.Genre_Musical    -0.9306681   0.3598880   -2.586 0.009966 **
## Main.Genre_Romance    -0.3943736   0.5007340   -0.788 0.431275
## Main.Genre_Western    -1.0622698   0.3575178   -2.971 0.003096 **
## Content.Rating_G      0.0304803   0.0876661    0.348 0.728209
## Content.Rating_NR     0.1073793   0.0687248    1.562 0.118756
## Content.Rating_PG     0.2584658   0.0750049    3.446 0.000612 ***
## Content.Rating_PG.13  0.2915523   0.0938619    3.106 0.001993 **
## Content.Rating_R      0.3063185   0.0805032    3.805 0.000158 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4906 on 550 degrees of freedom
## Multiple R-squared:  0.2585, Adjusted R-squared:  0.2315
## F-statistic: 9.587 on 20 and 550 DF,  p-value: < 2.2e-16
```

Model višestruke linearne regresije procjenjuje IMDb ocjenu kao funkciju godine izlaska, trajanja filma, žanra i content ratinga. Dummy varijable predstavljaju razlike u ocjenama između pojedinih žanrova i content ratinga u odnosu na referentnu kategoriju.

Iz sažetka modela možemo iščitati da su neki koeficijenti statistički značajni ($p < 0.05$), što znači da imaju značajan utjecaj na IMDb ocjenu. Adjusted R^2 pokazuje koliki postotak varijance u ocjenama model objašnjava, prilagođeno za broj parametara.

3.9 Testovi regresijskih koeficijenata i adjusted R^2

```
adj_r2 <- summary(fit.multi)$adj.r.squared
f_stat <- summary(fit.multi)$fstatistic
f_pval <- pf(f_stat[1], f_stat[2], f_stat[3], lower.tail = FALSE)

cat("Adjusted R2:", round(adj_r2, 4), "\n")
```

```
## Adjusted R2: 0.2315
```

```
cat("F-statistika:", round(f_stat[1], 2), "\n")
```

```
## F-statistika: 9.59
```

```
cat(sprintf("p-vrijednost: %.4e\n\n", f_pval))
```

```
## p-vrijednost: 3.1573e-25
```

```
coef_summary <- summary(fit.multi)$coefficients
significant_coefs <- sum(coef_summary[, 4] < 0.05, na.rm = TRUE)
total_coefs <- nrow(coef_summary)
```

```
cat("Broj značajnih koeficijenata (p < 0.05):", significant_coefs, "od", total_coefs, "\n")
```

```
## Broj značajnih koeficijenata (p < 0.05): 9 od 21
```

F-test pokazuje da je model statistički značajan i pruža bolju predikciju od nul-modela.

3.10 Predikcija srednje vrijednosti

Koristimo procijenjeni model za predikciju IMDb ocjene za “prosječan” film.

```
new_data <- data.frame(
  Year.of.Release = median(oscars_clean$Year.of.Release, na.rm = TRUE),
  Movie.Time = median(oscars_clean$Movie.Time, na.rm = TRUE)
)
```

```
# Dodavanje dummy varijabli (sve na 0 za referentne kategorije)
for (col in c(genre_cols, rating_cols)) {
  new_data[[col]] <- 0
}
```

```
pred_mean <- predict(fit.multi, newdata = new_data,
  interval = "confidence", level = 0.95)
```

```
cat("Predikcija IMDb ocjene za prosječan film:\n")
```

```
## Predikcija IMDb ocjene za prosječan film:
```

```
cat("Godina izlaska:", new_data$Year.of.Release, "\n")
```

```
## Godina izlaska: 1972
```

```
cat("Trajanje:", new_data$Movie.Time, "minuta\n")
```

```
## Trajanje: 121 minuta
```

```
cat("Referentni žanr i rating\n\n")
```

```
## Referentni žanr i rating
```

```
cat("Predviđena ocjena:", round(pred_mean[1], 3), "\n")
```

```
## Predviđena ocjena: 7.363
```

```
cat("95% interval pouzdanosti: [",  
    round(pred_mean[2], 3), ",", round(pred_mean[3], 3), "]\n")
```


```
## 95% interval pouzdanosti: [ 7.181 , 7.545 ]
```

Interval pouzdanosti od 95% znači da smo 95% uvjereni da će se prava srednja vrijednost IMDb ocjene za filmove s ovim karakteristikama nalaziti unutar navedenog intervala.

3.11 Analiza reziduala

Prije donošenja konačnih zaključaka o modelu, potrebno je provjeriti pretpostavke linearne regresije analizom reziduala.

```
par(mfrow = c(2, 2))  
  
plot(fit.multi$fitted.values, fit.multi$residuals,  
     main = "Fitted vs Residuals",  
     xlab = "Fitted vrijednosti (predviđene ocjene)",  
     ylab = "Reziduali",  
     pch = 19, col = rgb(0, 0, 1, 0.5))  
abline(h = 0, col = "red", lwd = 2, lty = 2)  
  
# 2. Histogram reziduala  
hist(rstandard(fit.multi), breaks = 25,  
     main = "Histogram standardiziranih reziduala",  
     xlab = "Standardizirani reziduali",  
     ylab = "Frekvencija",  
     col = "lightblue")  
  
# 3. Q-Q plot  
qqnorm(rstandard(fit.multi),  
       main = "Q-Q dijagram standardiziranih reziduala",  
       xlab = "Teorijski kvantili",  
       ylab = "Standardizirani reziduali")  
qqline(rstandard(fit.multi), col = "red", lwd = 2)  
  
# 4. Scale-Location  
plot(fit.multi$fitted.values, sqrt(abs(rstandard(fit.multi))),  
     main = "Scale-Location",  
     xlab = "Fitted vrijednosti",  
     ylab = "√|Standardizirani reziduali|",  
     pch = 19, col = rgb(0, 0, 1, 0.5))
```



```
par(mfrow = c(1, 1))
```

Q-Q plot pokazuje da reziduali uglavnom prate dijagonalnu liniju, s blagim odstupanjima na krajevima, što sugerira da pretpostavka normalnosti nije značajno narušena.

3.12 Test normalnosti reziduala

Provjerimo sada normalnost reziduala Lillieforsovom inačicom Kolmogorov-Smirnovljevog testa na razini značajnosti od 5% uz sljedeće hipoteze:

H0: Reziduali su normalno distribuirani H1: Reziduali nisu normalno distribuirani.

```
nortest::lillie.test(rstandard(fit.multi))
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  rstandard(fit.multi)
## D = 0.025402, p-value = 0.5007
```

Testna statistika pokazuje p-vrijednost. Ako je p-vrijednost veća od 0.05, test nije statistički značajan te nemamo dovoljno dokaza za odbacivanje nul-hipoteze. Reziduali se mogu smatrati normalno distribuiranima.

3.13 Bootstrap analiza

Bootstrap se koristi radi **robusnosti procjena**. Omogućuje procjenu intervala pouzdanosti bez striktnih pretpostavki o distribuciji podataka, što je posebno korisno kada pretpostavke normalnosti mogu biti narušene.

```
set.seed(42)

formula_string <- paste("IMDB.Rating ~", paste(all_predictors, collapse = " + "))

bootstrap_lm <- function(data, indices) {
  d <- data[indices, ]
  fit <- lm(as.formula(formula_string), data = d)
  return(coef(fit))
}

# Bootstrap s 1000 iteracija

boot_results <- boot::boot(data = oscars_model,
                          statistic = bootstrap_lm,
                          R = 1000)
```

3.14 Bootstrap intervali pouzdanosti

Bootstrap intervali pouzdanosti za sve koeficijente modela:

```
coef_names <- names(coef(fit.multi))
bootstrap_intervals <- data.frame(
  Koeficijent = coef_names,
  Procjena = round(coef(fit.multi), 4),
  OLS_SE = round(summary(fit.multi)$coefficients[, "Std. Error"], 4),
  Boot_SE = round(apply(boot_results$t, 2, sd, na.rm = TRUE), 4),
  Boot_Lower = numeric(length(coef_names)),
  Boot_Upper = numeric(length(coef_names)),
  stringsAsFactors = FALSE
)

for (i in 1:length(coef_names)) {
  tryCatch({
    boot_ci <- boot::boot.ci(boot_results, type = "perc", index = i)
    if (!is.null(boot_ci$percent)) {
      bootstrap_intervals$Boot_Lower[i] <- round(boot_ci$percent[4], 4)
      bootstrap_intervals$Boot_Upper[i] <- round(boot_ci$percent[5], 4)
    }
  }, error = function(e) {
    bootstrap_intervals$Boot_Lower[i] <- NA
    bootstrap_intervals$Boot_Upper[i] <- NA
  })
}
```



```
print(bootstrap_intervals)
```

##		Koeficijent	Procjena	OLS_SE	Boot_SE	Boot_Lower
##	(Intercept)	(Intercept)	3.1592	2.3171	2.3583	-1.3825
##	Year.of.Release	Year.of.Release	0.0018	0.0012	0.0012	-0.0005
##	Movie.Time	Movie.Time	0.0052	0.0009	0.0009	0.0035
##	Main.Genre_Adventure	Main.Genre_Adventure	-0.0381	0.1091	0.1245	-0.2940
##	Main.Genre_Animation	Main.Genre_Animation	0.7458	0.3056	0.1396	0.4712
##	Main.Genre_Biography	Main.Genre_Biography	-0.0765	0.0927	0.1029	-0.2888
##	Main.Genre_Comedy	Main.Genre_Comedy	0.0081	0.0944	0.1073	-0.2274
##	Main.Genre_Crime	Main.Genre_Crime	0.2992	0.1078	0.1243	0.0477
##	Main.Genre_Drama	Main.Genre_Drama	0.0025	0.0863	0.0994	-0.2048
##	Main.Genre_Family	Main.Genre_Family	0.4499	0.5000	0.1127	0.2255
##	Main.Genre_Film.Noir	Main.Genre_Film.Noir	0.1690	0.3578	0.1211	-0.0822
##	Main.Genre_Horror	Main.Genre_Horror	0.1870	0.2954	0.1231	-0.0432
##	Main.Genre_Music	Main.Genre_Music	-1.4016	0.5005	0.1156	-1.6366
##	Main.Genre_Musical	Main.Genre_Musical	-0.9307	0.3599	0.4091	-1.6057
##	Main.Genre_Romance	Main.Genre_Romance	-0.3944	0.5007	0.1181	-0.6259
##	Main.Genre_Western	Main.Genre_Western	-1.0623	0.3575	0.4788	-1.8324
##	Content.Rating_G	Content.Rating_G	0.0305	0.0877	0.0956	-0.1532
##	Content.Rating_NR	Content.Rating_NR	0.1074	0.0687	0.0767	-0.0519
##	Content.Rating_PG	Content.Rating_PG	0.2585	0.0750	0.0764	0.1081
##	Content.Rating_PG.13	Content.Rating_PG.13	0.2916	0.0939	0.0856	0.1212
##	Content.Rating_R	Content.Rating_R	0.3063	0.0805	0.0802	0.1428
##		Boot_Upper				
##	(Intercept)	7.6535				
##	Year.of.Release	0.0042				
##	Movie.Time	0.0068				
##	Main.Genre_Adventure	0.1972				
##	Main.Genre_Animation	1.0122				
##	Main.Genre_Biography	0.1237				
##	Main.Genre_Comedy	0.2164				
##	Main.Genre_Crime	0.5562				
##	Main.Genre_Drama	0.2061				
##	Main.Genre_Family	0.6659				
##	Main.Genre_Film.Noir	0.4045				
##	Main.Genre_Horror	0.4380				
##	Main.Genre_Music	-1.1930				
##	Main.Genre_Musical	-0.2553				
##	Main.Genre_Romance	-0.1740				
##	Main.Genre_Western	-0.2767				
##	Content.Rating_G	0.2222				
##	Content.Rating_NR	0.2645				
##	Content.Rating_PG	0.4174				
##	Content.Rating_PG.13	0.4558				
##	Content.Rating_R	0.4580				

Bootstrap standardne pogreške (Boot_SE) omogućuju usporedbu s klasičnim OLS standardnim pogreškama. Sličnost ovih vrijednosti potvrđuje robusnost procjena.

3.15 Vizualizacija Bootstrap distribucija


```
par(mfrow = c(2, 2))

# Bootstrap za Year.of.Release
if (ncol(boot_results$t) >= 2) {
  hist(boot_results$t[, 2], breaks = 30,
       main = "Bootstrap: Year.of.Release",
       xlab = "Koeficijent",
       col = "lightblue",
       border = "white")
  abline(v = coef(fit.multi)[2], col = "red", lwd = 2)
  abline(v = quantile(boot_results$t[, 2], c(0.025, 0.975), na.rm = TRUE),
        col = "darkred", lwd = 2, lty = 2)
}

# Bootstrap za Movie.Time
if (ncol(boot_results$t) >= 3) {
  hist(boot_results$t[, 3], breaks = 30,
       main = "Bootstrap: Movie.Time",
       xlab = "Koeficijent",
       col = "lightgreen",
       border = "white")
  abline(v = coef(fit.multi)[3], col = "red", lwd = 2)
  abline(v = quantile(boot_results$t[, 3], c(0.025, 0.975), na.rm = TRUE),
        col = "darkred", lwd = 2, lty = 2)
}

# Bootstrap za Intercept
hist(boot_results$t[, 1], breaks = 30,
     main = "Bootstrap: Intercept",
     xlab = "Koeficijent",
     col = "lightyellow",
     border = "white")
abline(v = coef(fit.multi)[1], col = "red", lwd = 2)
abline(v = quantile(boot_results$t[, 1], c(0.025, 0.975), na.rm = TRUE),
      col = "darkred", lwd = 2, lty = 2)

par(mfrow = c(1, 1))
```



Crvena linija označava procjenu koeficijenta iz originalnog modela, dok isprekidane linije označavaju 95% bootstrap interval pouzdanosti.

3.16 Zaključak

Model višestruke linearne regresije koristi godinu izlaska filma, trajanje filma, žanr i content rating za predikciju IMDb ocjene nominiranih filmova za Oscara.

Adjusted R^2 iznosi 0.2315, što znači da model objašnjava 23.15% varijance u IMDb ocjenama. F-test pokazuje da je model statistički značajan ($p < 0.001$), što znači da korištene značajke imaju prediktivnu moć.

9 od 21 koeficijenata su statistički značajni na razini značajnosti od 5%, što ukazuje na to da većina varijabli uključenih u model ima značajan doprinos predikciji ocjene.

Bootstrap analiza korištena je radi robusnosti procjena. Bootstrap intervali pouzdanosti potvrđuju stabilnost procjena koeficijenata i omogućuju zaključivanje bez striktnih pretpostavki o normalnosti podataka.

Iako model objašnjava značajan dio varijabilnosti, preostala neobjašnjena varijanca ukazuje na to da postoje i drugi faktori (kvaliteta režije, gluma, priča) koji utječu na ocjene, a nisu uključeni u ovaj model.

4 Istraživanje povezanosti između starosti filma i njegove ocjene

```
oscars <- read.csv2("oscars_dataset.csv")
```

4.1 Opis problema

Jedno od pitanja koje razmatramo jest kako su filmovi ocijenjeni s obzirom na svoju starost, odnosno kako godina izlaska filma utječe na njegovu ocjenu. Cilj je dobiti uvid u trend promjene ocjena kroz godine i provjeriti jesu li godina izlaska i ocjena međusobno značajno korelirani.

4.2 Priprema podataka za analizu

Najprije moramo odabrati koje ocjene ćemo koristiti za analizu. Pogledajmo kojih podataka ima najviše odnosno nedostaju li neki podaci:

```
data.frame(Ocjena = c("IMDb", "Rotten Tomatoes", "Audience"),
           Broj_vrijednosti = c(sum(oscars$IMDB.Rating != ""),
                                sum(oscars$Tomatometer.Rating != ""),
                                sum(oscars$Audience.Rating != "")))
```

```
##           Ocjena Broj_vrijednosti
## 1           IMDb             571
## 2 Rotten Tomatoes             459
## 3           Audience             459
```

Primjećujemo da postoje neki nedostaci, stoga ćemo za daljnja promatranja koristiti podatke o IMDb ocjenama.

Kako bi podaci bili spremni za daljnu analizu, potrebno je osigurati da je njihov tip numeric.


```
oscars$IMDB.Rating <- as.numeric(as.character(oscars$IMDB.Rating))
oscars$Year.of.Release <- as.numeric(as.character(oscars$Year.of.Release))
```

4.3 Vizualizacija podataka

Analizirajmo sada povezanost između godine izlaska filma i njegove ocjene. Budući da promatramo utjecaj jedne numeričke varijable (godina izlaska) na drugu numeričku varijablu (ocjena), osnovni uvid u njihov odnos dobiva se grafičkim prikazom pomoću scatter plot. Takav prikaz omogućuje uočavanje općeg trenda i eventualne nelinearnosti.

```
plot(oscars$Year.of.Release, oscars$IMDB.Rating,
     main = "Odnos godine izlaska filma i IMDb ocjene",
     xlab = "Godina izlaska filma",
     ylab = "IMDb ocjena")
```


Odnos godine izlaska filma i IMDb ocjene



Scatter plot ne pokazuje jasno povećanje ocjena s godinama izlaska zbog raspršenosti podataka i prisutnosti outliera. Kako bismo bolje sagledali trend, možemo grupirati filmove po desetljećima i prikazati ocjene pomoću box plot, što omogućuje uočavanje promjena u medijanu i rasponu ocjena kroz vrijeme.

```
oscars$desetljece <- floor(oscars$Year.of.Release / 10) * 10
boxplot(IMDB.Rating ~ desetljece, data = oscars,
        main = "Distribucija IMDb ocjena po desetljećima",
        xlab = "Desetljeće izlaska filma",
        ylab = "IMDb ocjena")
```

Distribucija IMDb ocjena po desetljećima




Iz scatter plotu i box plotu može se naslutiti da postoji određena povezanost između godine izlaska filma i

njegove ocjene, no ona se ne čini velikom.

4.4 Linearna regresija

Kako bismo procijenili jačinu promatranog odnosa, izrađujemo jednostavnu linearnu regresiju s ocjenom filma kao zavisnom varijablom i godinom izlaska kao nezavisnom varijablom.

```
fit.year <- lm(IMDB.Rating ~ Year.of.Release, data = oscars)
plot(oscars$Year.of.Release, oscars$IMDB.Rating,
     main = "Linearna regresija IMDb ocjene ~ godina izlaska",
     xlab = "Godina izlaska filma",
     ylab = "IMDb ocjena")
lines(oscars$Year.of.Release, fit.year$fitted.values, col = "blue")
```




Dobiveni regresijski model pokazuje mali pozitivan nagib, što znači da noviji filmovi u prosjeku imaju nešto više ocjene, no efekt je slab. Kako bismo potvrdili valjanost ovakvog zaključka, potrebno je provjeriti temeljne pretpostavke linearne regresije, prvenstveno normalnost distribucije reziduala (i homogenost njihove varijance).

4.5 Analiza reziduala

Za vizualnu provjeru pretpostavke normalnosti reziduala koristimo histogram, koji omogućuje uvid u raspodjelu pogrešaka. Potpunu potvrdu normalnosti provjerit ćemo kasnije odgovarajućim statističkim testovima.

```
selected.model <- fit.year
hist(selected.model$residuals, breaks = 15,
     main = "Histogram reziduala linearnog regresijskog modela",
     xlab = "Reziduali modela",
     ylab = "Frekvencija")
```

Histogram reziduala linearnog regresijskog modela




4.6 Q-Q graf

Normalnost reziduala egzaktnije možemo provjeriti Q-Q plotom kako bismo utvrdili da pogreške modela približno slijede normalnu distribuciju, što je pretpostavka za valjanost statističkih testova koeficijenata i intervala pouzdanosti.

```
qqnorm(rstandard(selected.model),  
      main = "Q-Q dijagram standardiziranih reziduala",  
      xlab = "Teorijski kvantili normalne razdiobe",  
      ylab = "Standardizirani reziduali")  
qqline(rstandard(selected.model))
```

Q–Q dijagram standardiziranih reziduala



Q-Q graf pokazuje da reziduali uglavnom prate dijagonalnu liniju, s blagim odstupanjima na krajevima, što sugerira da pretpostavka normalnosti nije značajno narušena.

4.7 Testiranje Lillieforsovom inačicom

Provjerimo sada normalnost reziduala Lillieforsovom inačicom Kolmogorov-Smirnovljeva testa na razini značajnosti od 5% uz sljedeće hipoteze:

H0: Reziduali su normalno distribuirani

H1: Reziduali nisu normalno distribuirani.

```
lillie.test(rstandard(fit.year))
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  rstandard(fit.year)
## D = 0.026192, p-value = 0.4463
```

Testna statistika pokazuje vrlo visoku p-vrijednost. Budući da je ona veća od 0.05, test nije statistički značajan te nemamo dovoljno dokaza za odbacivanje nul-hipoteze. Reziduali se mogu smatrati normalno distribuiranima.

4.8 Pearsonov koeficijent korelacije

Kao završni korak analize, računamo Pearsonov koeficijent korelacije i provodimo test kako bismo statistički evaluirali odnos između godine nastanka filma i njegove IMDb ocjene. Test provodimo na razini značajnosti od 5% uz hipoteze:

H0: Ne postoji linearna povezanost između godine izlaska filma i IMDb ocjene.

H1: Postoji linearna povezanost između godine izlaska filma i IMDb ocjene.


```
cor.test(oscars$Year.of.Release,oscars$IMDB.Rating)
```

```
##  
## Pearson's product-moment correlation  
##  
## data:  oscars$Year.of.Release and oscars$IMDB.Rating  
## t = 8.3363, df = 569, p-value = 5.783e-16  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
##  0.2547525 0.4011050  
## sample estimates:  
##      cor  
## 0.3299097
```

Koeficijent korelacije r iznosi 0,33 što ukazuje na umjerenu pozitivnu korelaciju dviju varijabli. P-vrijednost je vrlo mala, manja od 0,05. S obzirom na to, odbacujemo hipotezu H_0 te je pozitivna povezanost statistički značajna. 95-postotni interval pouzdanosti je cijelim dijelom pozitivan što je još jedan indikator da pozitivna povezanost postoji.

Na temelju početnih deskriptivnih statistika opravdano bi bilo zaključiti i da stvarna korelacija između varijabli ne postoji te da je uočeni pozitivan trend posljedica šuma. Međutim, provedena statistička analiza i testovi pokazuju da je povezanost statistički značajna, a zbog velikog uzorka takav je zaključak opravdan.

5 Analiza predviđanja pobjednika (Ivan)

5.1 Opis problema

U ovoj analizi istražiti ćemo **Možemo li pomoću dostupnih značajki pouzdano razlikovati pobjednike od ostalih?** na temelju dostupnih značajki. Za razliku od prethodnih analiza koje su se fokusirale na razlike između grupa, ova analiza koristi **logističku regresiju** kako bi modelirala vjerojatnost pobjede filma.

Cilj je utvrditi:

1. Koje značajke predviđaju pobjedu na Oscarima?
2. Koliko dobro možemo klasificirati pobjednike pomoću tih značajki?
3. Postoji li kombinacija varijabli koja omogućava pouzdanu predikciju?

Za analizu koristimo sljedeće prediktore:

- **IMDB Rating** - ocjena na IMDB platformi
- **IMDB Votes** - broj glasova korisnika (log transformacija)
- **Runtime** - trajanje filma u minutama
- **Year** - godina izlaska filma
- **Genre** - žanr filma (grupirani rijetki žanrovi)

5.2 Analiza podataka

5.2.1 Priprema podataka za logističku regresiju

Prvo učitavamo podatke i kreiramo potrebne varijable.

```
data <- read.csv("oscars_dataset.csv", sep=";")

# Kreiranje binarne varijable ishoda
# IsWinner = 1 (pobjednik), IsWinner = 0 (nominiran bez pobjede)
data$IsWinner <- ifelse(data$Award == "Winner", 1, 0)

# Čišćenje i pretvaranje varijabli
data$Rating <- as.numeric(data$IMDB.Rating)
data$Votes <- as.numeric(gsub(",", "", data$IMDB.Votes))
data$Runtime <- as.numeric(data$Movie.Time)
data$Year <- as.numeric(data$Year.of.Release)

# Grupiranje rijetkih žanrova
common_genres <- c("Action", "Adventure", "Biography",
                  "Comedy", "Crime", "Drama")
data$GenreGroup <- ifelse(data$Main.Genre %in% common_genres,
                        data$Main.Genre, "Other")
data$GenreGroup <- factor(data$GenreGroup,
                        levels = c("Drama", "Action", "Adventure",
                                   "Biography", "Comedy", "Crime", "Other"))
```

5.2.2 Finalni dataset za modeliranje

```

model_data <- data %>%
  dplyr::select(IsWinner, Rating, Votes, Runtime, Year, GenreGroup) %>%
  na.omit()

cat("Broj filmova u analizi:", nrow(model_data), "\n")

## Broj filmova u analizi: 571

cat("Broj pobjednika:", sum(model_data$IsWinner), "\n")

## Broj pobjednika: 94

cat("Broj nominiranih (bez pobjede):", sum(model_data$IsWinner == 0), "\n")

## Broj nominiranih (bez pobjede): 477

```

Nakon čišćenja podataka imamo **571 filmova**, od kojih je **94 (16.5%)** pobjednika. Omjer pobjednika i nominiranih je približno **1:5**, što predstavlja klasičan problem **neuravnoteženih klasa**.

5.2.3 Eksplorativna analiza

5.2.3.1 Usporedba IMDB ocjena Testiramo razlikuju li se pobjednici i nominirani po IMDB ocjeni koristeći **t-test**

```

cat("Pobjednici - Mean:",
    mean(model_data$Rating[model_data$IsWinner == 1]), "\n")

## Pobjednici - Mean: 7.779787

cat("Nominirani - Mean:",
    mean(model_data$Rating[model_data$IsWinner == 0]), "\n")


## Nominirani - Mean: 7.52914

t_rating <- t.test(Rating ~ IsWinner, data = model_data)
print(t_rating)

##
## Welch Two Sample t-test
##
## data: Rating by IsWinner
## t = -3.573, df = 120.07, p-value = 0.0005091
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
## -0.3895394 -0.1117541
## sample estimates:
## mean in group 0 mean in group 1
## 7.529140 7.779787

```

```
ggplot(model_data, aes(x = factor(IsWinner, labels = c("Nominee", "Winner")),
                      y = Rating, fill = factor(IsWinner))) +
  geom_boxplot(alpha = 0.7) +
  scale_fill_manual(values = c("0" = "#a6cee3", "1" = "#1f78b4")) +
  theme_minimal(base_size = 14) +
  labs(title = "IMDB ocjena: Pobjednici vs Nominirani",
       x = "", y = "IMDB Rating") +
  theme(legend.position = "none")
```



5.2.3.2 Usporedba broja glasova Zbog jako skewed distribucije koristimo **Wilcoxonov test**

```
cat("Pobjednici - Median votes:",
    median(model_data$Votes[model_data$IsWinner == 1]), "\n")
```

```
## Pobjednici - Median votes: 177533.5
```

```
cat("Nominirani - Median votes:",
    median(model_data$Votes[model_data$IsWinner == 0]), "\n")
```


```
## Nominirani - Median votes: 41582
```

```
wilcox_votes <- wilcox.test(Votes ~ IsWinner, data = model_data)
print(wilcox_votes)
```

```
##
```

```
## Wilcoxon rank sum test with continuity correction
##
## data: Votes by IsWinner
## W = 14434, p-value = 4.71e-08
## alternative hypothesis: true location shift is not equal to 0
```

```
ggplot(model_data, aes(x = factor(IsWinner, labels = c("Nominee", "Winner")),
                        y = Votes, fill = factor(IsWinner))) +
  geom_boxplot(alpha = 0.7) +
  scale_y_log10(labels = comma) +
  scale_fill_manual(values = c("0" = "#a6cee3", "1" = "#1f78b4")) +
  theme_minimal(base_size = 14) +
  labs(title = "Broj glasova (log skala): Pobjednici vs Nominirani",
       x = "", y = "IMDB Votes (log10)") +
  theme(legend.position = "none")
```



```
cat("Pobjednici - Mean runtime:",
    mean(model_data$Runtime[model_data$IsWinner == 1]), "\n")
```

5.2.3.3 Usporedba duljine filma

```
## Pobjednici - Mean runtime: 138.266
```

```
cat("Nominirani - Mean runtime:",
    mean(model_data$Runtime[model_data$IsWinner == 0]), "\n")
```

```
## Nominirani - Mean runtime: 122.26
```

```
t_runtime <- t.test(Runtime ~ IsWinner, data = model_data)
print(t_runtime)
```

```
##
## Welch Two Sample t-test
##
## data: Runtime by IsWinner
## t = -4.6816, df = 116.26, p-value = 7.767e-06
## alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
## 95 percent confidence interval:
## -22.777405 -9.234594
## sample estimates:
## mean in group 0 mean in group 1
##      122.260      138.266
```

5.2.3.4 Distribucija po žanrovima Koristimo Chi-squared test nezavisnosti

```
genre_winner_table <- table(model_data$GenreGroup, model_data$IsWinner)
addmargins(genre_winner_table)
```

```
##
##      0  1 Sum
## Drama  173  42 215
## Action   36   3  39
## Adventure 36   9  45
## Biography 83  18 101
## Comedy   95  13 108
## Crime    39   9  48
## Other    15   0  15
## Sum     477  94 571
```


```
chisq_genre <- chisq.test(genre_winner_table)
print(chisq_genre)
```

```
##
## Pearson's Chi-squared test
##
## data: genre_winner_table
## X-squared = 8.8789, df = 6, p-value = 0.1805
```

Vizualizacija distribucije po žanrovima:

```
genre_plot_data <- model_data %>%
  group_by(GenreGroup, IsWinner) %>%
  summarise(Count = n(), .groups = "drop") %>%
  mutate(Outcome = ifelse(IsWinner == 1, "Winner", "Nominee"))

ggplot(genre_plot_data, aes(x = GenreGroup, y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "dodge", color = "black") +
  scale_fill_manual(values = c("Winner" = "#1f78b4", "Nominee" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Distribucija pobjednika i nominiranih po žanrovima",
       x = "Žanr", y = "Broj filmova", fill = "") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



5.3 Logistička regresija

Koristimo logističku regresiju za modeliranje binarne zavisne varijable (IsWinner)

5.3.1 Model 1: Samo IMDB Rating

```
model1 <- glm(IsWinner ~ Rating,
              data = model_data,
              family = binomial(link = "logit"))

summary(model1)
```

##

```
## Call:
## glm(formula = IsWinner ~ Rating, family = binomial(link = "logit"),
##      data = model_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -8.3611      1.7364  -4.815 1.47e-06 ***
## Rating         0.8798      0.2240   3.928 8.55e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 494.05  on 569  degrees of freedom
## AIC: 498.05
##
## Number of Fisher Scoring iterations: 4
```

```
null_model <- glm(IsWinner ~ 1, data = model_data, family = binomial)
ll_null <- logLik(null_model)
ll_model1 <- logLik(model1)
mcfadden_r2_m1 <- 1 - (ll_model1 / ll_null)

cat("McFadden's Pseudo R²:", round(as.numeric(mcfadden_r2_m1), 4), "\n")
```

5.3.1.1 McFadden's Pseudo R²

```
## McFadden's Pseudo R²: 0.0327
```

5.3.2 Model 2: Svi prediktori

```
model2 <- glm(IsWinner ~ Rating + log10(Votes) + Runtime + Year + GenreGroup,
              data = model_data,
              family = binomial(link = "logit"))

summary(model2)
```

```
##
## Call:
## glm(formula = IsWinner ~ Rating + log10(Votes) + Runtime + Year +
##      GenreGroup, family = binomial(link = "logit"), data = model_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    115.210770  17.700672   6.509 7.57e-11 ***
## Rating         -1.770832   0.397811  -4.451 8.53e-06 ***
## log10(Votes)     3.264831   0.447109   7.302 2.83e-13 ***
## Runtime          0.016514   0.005086   3.247 0.00117 **
```



```
## Year                -0.061292    0.008938   -6.857 7.02e-12 ***
## GenreGroupAction    -1.784374    0.664404   -2.686 0.00724 **
## GenreGroupAdventure -0.673262    0.494484   -1.362 0.17334
## GenreGroupBiography -0.022287    0.358982   -0.062 0.95050
## GenreGroupComedy     -0.513873    0.385988   -1.331 0.18308
## GenreGroupCrime      -0.823464    0.481372   -1.711 0.08714 .
## GenreGroupOther      -15.483637  573.192070   -0.027 0.97845
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 392.00  on 560  degrees of freedom
## AIC: 414
##
## Number of Fisher Scoring iterations: 15
```

```
ll_model2 <- logLik(model2)
mcfadden_r2_m2 <- 1 - (ll_model2 / ll_null)

cat("McFadden's Pseudo R2:", round(as.numeric(mcfadden_r2_m2), 4), "\n")
```

5.3.2.1 McFadden's Pseudo R²

```
## McFadden's Pseudo R2: 0.2325
```

5.4 Test omjera vjerodostojnosti (LR test)

Koristimo LR test za usporedbu modela

5.4.1 LR test: Model 2 vs Null model

```
LR_full <- -2 * (as.numeric(ll_null) - as.numeric(ll_model2))
df_full <- length(coef(model2)) - 1
p_value_full <- pchisq(LR_full, df = df_full, lower.tail = FALSE)

cat("H0: Svi regresori su redundantni\n")
```

```
## H0: Svi regresori su redundantni
```

```
cat("H1: Barem jedan regresor nije redundantan\n\n")
```

```
## H1: Barem jedan regresor nije redundantan
```

```
cat("LR statistika:", round(LR_full, 2), "\n")
```

```
## LR statistika: 118.76
```

```
cat("Stupnjevi slobode:", df_full, "\n")
```

```
## Stupnjevi slobode: 10
```

```
cat("p-vrijednost:", format.pval(p_value_full, digits = 3), "\n")
```

```
## p-vrijednost: <2e-16
```

5.4.2 LR test: Model 2 vs Model 1

```
LR_comparison <- -2 * (as.numeric(ll_model1) - as.numeric(ll_model2))
df_comparison <- length(coef(model2)) - length(coef(model1))
p_value_comparison <- pchisq(LR_comparison, df = df_comparison, lower.tail = FALSE)

cat("LR statistika:", round(LR_comparison, 2), "\n")
```

```
## LR statistika: 102.05
```

```
cat("Stupnjevi slobode:", df_comparison, "\n")
```

```
## Stupnjevi slobode: 9
```

```
cat("p-vrijednost:", format.pval(p_value_comparison, digits = 3), "\n")
```

```
## p-vrijednost: <2e-16
```

5.5 Odds Ratios - Tumačenje koeficijenata

Interpretiramo koeficijente kroz Odds Ratios

```
odds_ratios <- exp(coef(model2))
conf_int <- exp(confint(model2, quiet = TRUE))
```

```
## Waiting for profiling to be done...
```

```
odds_table <- data.frame(
  Predictor = names(odds_ratios),
  OddsRatio = odds_ratios,
  CI_Lower = conf_int[, 1],
  CI_Upper = conf_int[, 2]
)
rownames(odds_table) <- NULL
print(odds_table, digits = 3)
```

##	Predictor	OddsRatio	CI_Lower	CI_Upper
## 1	(Intercept)	1.08e+50	3.07e+35	5.26e+65
## 2	Rating	1.70e-01	7.62e-02	3.65e-01
## 3	log10(Votes)	2.62e+01	1.13e+01	6.57e+01
## 4	Runtime	1.02e+00	1.01e+00	1.03e+00
## 5	Year	9.41e-01	9.24e-01	9.57e-01
## 6	GenreGroupAction	1.68e-01	3.70e-02	5.42e-01
## 7	GenreGroupAdventure	5.10e-01	1.83e-01	1.29e+00
## 8	GenreGroupBiography	9.78e-01	4.77e-01	1.96e+00
## 9	GenreGroupComedy	5.98e-01	2.73e-01	1.25e+00
## 10	GenreGroupCrime	4.39e-01	1.63e-01	1.09e+00
## 11	GenreGroupOther	1.89e-07	NA	2.54e+09


Interpretacija Odds Ratios:

- **OR > 1:** Povećanje regresora povećava šanse za pobjedu
- **OR < 1:** Povećanje regresora smanjuje šanse za pobjedu
- **OR = 1:** Regresor nema utjecaj

```
odds_plot_data <- odds_table[-1, ]

ggplot(odds_plot_data, aes(x = OddsRatio, y = reorder(Predictor, OddsRatio))) +
  geom_point(size = 4, color = "#1f78b4") +
  geom_errorbarh(aes(xmin = CI_Lower, xmax = CI_Upper), height = 0.2) +
  geom_vline(xintercept = 1, linetype = "dashed", color = "red") +
  theme_minimal(base_size = 14) +
  labs(title = "Odds Ratios za Model 2",
       subtitle = "Crvena linija = neutralan efekt (OR = 1)",
       x = "Odds Ratio (log skala)",
       y = "Prediktor") +
  scale_x_log10()
```

`height` was translated to `width`.



5.6 Predikcija i Confusion Matrix

5.6.1 Izračun predikcija

```
predicted_probs <- predict(model2, type = "response")
```

```
# Threshold postavljen na proporciju pobjednika u uzorku
threshold <- sum(model_data$IsWinner) / nrow(model_data)
cat("Odabrani threshold:", round(threshold, 3), "\n")
```

```
## Odabrani threshold: 0.165
```

```
predicted_class <- ifelse(predicted_probs >= threshold, 1, 0)
```

```
conf_matrix <- table(Predicted = predicted_class, Actual = model_data$IsWinner)
print(conf_matrix)
```

```
##           Actual
## Predicted    0    1
##           0 353  21
##           1 124  73
```

5.6.2 Metrike performansi

```

TP <- conf_matrix[2, 2] # True Positive
TN <- conf_matrix[1, 1] # True Negative
FP <- conf_matrix[2, 1] # False Positive
FN <- conf_matrix[1, 2] # False Negative

accuracy <- (TP + TN) / sum(conf_matrix)
precision <- TP / (TP + FP)
recall <- TP / (TP + FN)
f1 <- 2 * (precision * recall) / (precision + recall)

cat("Accuracy: ", round(accuracy, 4),
    " - postotak točnih predikcija\n")

```

```
## Accuracy: 0.7461 - postotak točnih predikcija
```

```

cat("Precision: ", round(precision, 4),
    " - od predviđenih pobjednika, koliko je stvarno pobijedilo\n")

```

```
## Precision: 0.3706 - od predviđenih pobjednika, koliko je stvarno pobijedilo
```

```

cat("Recall: ", round(recall, 4),
    " - koliko stvarnih pobjednika uspijemo detektirati\n")

```

```
## Recall: 0.7766 - koliko stvarnih pobjednika uspijemo detektirati
```

```

cat("F1 Score: ", round(f1, 4),
    " - harmonijska sredina precision i recall\n")

```

```
## F1 Score: 0.5017 - harmonijska sredina precision i recall
```

5.6.3 Vizualizacija Confusion Matrix


```

conf_df <- as.data.frame(conf_matrix)
colnames(conf_df) <- c("Predicted", "Actual", "Freq")

ggplot(conf_df, aes(x = Actual, y = Predicted, fill = Freq)) +
  geom_tile(color = "white", linewidth = 1) +
  geom_text(aes(label = Freq), size = 10, color = "white") +
  scale_fill_gradient(low = "#a6cee3", high = "#1f78b4") +
  theme_minimal(base_size = 14) +
  labs(title = "Confusion Matrix (Model 2)",
       x = "Stvarni ishod (0=Nominee, 1=Winner)",
       y = "Predviđeni ishod") +
  theme(legend.position = "none")

```


Confusion Matrix (Model 2)



5.6.4 Distribucija predvidenih vjerojatnosti

```
pred_df <- data.frame(
  Probability = predicted_probs,
  Actual = factor(model_data$IsWinner,
    levels = c(0, 1),
    labels = c("Nominee", "Winner"))
)

ggplot(pred_df, aes(x = Probability, fill = Actual)) +
  geom_histogram(position = "identity", alpha = 0.6, bins = 30, color = "black") +
  geom_vline(xintercept = threshold, linetype = "dashed",
    color = "red", linewidth = 1) +
  scale_fill_manual(values = c("Nominee" = "#a6cee3", "Winner" = "#1f78b4")) +
  theme_minimal(base_size = 14) +
  labs(title = "Distribucija predvidenih vjerojatnosti",
    subtitle = paste0("Crvena linija = threshold (",
      round(threshold, 3), ")"),
    x = "Predviđena vjerojatnost pobjede",
    y = "Broj filmova",
    fill = "Stvarni ishod")
```



5.7 Zaključak

Na temelju rezultata logističke regresije i testova omjera vjerodostojnosti, možemo zaključiti sljedeće:

Odgovor na glavno pitanje: Možemo li pouzdano razlikovati pobjednike?

Djelomično DA, ali s ograničenjima.

Pozitivni nalazi:

1. Model ima statistički značajnu prediktivnu moć (McFadden $R^2 = 0.233$, LR test $p < 0.001$)
2. Broj glasova na IMDB-u je najjači prediktor pobjede
3. Model postiže 74.6% accuracy
4. 77.7% recall - detektiramo većinu stvarnih pobjednika

Ograničenja:

1. Precision je 37.1% - prisutno je puno lažnih pozitiva
2. Model objašnjava samo 23.3% varijance
3. 76.7% faktora ostaje neobjašnjeno (kvaliteta glume i režije, marketinška kampanja, politički i kulturni kontekst, subjektivni ukus Akademije)

Praktična primjena:

Model je koristan za screening - može identificirati filmove s niskim šansama, ali nije pouzdan za definitivnu predikciju pobjednika. Služi više kao dopunski alat uz druge analize.

Na temelju dostupnih podataka, možemo zaključiti da je pobjeda na Oscarima fenomen koji se ne može potpuno objasniti kvantitativnim mjerama - što potvrđuje kompleksnost i nepredvidivost umjetničkih nagrada.