

# Oscarovci

Tim #1

2025-11-06

## Contents

|          |                                                                                        |           |
|----------|----------------------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Opis skupa podataka</b>                                                             | <b>2</b>  |
| <b>2</b> | <b>Analiza žanrova kod pobjednika (Matija)</b>                                         | <b>4</b>  |
| 2.1      | Opis problema . . . . .                                                                | 4         |
| 2.2      | Single-label analiza . . . . .                                                         | 4         |
| 2.3      | Multi-label analiza . . . . .                                                          | 8         |
| 2.4      | Statističko testiranje . . . . .                                                       | 11        |
| 2.5      | Zaključak . . . . .                                                                    | 15        |
| <b>3</b> | <b>Analiza ocjena kroz godine (Roko)</b>                                               | <b>16</b> |
| <b>4</b> | <b>Možemo li naslutiti ocjenu na IMDb pomoću nekih parametara? (Roko)</b>              | <b>19</b> |
| <b>5</b> | <b>Istraživačko pitanje: Ocjene filmova i njihova starost (Damjan)</b>                 | <b>22</b> |
| <b>6</b> | <b>Možemo li pomoću dostupnih značajki pouzdano razlikovati pobjednike od ostalih?</b> | <b>30</b> |
| 6.1      | Priprema podataka za logističku regresiju . . . . .                                    | 30        |
| <b>7</b> | <b>Eksplorativna analiza - usporedba pobjednika i nominiranih</b>                      | <b>31</b> |

# 1 Opis skupa podataka

Skup podataka koji analiziramo u projektu sadrži 571 odgovor/redak.

```
#Prikaz varijabli u skupu podataka i njihovog podatkovnog tipa
```

```
data = read_csv2("oscars_dataset.csv")
```

```
## i Using '"','"' as decimal and "'.'" as grouping mark. Use `read_delim()` for more control.
```

```
## Rows: 571 Columns: 20
```

```
## -- Column specification -----
```

```
## Delimiter: ";"
```

```
## chr (11): Film, Oscar Year, Film Studio/Producer(s), Award, Movie Genre, Ma...
```

```
## dbl (3): Unnamed: 0, Year of Release, Movie Time
```

```
## num (5): IMDB Rating, Tomatometer Rating, Tomatometer Count, Audience Rati...
```

```
## date (1): Original Release Date
```

```
##
```

```
## i Use `spec()` to retrieve the full column specification for this data.
```

```
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
glimpse(data)
```

```
## Rows: 571
```

```
## Columns: 20
```

```
## $ `Unnamed: 0` <dbl> 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13~
```

```
## $ Film <chr> "Wings", "7th Heaven", "The Racket", "The Br~
```

```
## $ `Oscar Year` <chr> "1927/28", "1927/28", "1927/28", "1928/29", ~
```

```
## $ `Film Studio/Producer(s)` <chr> "Famous Players-Lasky", "Fox", "The Caddo Co~
```

```
## $ Award <chr> "Winner", "Nominee", "Nominee", "Winner", "N~
```

```
## $ `Year of Release` <dbl> 1927, 1927, 1928, 1929, 1929, 1929, 1928, 19~
```

```
## $ `Movie Time` <dbl> 144, 110, 84, 100, 91, 130, 95, 113, 152, 87~
```

```
## $ `Movie Genre` <chr> "Drama,Romance,War", "Drama,Romance", "Crime~
```

```
## $ `Main Genre` <chr> "Drama", "Drama", "Crime", "Drama", "Action"~
```

```
## $ Subgenre <chr> "Romance", "Romance", "Drama", "Musical", "C~
```

```
## $ `IMDB Rating` <dbl> 75, 77, 67, 57, 58, 57, 56, 74, 81, 71, 62, ~
```

```
## $ `IMDB Votes` <chr> "12,221", "3,439", "1,257", "6,890", "765", ~
```

```
## $ `Content Rating` <chr> "PG-13", NA, NA, "NR", NA, NA, "NR", NA, NA, ~
```

```
## $ Directors <chr> "William Wellman", NA, NA, "Harry Beaumont", ~
```

```
## $ `Original Release Date` <date> 1927-08-12, NA, NA, 1929-02-01, NA, NA, 192~
```

```
## $ `Production Company` <chr> "Unknown", NA, NA, "MGM Home Entertainment", ~
```

```
## $ `Tomatometer Rating` <dbl> 930, NA, NA, 330, NA, NA, 560, NA, NA, 750, ~
```

```
## $ `Tomatometer Count` <dbl> 460, NA, NA, 240, NA, NA, 90, NA, NA, 80, NA~
```

```
## $ `Audience Rating` <dbl> 780, NA, NA, 210, NA, NA, 380, NA, NA, 690, ~
```

```
## $ `Audience Count` <dbl> 35300, NA, NA, 18130, NA, NA, 3560, NA, NA, ~
```

```
var_types <- sapply(data, class)
```

```
cat(paste(names(var_types), ": ", var_types, sep = " ", collapse = "\n"))
```

```
## Unnamed: 0: numeric
```

```
## Film: character
```

## Oscar Year: character  
## Film Studio/Producer(s): character  
## Award: character  
## Year of Release: numeric  
## Movie Time: numeric  
## Movie Genre: character  
## Main Genre: character  
## Subgenre: character  
## IMDB Rating: numeric  
## IMDB Votes: character  
## Content Rating: character  
## Directors: character  
## Original Release Date: Date  
## Production Company: character  
## Tomatometer Rating: numeric  
## Tomatometer Count: numeric  
## Audience Rating: numeric  
## Audience Count: numeric

## 2 Analiza žanrova kod pobjednika (Matija)

### 2.1 Opis problema

Cilj ove analize je ispitati postoji li povezanost između filmskih žanrova i vjerojatnosti osvajanja Oscara. S obzirom na to da je teško svesti film na samo jedan žanr, analizu provodimo na dva načina:

1. *Single-label pristup* – svakom filmu pridružujemo samo jedan glavni žanr (Main Genre).
2. *Multi-label pristup* – film može pripadati više žanrova (Movie Genre), a svaki žanr ćemo zasebno brojati.

Na taj način možemo usporediti kako različiti modeli označavanja žanrova utječu na rezultate.

### 2.2 Single-label analiza

#### 2.2.1 Grupiranje žanrova i priprema podataka za analizu:

Prvo nego što krenemo raditi bilo kakve statističke testove, moramo se upoznati s podacima. U datasetu se nalazi više stupaca koje sadrže kako su labelirani filmovi po z

```
data <- data %>%
  mutate(`Main Genre` = as.character(`Main Genre`))

winners <- data %>% filter(Award == "Winner")
nominees <- data %>% filter(Award %in% c("Nominee", "Winner"))

winner_counts <- winners %>%
  count(`Main Genre`, name = "Winners")

nominee_counts <- nominees %>%
  count(`Main Genre`, name = "Nominations")

genre_table <- nominee_counts %>%
  left_join(winner_counts, by = "Main Genre") %>%
  mutate(
    Winners = replace_na(Winners, 0),
    NotWinner = Nominations - Winners
  ) %>%
  rename(Genre = `Main Genre`)
```

Vizualizacija pobjeda i nominacija po žanru:


```
genre_plot_data <- genre_table %>%
  arrange(desc(Winners)) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )

ggplot(genre_plot_data,
```

```

    aes(x = Count,
        y = reorder(Genre, Count),
        fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  geom_text(aes(label = Count),
            position = position_stack(vjust = 0.5),
            size = 3) +
  scale_fill_manual(values = c(
    "Winners" = "#1f78b4",
    "NotWinner" = "#a6cee3"
  )) +
  theme_minimal(base_size = 15) +
  labs(
    title = "Oscari po žanru: Pobjede i nominacije",
    x = "Broj filmova",
    y = "Žanr",
    fill = ""
  )
)

```



Zbog velike disproporcije između broja pobjeda i nominacija, koristimo i postotne prikaze te logaritamsku skalu kako bismo mogli bolje vizualizirati podatke.


#### 2.2.2 Postotni prikaz pobjeda vs nominacija po žanru:

```

ggplot(genre_plot_data, aes(x = reorder(Genre, -Count), y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "fill", color = "black") +
  scale_y_continuous(labels = scales::percent_format()) +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6c3e3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Postotak pobjeda vs nominacija po žanru",


```

```
x = "Žanr", y = "Postotak", fill = "") +
theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



### 2.2.3 Logaritamska skala za broj pobjeda vs nominacija po žanru:

```
ggplot(genre_plot_data, aes(x = reorder(Genre, Count), y = Count, fill = Outcome)) +
  geom_bar(stat = "identity", position = "stack", color = "black") +
  scale_y_log10() +
  scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
  theme_minimal(base_size = 14) +
  labs(title = "Oscari po žanru (log skala)",
       x = "Žanr", y = "Broj filmova (log10)", fill = "") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```




#### 2.2.4 Stopa uspješnosti po žanru:

Možemo također izračunati stopu uspješnosti (postotak pobjeda u odnosu na broj nominacija) za svaki žanr kako bismo dodatno ilustrirali razlike među žanrovima.

```
genre_table <- genre_table %>%
  mutate(WinRate = (Winners / Nominations) * 100)

ggplot(genre_table, aes(x = reorder(Genre, WinRate), y = WinRate)) +
  geom_col(fill = "#1f78b4", width = 0.7) +
  geom_text(
    aes(label = sprintf("%.1f%%", WinRate)),
    hjust = -0.1,
    size = 4
  ) +
  coord_flip() +
  scale_y_continuous(limits = c(0, max(genre_table$WinRate) * 1.15)) +
  labs(
    title = "Stopa pobjeda po žanru",
    x = "Žanr",
    y = "Postotak pobjede"
  ) +
  theme_minimal(base_size = 14) +
  theme(
    plot.title = element_text(face = "bold", size = 16),
    axis.text.y = element_text(size = 12),
    axis.text.x = element_text(size = 11)
  )
```



#### 2.2.5 Kontingencijska tablica nominiranih i pobjednika po žanrovima:

```
kontingencijska <- genre_table[, c("Winners", "NotWinner")]
row.names(kontingencijska) <- genre_table$Genre
kontingencijska
```

```
## # A tibble: 14 x 2
##   Winners NotWinner
##   *      <int>      <int>
## 1         3        36
## 2         9        36
## 3         0         3
## 4        18        83
## 5        13        95
## 6         9        39
## 7        42       173
## 8         0         1
## 9         0         2
## 10        0         3
## 11        0         1
## 12        0         2
## 13        0         1
## 14        0         2
```

## 2.3 Multi-label analiza

### 2.3.1 Priprema podataka

Priprema podataka za multi-label analizu žanrova:



```
data <- data %>%
  mutate(`Movie Genre` = as.character(`Movie Genre`))
```

Mutiramo podatke kako bismo razdvojili višestruke žanrove u zasebne retke.

```
data_long <- data %>%
  separate_rows(`Movie Genre`, sep = ",") %>%
  mutate(`Movie Genre` = trimws(`Movie Genre`))
```

Izračun broja pobjeda i ne-pobjeda po žanru:

```
genre_counts <- data_long %>%
  mutate(
    Outcome = ifelse(Award == "Winner", "Winner", "NotWinner")
  ) %>%
  count(`Movie Genre`, Outcome) %>%
  pivot_wider(
    names_from = Outcome,
    values_from = n,
    values_fill = 0
  ) %>%
  mutate(
    Total = Winner + NotWinner,
    GenreGroup = ifelse(Total < 5, "Other", `Movie Genre`),
    SuccessRate = Winner / Total
  )
```

Grupiranje rijetkih žanrova u kategoriju “Ostali” i izračun ukupnih vrijednosti po grupama žanrova:

```
genre_table_ml <- genre_counts %>%
  group_by(GenreGroup) %>%
  summarise(
    Winners = sum(Winner),
    NotWinner = sum(NotWinner),
    Total = sum(Total),
    SuccessRate = sum(Winner)/sum(Total),
    .groups = "drop"
  )
```


### 2.3.2 Vizualizacija rezultata multi-label analize žanrova:

```
genre_melt <- genre_table_ml %>%
  select(GenreGroup, Winners, NotWinner) %>%
  pivot_longer(
    cols = c(Winners, NotWinner),
    names_to = "Outcome",
    values_to = "Count"
  )


# Bar plot (broj pojavljivanja)
ggplot(genre_melt, aes(x = Count, y = reorder(GenreGroup, Count), fill = Outcome)) +
```

```
geom_bar(stat = "identity", color = "black") +
geom_text(aes(label = Count), position = position_stack(vjust = 0.5), size = 3) +
scale_fill_manual(values = c("Winners" = "#1f78b4", "NotWinner" = "#a6cee3")) +
theme_minimal(base_size = 14) +
labs(title = "Multi-label analiza žanrova (grupirani rijetki žanrovi)",
      x = "Broj pojavljivanja",
      y = "Žanr",
      fill = "")
```

## Multi-label analiza žanrova (grupirani rijetki žanrovi)



```
# Bar plot (postotak pobjeda)
ggplot(genre_table_ml, aes(x = SuccessRate, y = reorder(GenreGroup, SuccessRate))) +
  geom_col(fill = "#1f78b4") +
  geom_text(aes(label = scales::percent(SuccessRate, accuracy = 0.1)), hjust = -0.1, size = 4) +
  scale_x_continuous(labels = scales::percent_format(), limits = c(0, NA)) +
  theme_minimal(base_size = 14) +
  labs(title = "Postotak uspješnosti po žanru (multi-label)",
        x = "Udio pobjeda",
        y = "Žanr")
```



## 2.4 Statističko testiranje

### 2.4.1 Hipoteze:

- Nulta hipoteza ( $H_0$ ): Ne postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.
- Alternativna hipoteza ( $H_1$ ): Postoji značajna razlika u učestalosti pobjeda među različitim žanrovima filmova.

### 2.4.2 Grupiranje žanrova i priprema podataka za analizu:

Kako bi ispitali nezavisnost dviju kategorijske varijable, odnosno kako bi ispitali jesu li žanrovi i pobjede zavisi, koristit ćemo hi-kvadrat test. Neka je kontingencijska tablica dimenzija  $r \times c$  sa:

- $O_{ij}$  = promatrana frekvencija u ćeliji  $(i, j)$
- $E_{ij}$  = očekivana frekvencija ako su varijable neovisne

Očekivane frekvencije računamo

$$E_{ij} = \frac{(\text{ukupno u redu } i) \cdot (\text{ukupno u stupcu } j)}{\text{ukupan broj promatranja}}$$

Hi-kvadrat statistika se provodi formulom:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

- Mala vrijednost  $\chi^2 \rightarrow$  promatrane frekvencije blizu očekivanih (neovisnost)

- Velika vrijednost  $\chi^2 \rightarrow$  značajna odstupanja (ovisnost)

Stupnjevi slobode računamo:

$$df = (r - 1)(c - 1)$$

Standardizirani reziduali za procjenu odstupanja pojedine ćelije, odnosno u ovome slučaju žanra:

$$\text{StdRes}_{ij} = \frac{O_{ij} - E_{ij}}{\sqrt{E_{ij}}}$$

- Pozitivni rezidual  $\rightarrow$  više promatranih nego očekivanih
- Negativni rezidual  $\rightarrow$  manje promatranih nego očekivanih
- Vrijednosti veće od  $\pm 2$  obično se smatraju **statistički značajnim!**

Važno je reći da hi-kvadrat test ima važan uvjet: očekivane frekvencije u svakoj ćeliji kontingencijske tablice trebaju biti veće od 5. Za žanrove s jako malim brojem filmova (npr. 1–2 pojave), očekivane frekvencije za te vrlo male. Kako bi statistički test bio valjan, grupirat ćemo manje zastupljene žanrove u kategoriju “Ostali” kako bismo osigurali da sve ćelije imaju dovoljne očekivane frekvencije.

### 2.4.3 Prvo ćemo analizirati prvi pristup: Single-label analiza

```
common_genres <- c("Action", "Adventure", "Biography", "Comedy", "Crime", "Drama")
data$GenreGroup <- ifelse(data$`Main Genre` %in% common_genres,
                           data$`Main Genre`,
                           "Other")

# broj pobjeda po grupama
winner_counts <- as.data.frame(table(subset(data, Award=="Winner")$GenreGroup))
colnames(winner_counts) <- c("GenreGroup", "Winners")

# broj nominacija po grupama
nominee_counts <- as.data.frame(table(subset(data, Award %in% c("Winner", "Nominee"))$GenreGroup))
colnames(nominee_counts) <- c("GenreGroup", "Nominations")

df <- merge(nominee_counts, winner_counts, by="GenreGroup", all.x=TRUE)
df$Winners[is.na(df$Winners)] <- 0

# Dodaj kolonu za ne-pobjede
df$NotWinner <- df$Nominations - df$Winners

kontigencijska_single <- as.data.frame(df[, c("Winners", "NotWinner")])
row.names(kontigencijska_single) <- df$GenreGroup

#Prikaz kontigencijske tablice
kontigencijska_single
```

```
##           Winners NotWinner
## Action           3         36
## Adventure        9         36
```

|              |    |     |
|--------------|----|-----|
| ## Biography | 18 | 83  |
| ## Comedy    | 13 | 95  |
| ## Crime     | 9  | 39  |
| ## Drama     | 42 | 173 |
| ## Other     | 0  | 15  |

#### 2.4.4 Hi-kvadrat test:

Sada radimo Hi-kvadrat test kako bismo vidjeli postoje li značajne razlike u učestalosti pobjeda među različitim žanrovima. Za razinu značajnosti, uzet ćemo  $\alpha = 0,05$ .

```
# Chi-squared test
chisq_single <- chisq.test(kontigencijska_single)
chisq_single
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_single
## X-squared = 8.8789, df = 6, p-value = 0.1805
```

S obzirom na to da je  $p - value > \alpha$ , odnosno  $0.1805 > 0.05$ , prihvaćamo  $H_0$ .

Standardizirani reziduali koji pokazuju kako žanrovi odstupaju:

```
chisq_single$stdres
```

```
##           Winners NotWinner
## Action    -1.5300621  1.5300621
## Adventure  0.6667449 -0.6667449
## Biography  0.4060704 -0.4060704
## Comedy    -1.3771971  1.3771971
## Crime      0.4465715 -0.4465715
## Drama      1.5385882 -1.5385882
## Other     -1.7423324  1.7423324
```

#### 2.4.5 Zatim analiziramo Multi-label analizu:

```
kontigencijska_multi <- genre_table_ml[, c("Winners", "NotWinner")]
row.names(kontigencijska_multi) <- genre_table_ml$GenreGroup
kontigencijska_multi
```

```
## # A tibble: 20 x 2
##   Winners NotWinner
## *   <int>     <int>
## 1      3         36
## 2     11         56
## 3     20         89
## 4     16        109
## 5     13         59
```

```
## 6      88      414
## 7       6       21
## 8       1       23
## 9       2       11
## 10      13       54
## 11       1       25
## 12       8       22
## 13       2       26
## 14       0        7
## 15      25      149
## 16       0       10
## 17       3        7
## 18       8       32
## 19      13       29
## 20       3       12
```

## 2.4.6 Hi-kvadrat test

```
chisq_multi <- chisq.test(kontigencijska_multi)
chisq_multi
```

```
##
## Pearson's Chi-squared test
##
## data: kontigencijska_multi
## X-squared = 27.047, df = 19, p-value = 0.1036
```

```
chisq_multi$stdres
```

```
##           Winners  NotWinner
## Action    -1.50765823  1.50765823
## Adventure -0.02714508  0.02714508
## Biography  0.52937302 -0.52937302
## Comedy    -1.17770142  1.17770142
## Crime      0.35563977 -0.35563977
## Drama      0.74281443 -0.74281443
## Family     0.80259845 -0.80259845
## Fantasy    -1.64522050  1.64522050
## Film-Noir -0.11246503  0.11246503
## History    0.64652494 -0.64652494
## Music      -1.75801693  1.75801693
## Musical    1.50914353 -1.50914353
## Mystery    -1.35147028  1.35147028
## Other      -1.18063854  1.18063854
## Romance    -0.82235271  0.82235271
## Sci-Fi     -1.41262596  1.41262596
## Sport      1.14985359 -1.14985359
## Thriller   0.59774895 -0.59774895
## War        2.55219613 -2.55219613
## Western    0.36279002 -0.36279002
```

Ovdje također vidimo da je  $p - value > \alpha$ , odnosno  $0.1036 > 0.05$  te prihvaćamo  $H_0$ .

## 2.5 Zaključak

Na temelju rezultata Hi-kvadrat testa i Fisherovog testa oba pristupa, prihvaćamo  $H_0$  i možemo zaključiti da ne postoje značajne razlike u učestalosti pobjeda među različitim žanrovima filmova nominiranih za Oscara. Standardizirani reziduali ukazuju na to koji žanrovi značajno odstupaju od očekivanih vrijednosti, što može biti korisno za daljnje istraživanje i razumijevanje trendova u dodjeli nagrada.

### 3 Analiza ocjena kroz godine (Roko)

```
library(ggplot2)

oscars <- read.csv("oscars_dataset.csv", sep = ";")
oscars$win <- ifelse(oscars$Award == "Winner", 1, 0)
oscars$votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes))
summary(oscars$votes)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      18    9660   58996  208480  259429  2452594

model <- glm(
  win ~ votes,
  data = oscars,
  family = binomial
)

summary(model)

##
## Call:
## glm(formula = win ~ votes, family = binomial, data = oscars)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.915e+00  1.396e-01 -13.721  < 2e-16 ***
## votes       1.155e-06  2.760e-07   4.186  2.84e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 493.96  on 569  degrees of freedom
## AIC: 497.96
##
## Number of Fisher Scoring iterations: 4

# za inkrementalan glas publike log odds za dobivanje nagrade
# ce biti veci za 1.155e-06

# za inkrementalnig 100 tis glasova
oscars$votes100k <- oscars$votes / 100000

model100k <- glm(win ~ votes100k, family = binomial, data = oscars)
summary(model100k)


##
## Call:
## glm(formula = win ~ votes100k, family = binomial, data = oscars)
```



```
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.9151      0.1396 -13.721  < 2e-16 ***
## votes100k     0.1155      0.0276   4.186 2.84e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 493.96  on 569  degrees of freedom
## AIC: 497.96
##
## Number of Fisher Scoring iterations: 4

# z je 4.186, dovoljno velika za odbacivanje hipoteze
# vjerojatnost da će film osvojiti Oscar raste s većim brojem glasova

# vizualizacija
newframe <- data.frame(
  votes100k = seq(
    min(oscars$votes100k),
    max(oscars$votes100k),
    length.out = 100
  )
)
newframe$prob <- predict(model100k, newframe, type = "response") # vjerojatnosti
ggplot(newframe, aes(x = votes100k, y = prob)) +
  geom_line() +
  labs(x = "IMDb votes (log scale)", y = "Predicted probability of winning",
    title = "Audience votes and Oscar-winning probability"
  )
```



## 4 Možemo li naslutiti ocjenu na IMDb pomoću nekih parametara? (Roko)

```
library(ggplot2)
library(dplyr)

oscars <- read.csv("oscars_dataset.csv", sep=";")
oscars$rating <- as.numeric(oscars$IMDB.Rating) #IMDb rating
oscars$votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes)) #broj glasova na IMDb
oscars$runtime <- as.numeric(oscars$Movie.Time) # trajanje filma
oscars$year <- as.numeric(oscars$Year.of.Release) # godina izlaska filma
oscars$genre <- oscars$Main.Genre # žanr filma

oscars <- oscars %>%
  select(rating, votes, runtime, year, genre) %>%
  na.omit()


summary(oscars)
```

```
##      rating      votes      runtime      year
## Min.   :5.60   Min.    :   18   Min.    : 66.0   Min.    :1927
## 1st Qu.:7.30   1st Qu.:  9660   1st Qu.:107.0   1st Qu.:1944
## Median :7.60   Median : 58996   Median :121.0   Median :1972
## Mean   :7.57   Mean    :208480   Mean    :124.9   Mean    :1973
## 3rd Qu.:7.90   3rd Qu.:259429   3rd Qu.:136.5   3rd Qu.:2001
## Max.   :9.30   Max.    :2452594   Max.    :238.0   Max.    :2021
##      genre
## Length:571
## Class :character
## Mode  :character
##
##
##
```

*#analiza parametara*

*#1. Možemo li sa brojem glasova na IMDb-u predvidjeti ocjenu?*  
*# H0: ne možemo, H1: možemo*

```
ggplot(oscars, aes(x = votes, y = rating)) +
  geom_point(alpha = 0.4) +
  scale_x_log10() +
  labs(x = "Broj glasova na IMDb-u (log)", y = "Ocjena filma na IMDb-u")
```



*# Spearmanov test korelacije*

```
cor.test(
  oscars$rating,
  oscars$votes,
  method = "spearman"
)
```


```
##
## Spearman's rank correlation rho
##
## data: oscars$rating and oscars$votes
## S = 10060771, p-value < 2.2e-16
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##      rho
## 0.6757533
```

*# p value je izrazito mali, odbacujemo hipotezu H0 (glasovi i ocjena nisu korelirane)*

*#2. Možemo li s obzirom na žanr predvidjeti kako je ocijenjen film?*

*# H0: ne, H1: da*

```
ggplot(oscars, aes(x = genre, y = rating)) +
  geom_boxplot() +
  coord_flip()
```



```
# linearni model kada uzmemo logaritam broja glasova
m1 <- lm(rating ~ log10(votes), data = oscars)
summary(m1)
```

```
##
## Call:
## lm(formula = rating ~ log10(votes), data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.4959 -0.2649  0.0303  0.2821  1.3492
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   5.49427    0.09135   60.14  <2e-16 ***
## log10(votes)  0.44334    0.01917   23.12  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4022 on 569 degrees of freedom
## Multiple R-squared:  0.4844, Adjusted R-squared:  0.4835
## F-statistic: 534.6 on 1 and 569 DF, p-value: < 2.2e-16
```

```
m2 <- lm(
  rating ~ log10(votes) + runtime + year + genre,
  data = oscars
)

summary(m2)
```

```
##
```

```
## Call:
## lm(formula = rating ~ log10(votes) + runtime + year + genre,
##     data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.74777 -0.18846  0.01839  0.21712  1.61036
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  22.4099872   1.5024169   14.916 < 2e-16 ***
## log10(votes)   0.6513740   0.0281238   23.161 < 2e-16 ***
## runtime        0.0011657   0.0006378    1.828  0.06815 .
## year          -0.0091827   0.0008064  -11.387 < 2e-16 ***
## genreAdventure  0.0076345   0.0782912    0.098  0.92235
## genreAnimation  0.2070180   0.2148561    0.964  0.33571
## genreBiography  0.0988861   0.0672692    1.470  0.14213
## genreComedy     0.0439202   0.0676069    0.650  0.51619
## genreCrime      0.1715388   0.0769889    2.228  0.02627 *
## genreDrama      0.1345456   0.0623389    2.158  0.03133 *
## genreFamily     -0.1829209   0.3596893   -0.509  0.61127
## genreFilm-Noir -0.2449906   0.2586819   -0.947  0.34401
## genreHorror      0.0380331   0.2127347    0.179  0.85817
## genreMusic      -0.8471014   0.3617841   -2.341  0.01956 *
## genreMusical    -0.4869664   0.2596788   -1.875  0.06128 .
## genreRomance    -0.3484781   0.3609246   -0.966  0.33471
## genreWestern    -0.7292415   0.2583592   -2.823  0.00493 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3546 on 554 degrees of freedom
## Multiple R-squared:  0.6099, Adjusted R-squared:  0.5986
## F-statistic: 54.14 on 16 and 554 DF, p-value: < 2.2e-16
```

## 5 Istraživačko pitanje: Ocjene filmova i njihova starost (Damjan)

```
oscars <- read.csv2("oscars_dataset.csv")
# glimpse(oscars)
```

5.0.0.1 U ovom dijelu analiziramo kako se ocjene filmova mijenjaju s obzirom na godinu izlaska. Promatramo zasbenu ocjene publike (IMDb) i ocjene kritičara (Rotten Tomatoes).

5.0.0.2 U ovoj analizi istražujemo kako su filmovi nominirani za Oscara za najbolji film oci-  
jenjeni s obzirom na godinu izlaska.

```
oscars <- oscars %>%
  mutate(
```

```

IMDB.Rating = as.numeric(IMDB.Rating),
IMDB.Votes = as.numeric(gsub(",", "", IMDB.Votes)),
Tomatometer.Rating = as.numeric(Tomatometer.Rating),
Audience.Rating = as.numeric(Audience.Rating),
Award = factor(Award, levels = c("Nominee", "Winner"))
)

```


**5.0.0.3 Pretvorbe tipova, uređivanje dataseta** Da bismo dobili uvid u to postoji li promjena u prosječnim ocjenama filmova kroz vrijeme, usporedit ćemo IMDb ocjene starijih i novijih filmova.

```

oscars <- oscars %>%
  mutate(
    Period = ifelse(Year.of.Release < 1990, "Stariji", "Noviji")
  )

ggplot(oscars, aes(x = Period, y = IMDB.Rating)) +
  geom_boxplot() +
  labs(
    x = "Razdoblje",
    y = "IMDb ocjena",
    title = "IMDb ocjene starijih i novijih filmova"
  )

```



#### 5.0.0.4 Side-to-side usporedba ocjena starijih i novijih filmova

Budući da želimo statistički provjeriti postoji li značajna razlika u IMDb ocjenama između starijih i novijih filmova, primijenit ćemo neparametarski Wilcoxonov rank-sum test.

```
wilcox.test(
  IMDB.Rating ~ Period,
  data = oscars
)
```

#### 5.0.0.5 Wilcoxonov rank-sum test

```
##
## Wilcoxon rank sum test with continuity correction
##
## data: IMDB.Rating by Period
## W = 47342, p-value = 6.488e-08
## alternative hypothesis: true location shift is not equal to 0
```

Rezultati Wilcoxonovog testa pokazuju da je p-vrijednost vrlo mala ( $p < 0,001$ ), što znači da postoji statistički značajna razlika u IMDb ocjenama između starijih i novijih filmova, pri čemu noviji filmovi imaju prosječno više ocjene.

Pogledajmo sada kako se IMDb ocjene mijenjaju kroz godine izlaska filmova.


```
ggplot(oscars, aes(x = Year.of.Release, y = IMDB.Rating)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "IMDb ocjena",
    title = "Odnos godine izlaska i IMDb ocjene"
  )
```

#### 5.0.0.6 Graf: IMDb ocjena filmova kroz godine

```
## `geom_smooth()` using formula = 'y ~ x'
```



## Odnos godine izlaska i IMDb ocjene



S grafa je vidljivo da regresijski pravac ima blagi pozitivan nagib, što upućuje na to da IMDb ocjene filmova kroz vrijeme pokazuju tendenciju blagog porasta. Međutim, raspršenost podataka oko regresijske linije je velika, pa je vidljivo da je taj trend slab i da godina izlaska objašnjava samo mali dio varijabilnosti IMDb ocjena.

Kako bi provjerili je li ovaj porast ocjena s vremenom statistički značajan, izračunat ćemo Pearsonov koeficijent korelacije između godine izlaska i IMDb ocjena.

```
cor.test(
  oscars$Year.of.Release,
  oscars$IMDB.Rating,
  use = "complete.obs"
)
```

### 5.0.0.7 Određivanje Pearsonovog koeficijenta korelacije (jačine i smjera linearne povezanosti)

```
##
## Pearson's product-moment correlation
##
## data:  oscars$Year.of.Release and oscars$IMDB.Rating
## t = 8.3363, df = 569, p-value = 5.783e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.2547525 0.4011050
## sample estimates:
##      cor
## 0.3299097
```

Pearsonov koeficijent korelacije između godine izlaska i IMDb ocjena iznosi 0,33, što indicira umjerenu pozitivnu linearnu povezanost. Budući da je p-vrijednost gotovo zanemariva, veza je statistički značajna. Međutim, iako trend pokazuje da noviji filmovi imaju blago više ocjene, godina izlaska objašnjava samo mali dio

varijabilnosti ocjena.

Da bismo bolje razumjeli kako godina izlaska utječe na IMDb ocjene i mogli predviđati ocjene filmova, koristit ćemo linearnu regresiju s ocjenom kao zavisnom varijablom i godinom izlaska kao neovisnom.

```
model <- lm(
  IMDB.Rating ~ Year.of.Release,
  data = oscars
)

summary(model)
```

#### 5.0.0.8 Linearna regresija - IMDb

```
##
## Call:
## lm(formula = IMDB.Rating ~ Year.of.Release, data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.68474 -0.35157  0.00511  0.36096  1.63815
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -4.8580725   1.4910503   -3.258  0.00119 **
## Year.of.Release  0.0062981  0.0007555    8.336 5.78e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5288 on 569 degrees of freedom
## Multiple R-squared:  0.1088, Adjusted R-squared:  0.1073
## F-statistic: 69.49 on 1 and 569 DF, p-value: 5.783e-16
```


Linearni model pokazuje blagu pozitivnu povezanost između godine izlaska i IMDb ocjena. Svaka dodatna godina povećava očekivanu ocjenu za približno 0,006 rating bodova. Model je statistički značajan ( $p < 0,001$ ), no godina izlaska objašnjava samo oko 1% varijabilnosti ocjena, što znači da iako postoji trend rasta ocjena s vremenom, on je relativno slab.

Napravimo sada sličnu analizu gdje ćemo kao ocjenu uzeti ocjenu kritičara, odnosno Rotten Tomatoes rating.

```
ggplot(oscars, aes(x = Year.of.Release, y = Tomatometer.Rating)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "Tomatometer ocjena",
    title = "Odnos godine izlaska i RT ocjene"
  )
```

#### 5.0.0.9 Rotten Tomatoes i starost filma

```
## `geom_smooth()` using formula = 'y ~ x'
```



Regresijski pravac u ovom slučaju ima još manji nagib, no još uvijek ima pozitivan koeficijent smjera. Raspršenost podataka ponovno je velika (ponovno slab trend), stoga izračunajmo i za ovaj set podataka Pearsonov koeficijent korelacije.

```
cor.test(
  oscars$Year.of.Release,
  oscars$Tomatometer.Rating,
  use = "complete.obs"
)
```

```
##
## Pearson's product-moment correlation
##
## data:  oscars$Year.of.Release and oscars$Tomatometer.Rating
## t = 1.0749, df = 457, p-value = 0.283
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.04149945  0.14109647
## sample estimates:
##      cor
## 0.05021814
```

Pearsonov koeficijent korelacije između godine izlaska i ocjena kritičara (Tomatometer) iznosi 0,05, što ukazuje na vrlo slab trend. P-vrijednost je 0,283, što znači da veza nije statistički značajna. Drugim riječima, **ocjene kritičara ne pokazuju pouzdan trend rasta ili pada s vremenom.**

```
model <- lm(Tomatometer.Rating ~ Year.of.Release, data = oscars)
summary(model)
```

### 5.0.0.10 Linearna regresija - Rotten Tomatoes


```
##
## Call:
## lm(formula = Tomatometer.Rating ~ Year.of.Release, data = oscars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -58.427  -3.897   3.079   7.546  13.262
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   47.55938   37.29628   1.275   0.203
## Year.of.Release  0.02027    0.01886   1.075   0.283
##
## Residual standard error: 11.53 on 457 degrees of freedom
## (112 observations deleted due to missingness)
## Multiple R-squared:  0.002522, Adjusted R-squared:  0.0003392
## F-statistic: 1.155 on 1 and 457 DF, p-value: 0.283
```

Linearni model pokazuje da postoji gotovo zanemariva pozitivna veza između godine izlaska i ocjena kritičara (nagib = 0,02), koja nije statistički značajna ( $p = 0,283$ ) i objašnjava manje od 1% varijabilnosti ocjena.

```
ggplot(oscars, aes(x = Year.of.Release, y = IMDB.Votes)) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "broj IMDb glasova",
    title = "Odnos godine izlaska i broja IMDb glasova"
  )
```

### 5.0.0.11 Broj IMDb glasova i starost filma

```
## `geom_smooth()` using formula = 'y ~ x'
```




```
ggplot(oscars, aes(x = Year.of.Release, y = log(IMDB.Votes))) +
  geom_point(alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(
    x = "Godina izlaska",
    y = "Log(broj IMDb glasova)",
    title = "Odnos godine izlaska i broja IMDb glasova"
  )
```

5.0.0.12 Isti postupak, uz `log(IMDB.Votes)`

```
## `geom_smooth()` using formula = 'y ~ x'
```

### Odnos godine izlaska i broja IMDb glasova



```
cor.test(  
  oscars$Year.of.Release,  
  log(oscars$IMDB.Votes),  
  use = "complete.obs"  
)
```

#### 5.0.0.13 Korelacija glasova i godine izlaska filma

```
##  
## Pearson's product-moment correlation  
##  
## data:  oscars$Year.of.Release and log(oscars$IMDB.Votes)  
## t = 27.999, df = 569, p-value < 2.2e-16  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
##  0.7243963 0.7936847  
## sample estimates:  
##      cor  
## 0.7612044
```

## 6 Možemo li pomoću dostupnih značajki pouzdano razlikovati pobjednike od ostalih?

### 6.1 Priprema podataka za logističku regresiju

```

data <- read.csv("oscars_dataset.csv", sep=";")

# Kreiranje binarnog ishoda (Winner = 1, Nominee = 0)
data$IsWinner <- ifelse(data$Award == "Winner", 1, 0)

# Čišćenje i pretvaranje varijabli
data$Rating <- as.numeric(data$IMDB.Rating)
data$Votes <- as.numeric(gsub(",", "", data$IMDB.Votes))
data$Runtime <- as.numeric(data$Movie.Time)
data$Year <- as.numeric(data$Year.of.Release)

# Grupiranje rijetkih žanrova
common_genres <- c("Action", "Adventure", "Biography", "Comedy", "Crime", "Drama")
data$GenreGroup <- ifelse(data$Main.Genre %in% common_genres,
                          data$Main.Genre,
                          "Other")
data$GenreGroup <- factor(data$GenreGroup,
                          levels = c("Drama", "Action", "Adventure",
                                      "Biography", "Comedy", "Crime", "Other"))

# Uklanjanje redaka s nedostajućim podacima
model_data <- data %>%
  dplyr::select(IsWinner, Rating, Votes, Runtime, Year, GenreGroup) %>%
  na.omit()

cat("Broj filmova u analizi:", nrow(model_data), "\n")

## Broj filmova u analizi: 571

cat("Broj pobjednika:", sum(model_data$IsWinner), "\n")

## Broj pobjednika: 94

cat("Broj nominiranih (bez pobjede):", sum(model_data$IsWinner == 0), "\n")

## Broj nominiranih (bez pobjede): 477

```

## 7 Eksplorativna analiza - usporedba pobjednika i nominiranih