

peto_pitanje

36557629 Damjan Crnković

2026-01-23

Contents

1	Analiza predviđanja pobjednika	2
1.1	Priprema podataka	2
1.2	Konstrukcija jednostavnijeg modela logističke regresije	2
1.3	Konstrukcija složenijeg modela logističke regresije	4
1.4	Evaluacija modela	5

```
oscars <- read.csv("oscars_dataset.csv", sep = ";", na.strings = c("", "NA", "Unknown"),
                  encoding = "UTF-8")

oscars$Award <- factor(oscars$Award, levels = c("Nominee", "Winner"))
oscars$Main.Genre <- factor(oscars$Main.Genre)
oscars$Subgenre <- factor(oscars$Subgenre)
oscars$Content.Rating <- factor(oscars$Content.Rating)
oscars$Movie.Genre <- factor(oscars$Movie.Genre)

oscars$Year.of.Release <- as.numeric(oscars$Year.of.Release)
oscars$Movie.Time <- as.numeric(oscars$Movie.Time)

oscars$IMDB.Rating <- as.numeric(oscars$IMDB.Rating)
oscars$IMDB.Votes <- as.numeric(gsub(",", "", oscars$IMDB.Votes))

oscars$Tomatometer.Rating <- as.numeric(oscars$Tomatometer.Rating)
oscars$Tomatometer.Count <- as.numeric(oscars$Tomatometer.Count)

oscars$Audience.Rating <- as.numeric(oscars$Audience.Rating)
oscars$Audience.Count <- as.numeric(oscars$Audience.Count)

oscars$Original.Release.Date <- as.Date(oscars$Original.Release.Date)

small_genres <- c("Animation", "Family", "Film-Noir", "Horror",
                 "Music", "Musical", "Romance", "Western")
oscars$Main.Genre2 <- as.character(oscars$Main.Genre)
oscars$Main.Genre2[oscars$Main.Genre2 %in% small_genres] <- "Other"
```

1 Analiza predviđanja pobjednika

U ovoj analizi istražujemo postoje li statistički značajne razlike između filmova koji su osvojili Oscara (“Winner”) i onih koji su bili samo nominirani (“Nominee”). Analizu provodimo na temelju dostupnih značajki: IMDb ocjene, žanra, trajanja filma, broja IMDb glasova.

1.1 Priprema podataka

Prije analize, uređujemo dataset: kreiramo binarnu varijablu za pobjedu te izbacujemo zapise s NA vrijednostima. Žanrovi koji nisu često zastupljeni ranije su grupirani u kolonu Main.Genre2, stoga ćemo nju koristiti za daljnju analizu. Podatak o godini izlaska filma izostavljen je iz daljnje analize jer je detaljno proučavanje skupa podataka pokazalo da je broj pobjednika po godini gotovo konstantan (najčešće 1–2), dok se broj nominiranih filmova značajno razlikuje između godina. Zbog te nekonzistentnosti varijabla godine ne nosi stabilnu informaciju, već prvenstveno unosi dodatni šum u logistički regresijski model.

```
oscars <- oscars %>%
  mutate(
    IsWinner = ifelse(Award == "Winner", 1, 0),
    # Grupiranje žanrova radi stabilnosti modela
    Main.Genre2 = ifelse(Main.Genre %in% c("Drama", "Comedy", "Biography",
                                           "Adventure", "Action", "Crime"),
                        Main.Genre, "Other"),
    Main.Genre2 = factor(Main.Genre2)
  ) %>%
  filter(complete.cases(IMDb.Rating, Main.Genre2, Movie.Time, IsWinner, IMDb.Votes))
```

1.2 Konstrukcija jednostavnijeg modela logističke regresije

Najprije ćemo pokušati izgraditi jednostavniji model logističke regresije u kojem će zavisna varijabla biti IsWinner (0 = Nominirani, 1 = Pobjednik), dok će nezavisne varijable biti IMDb ocjena i prosječno trajanje filma (Movie.Time).

Prije izgradnje modela, pregledajmo raspodjelu broja filmova po ishodu te izračunajmo prosječne vrijednosti navedenih parametara kako bismo dobili uvid u osnovne karakteristike skupa podataka.


```
tablica <- oscars %>%
  group_by(IsWinner) %>%
  summarise(
    `Broj filmova` = n(),
    `Prosječna IMDb ocjena` = mean(IMDb.Rating),
    `Prosječno trajanje` = mean(Movie.Time)
  ) %>%
  rename(
    Pobjednik = IsWinner
  )
kable(tablica)
```

Pobjednik	Broj filmova	Prosječna IMDb ocjena	Prosječno trajanje
0	477	7.529140	122.260
1	94	7.779787	138.266

Podaci pokazuju da je među 94 pobjednika prosječna IMDb ocjena i trajanje filma nešto veća nego kod 477 nominiranih, što sugerira da ti faktori mogu imati pozitivan utjecaj na vjerojatnost osvajanja Oscara. Primjećuje se i da su podaci znatno nebalansirani - pobjednika je mnogo manje u odnosu na nominirane, što može otežati precizno predviđanje modelom.

Idući graf prikazuje raspodjelu filmova prema IMDb ocjeni i trajanju, razdvajajući pobjednike i nominirane, kako bismo vizualno uočili razlike između ishoda.

```
ggplot(oscars, aes(x = IMDB.Rating, y = Movie.Time, color = factor(IsWinner))) +
  geom_point(alpha = 0.6, size = 2) +
  labs(x = "IMDb ocjena", y = "Trajanje filma (min)", color = "Ishod") +
  scale_color_brewer(palette = "Set1") +
  theme_bw()
```



Iz grafa se teško uočava jasan trend koji bi sam po sebi prediktivno razlikovao ishode.

Izgradimo sada jednostavan model logističke regresije kako bismo procijenili vjerojatnost osvajanja Oscara na temelju IMDb ocjene i prosječnog trajanja filma.

```
logreg.mdl <- glm(IsWinner ~ IMDB.Rating + Movie.Time,
  data = oscars,
  family = binomial())
summary(logreg.mdl)
```

```
##
## Call:
## glm(formula = IsWinner ~ IMDB.Rating + Movie.Time, family = binomial(),
##      data = oscars)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -8.661073   1.748739  -4.953 7.32e-07 ***
## IMDB.Rating  0.619881   0.232517   2.666 0.00768 **
```

```
## Movie.Time    0.017685    0.004236    4.175 2.98e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 476.63  on 568  degrees of freedom
## AIC: 482.63
##
## Number of Fisher Scoring iterations: 4
```

Model pokazuje da obje varijable (IMDb ocjena i trajanje filma) značajno utječu na vjerojatnost osvajanja Oscara. Pozitivni koeficijenti govore da veća ocjena ili duži film povećavaju šansu za pobjedu. Model se bolje uklapa od nul-modela, što pokazuje i smanjena devijanca (510.77 → 476.63).

Pseudo- R^2 izračunavamo kao

$$R^2 = 1 - \frac{\text{devijanca modela}}{\text{devijanca nul-modela}}.$$

Vrijednost pokazuje koliko bolje naš model objašnjava podatke u odnosu na model bez predikora.

```
Rsq <- 1 - logreg.mdl$deviance / logreg.mdl$null.deviance
paste0("Pseudo- $R^2$  za jednostavni model: ", round(Rsq, 4))
```

```
## [1] "Pseudo- $R^2$  za jednostavni model: 0.0668"
```

Dobiveni rezultat inicira da model objašnjava samo oko 6.7% varijabilnosti u ishodu, što pokazuje da većina faktora koji utječu na pobjedu Oscara nije obuhvaćena ovim modelom.

1.3 Konstrukcija složenijeg modela logističke regresije

Kreirajmo složeniji model logističke regresije proširen dodatnim prediktorima: grupiranim žanrom filma (Main.Genre2) i brojem IMDb glasova (IMDB.Votes). Cilj je poboljšati sposobnost modela da razlikuje pobjednike od nominiranih uključivanjem više informacija o karakteristikama filmova.

```
logreg.mdl2 <- glm(IsWinner ~ IMDB.Rating + Movie.Time + Main.Genre2 + IMDB.Votes,
  data = oscars,
  family = binomial())
summary(logreg.mdl2)
```

```
##
## Call:
## glm(formula = IsWinner ~ IMDB.Rating + Movie.Time + Main.Genre2 +
##      IMDB.Votes, family = binomial(), data = oscars)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -7.452e+00  2.322e+00  -3.210 0.001329 **
## IMDB.Rating     2.361e-01  3.043e-01   0.776 0.437868
## Movie.Time      1.692e-02  4.628e-03   3.656 0.000257 ***
## Main.Genre22     1.625e+00  7.960e-01   2.041 0.041232 *
## Main.Genre24     1.585e+00  7.372e-01   2.150 0.031545 *
```

```
## Main.Genre25      1.620e+00  7.667e-01   2.113 0.034627 *
## Main.Genre26      1.469e+00  7.791e-01   1.886 0.059362 .
## Main.Genre27      1.863e+00  7.162e-01   2.601 0.009289 **
## Main.Genre20ther -1.293e+01  6.012e+02  -0.022 0.982843
## IMDB.Votes        9.419e-07  4.195e-07   2.245 0.024754 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 510.77  on 570  degrees of freedom
## Residual deviance: 461.62  on 561  degrees of freedom
## AIC: 481.62
##
## Number of Fisher Scoring iterations: 15
```

Dodani prediktori (žanr i broj glasova) pokazuju različite utjecaje na vjerojatnost pobjede, pri čemu neki žanrovi sugeriraju veće, a neki manje šanse za osvajanje nagrade.

Za procjenu značajnosti poboljšanja modela dodavanjem novih prediktora koristimo test omjera izglednosti (Likelihood Ratio Test, LRT). Ovaj test uspoređuje devijancu dva modela: nul-modela (jednostavnijeg) i proširenog modela (s dodatnim varijablama) na razini značajnosti $\alpha=0.05$. Hipoteze testa su:

H0: Dodatni prediktori nisu značajni

H1: Barem jedan dodatni prediktor je značajan.

```
anova(logreg.mdl, logreg.mdl2, test = "LRT")
```

```
## Analysis of Deviance Table
##
## Model 1: IsWinner ~ IMDB.Rating + Movie.Time
## Model 2: IsWinner ~ IMDB.Rating + Movie.Time + Main.Genre2 + IMDB.Votes
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1         568      476.63
## 2         561      461.62  7   15.011  0.03586 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Rezultati pokazuju da dodavanje varijabli Main.Genre2 i IMDB.Votes u model statistički značajno poboljšava njegov fit, odnosno novi model ima značajno manju devijancu.

Izračunajmo Pseudo- R^2 i za novi model:

```
Rsq2 <- 1 - logreg.mdl2$deviance / logreg.mdl2$null.deviance
paste0("Pseudo- $R^2$  za prošireni model: ", round(Rsq2, 4))
```

```
## [1] "Pseudo- $R^2$  za prošireni model: 0.0962"
```

On je i dalje relativno nizak, no postoji porast objašnjive varijabilnosti u odnosu na jednostavni model.

1.4 Evaluacija modela

Za evaluaciju klasifikacijskog učinka složenijeg modela možemo koristiti matricu zabune, koja uspoređuje stvarne i predviđene vrijednosti. Na temelju nje izračunavamo ključne mjere: točnost, preciznost, odziv i specifičnost, koje daju detaljniji uvid u sposobnost modela da pravilno predviđa pobjednike i nominirane.

```
yHat <- logreg.mdl2$fitted.values >= 0.5
tab <- table(oscars$IsWinner, yHat)
kable(tab)
```

	FALSE	TRUE
0	471	6
1	86	8

Tablica pokazuje da model vrlo rijetko pravilno predviđa pobjednike, no isto se tako rijetko dogodi False Positive vrijednost. To objašnjava zašto ukupna točnost može biti visoka, iako model loše prepoznaje stvarne pobjednike. Izračunajmo sve mjere:

```
tocnost <- sum(diag(tab)) / sum(tab)
preciznost <- tab[2,2] / sum(tab[,2])
odziv <- tab[2,2] / sum(tab[2,])
specificnost <- tab[1,1] / sum(tab[,1])
metrics <- data.frame(
  `Točnost` = round(tocnost,4),
  `Preciznost` = round(preciznost,4),
  `Odziv` = round(odziv,4),
  `Specifičnost` = round(specificnost,4)
)
kable(metrics)
```

Točnost	Preciznost	Odziv	Specifičnost
0.8389	0.5714	0.0851	0.8456

Kao što smo mogli previdjeti iz prve tablice rezultata, parametar točnosti je visok, dok je parametar odziv definiran kao $\frac{TP}{TP + FN}$ iznimno nizak.