

trece_pitanje

36557629 Damjan Crnković

2026-01-22

Istraživanje povezanosti između starosti filma i njegove ocjene

```
oscars <- read.csv2("oscars_dataset.csv")
```

Opis problema

Jedno od pitanja koje razmatramo jest kako su filmovi ocijenjeni s obzirom na svoju starost, odnosno kako godina izlaska filma utječe na njegovu ocjenu. Cilj je dobiti uvid u trend promjene ocjena kroz godine i provjeriti jesu li godina izlaska i ocjena međusobno značajno korelirani.

Priprema podataka za analizu

Najprije moramo odabrati koje ocjene ćemo koristiti za analizu. Pogledajmo kojih podataka ima najviše odnosno nedostaju li neki podaci:

```
data.frame(Ocjena = c("IMDb", "Rotten Tomatoes", "Audience"),  
           Broj_vrijednosti = c(sum(oscars$IMDB.Rating != ""),  
                                sum(oscars$Tomatometer.Rating != ""),  
                                sum(oscars$Audience.Rating != "")))
```

##	Ocjena	Broj_vrijednosti
## 1	IMDb	571
## 2	Rotten Tomatoes	459
## 3	Audience	459

Primjećujemo da postoje neki nedostaci, stoga ćemo za daljnja promatranja koristiti podatke o IMDb ocjenama.


Kako bi podaci bili spremni za daljnu analizu, potrebno je osigurati da je njihov tip numeric.

```
oscars$IMDB.Rating <- as.numeric(as.character(oscars$IMDB.Rating))  
oscars$Year.of.Release <- as.numeric(as.character(oscars$Year.of.Release))
```

Vizualizacija podataka

Analizirajmo sada povezanost između godine izlaska filma i njegove ocjene. Budući da promatramo utjecaj jedne numeričke varijable (godina izlaska) na drugu numeričku varijablu (ocjena), osnovni uvid u njihov odnos dobiva se grafičkim prikazom pomoću scatter plot. Takav prikaz omogućuje uočavanje općeg trenda i eventualne nelinearnosti.


```
plot(oscars$Year.of.Release, oscars$IMDB.Rating,  
      main = "Odnos godine izlaska filma i IMDb ocjene",  
      xlab = "Godina izlaska filma",  
      ylab = "IMDb ocjena")
```



Scatter plot ne pokazuje jasno povećanje ocjena s godinama izlaska zbog raspršenosti podataka i prisutnosti outliera. Kako bismo bolje sagledali trend, možemo grupirati filmove po desetljećima i prikazati ocjene pomoću box plot, što omogućuje uočavanje promjena u medijanu i rasponu ocjena kroz vrijeme.

```
oscars$desetljece <- floor(oscars$Year.of.Release / 10) * 10  
boxplot(IMDB.Rating ~ desetljece, data = oscars,  
        main = "Distribucija IMDb ocjena po desetljećima",  
        xlab = "Desetljeće izlaska filma",  
        ylab = "IMDb ocjena")
```

Distribucija IMDb ocjena po desetljećima




Iz scatter plotu i box plotu može se naslutiti da postoji određena povezanost između godine izlaska filma i njegove ocjene, no ona se ne čini velikom.

Linearna regresija

Kako bismo procijenili jačinu promatranog odnosa, izrađujemo jednostavnu linearnu regresiju s ocjenom filma kao zavisnom varijablom i godinom izlaska kao nezavisnom varijablom.

```
fit.year <- lm(IMDB.Rating ~ Year.of.Release, data = oscars)
plot(oscars$Year.of.Release, oscars$IMDB.Rating,
     main = "Linearna regresija IMDb ocjene ~ godina izlaska",
     xlab = "Godina izlaska filma",
     ylab = "IMDb ocjena")
lines(oscars$Year.of.Release, fit.year$fitted.values, col = "blue")
```

Linearna regresija IMDb ocjene ~ godina izlaska




Dobiveni regresijski model pokazuje mali pozitivan nagib, što znači da noviji filmovi u prosjeku imaju nešto više ocjene, no efekt je slab. Kako bismo potvrdili valjanost ovakvog zaključka, potrebno je provjeriti temeljne pretpostavke linearne regresije, prvenstveno normalnost distribucije reziduala (i homogenost njihove varijance).

Analiza reziduala

Za vizualnu provjeru pretpostavke normalnosti reziduala koristimo histogram, koji omogućuje uvid u raspodjelu pogrešaka. Potpunu potvrdu normalnosti provjerit ćemo kasnije odgovarajućim statističkim testovima.

```
selected.model <- fit.year  
hist(selected.model$residuals, breaks = 15,  
      main = "Histogram reziduala linearnog regresijskog modela",  
      xlab = "Reziduali modela",  
      ylab = "Frekvencija")
```

Histogram reziduala linearnog regresijskog modela




Q-Q graf

Normalnost reziduala egzaktnije možemo provjeriti Q-Q plotom kako bismo utvrdili da pogreške modela približno slijede normalnu distribuciju, što je pretpostavka za valjanost statističkih testova koeficijenata i intervala pouzdanosti.

```
qqnorm(rstandard(selected.model),  
      main = "Q-Q dijagram standardiziranih reziduala",  
      xlab = "Teorijski kvantili normalne razdiobe",  
      ylab = "Standardizirani reziduali")  
qqline(rstandard(selected.model))
```

Q-Q dijagram standardiziranih reziduala



Q-Q graf pokazuje da reziduali uglavnom prate dijagonalnu liniju, s blagim odstupanjima na krajevima, što sugerira da pretpostavka normalnosti nije značajno narušena.

Testiranje Lillieforsovom inačicom

Provjerimo sada normalnost reziduala Lillieforsovom inačicom Kolmogorov-Smirnovljeva testa na razini značajnosti od 5% uz sljedeće hipoteze:

H0: Reziduali su normalno distribuirani

H1: Reziduali nisu normalno distribuirani.

```
lillie.test(rstandard(fit.year))
```

```
##  
## Lilliefors (Kolmogorov-Smirnov) normality test  
##  
## data:  rstandard(fit.year)  
## D = 0.026192, p-value = 0.4463
```

Testna statistika pokazuje vrlo visoku p-vrijednost. Budući da je ona veća od 0.05, test nije statistički značajan te nemamo dovoljno dokaza za odbacivanje nul-hipoteze. Reziduali se mogu smatrati normalno distribuiranima.

Pearsonov koeficijent korelacije

Kao završni korak analize, računamo Pearsonov koeficijent korelacije i provodimo test kako bismo statistički evaluirali odnos između godine nastanka filma i njegove IMDb ocjene. Test provodimo na razini značajnosti

od 5% uz hipoteze:

H0: Ne postoji linearna povezanost između godine izlaska filma i IMDb ocjene.

H1: Postoji linearna povezanost između godine izlaska filma i IMDb ocjene.

```
cor.test(oscars$Year.of.Release,oscars$IMDB.Rating)
```

```
##  
## Pearson's product-moment correlation  
##  
## data:  oscars$Year.of.Release and oscars$IMDB.Rating  
## t = 8.3363, df = 569, p-value = 5.783e-16  
## alternative hypothesis: true correlation is not equal to 0  
## 95 percent confidence interval:  
##  0.2547525 0.4011050  
## sample estimates:  
##          cor  
## 0.3299097
```

Koeficijent korelacije r iznosi 0,33 što ukazuje na umjerenu pozitivnu korelaciju dviju varijabli. P-vrijednost je vrlo mala, manja od 0,05. S obzirom na to, odbacujemo hipotezu H0 te je pozitivna povezanost statistički značajna. 95-postotni interval pouzdanosti je cijelim dijelom pozitivan što je još jedan indikator da pozitivna povezanost postoji.

Na temelju početnih deskriptivnih statistika opravdano bi bilo zaključiti i da stvarna korelacija između varijabli ne postoji te da je uočeni pozitivan trend posljedica šuma. Međutim, provedena statistička analiza i testovi pokazuju da je povezanost statistički značajna, a zbog velikog uzorka takav je zaključak opravdan.